密　　级：公开

加密论文编号：

论文题目：面向反无人机场景的无人机识别与定位系统设计与实现

学　　号：M202640106

作　　者：梁辰

专 业 名 称：软件工程

2026 年 11 月 20 日

面向反无人机场景的无人机识别与定位系统设计与实现

Design and Implementation of a Drone Recognition and Localization System for Counter-UAV Scenarios

研究生姓名：梁辰
指导教师姓名：段世红
北京科技大学数理学院
北京 100083，中国

Master Degree Candidate：Liang Chen
Supervisor：Shihong Duan
School of Mathematics and Physics
University of Science and Technology Beijing
30 Xueyuan Road，Haidian District
Beijing 100083，P.R.CHINA

中图分类号： TP391 学校代码: 10008
U D C ： 004.8 密 级: 公开

北京科技大学硕士学位论文

论文题目：

面向反无人机场景的无人机识别与定位系统设计与实现

作者： 梁辰

指 导 教 师： 段世红 **单位：** 北京科技大学 **职称：** 副教授

指 导 小 组 成 员： _____ **单位：** _____ **职称：** _____

_____ **单位：** _____ **职称：** _____

论文提交日期： 2026 年 11 月 20 日

学位授予单位： 北 京 科 技 大 学

摘 要

随着低空禁忌的快速发展，微型无人机在救援、航拍、物流、巡检等多领域广泛应用，但”黑飞””乱飞”等违规飞行事件也随之增多，对机场，军区等保密单位构成了威胁。这一问题已成为反无人机领域待解决的关键问题。雷达，声学，光学，视觉等光学视觉方案具有成本低，部署灵活，可直观确认目标等优势，但同时也面临这两个突出的问题，第一个问题较远距离目标在图像中成像过小，约几十个像素，属于小目标检测问题；第二个问题是在真实的场景环境中，树木、建筑等障碍物随处可见，检测数据中断较为频繁，难以形成连续，持久，可用的航迹。

针对以上问题，本文设计并实现了一个面向反无人机场景的无人机识别与定位系统。在这个系统中，单目可见相机是唯一的视觉传感器，通过“检测-跟踪-定位-显示”这一流程，主要工作包含了以下五个方面。

（1）面向小目标检测搭建模型。该模型以 YOLOv8n 为基础，在特征金字塔中增加 stride=4 的 P2 高分辨率检测头，并且在 C2f 模块中嵌入 EMA 搞笑多尺度注意力机制，结合成 YOLOv8n-P2-EMA 模型。随后将 Det-Fly 数据集划分为训练集与验证集，避免同一序列帧同时出现在训练和验证中，造成数据泄露。四组消融实验表明：YOLOv8n、+P2、+EMA、+P2+EMA 的 mAP50 分别为 81.3%、82.3%、76.2% 与 83.5%，AP_small 分别为 6.1%、8.3%、4.1% 与 9.8%，推理速度分别为 123、90、101 与 98 fps。本文模型以 2.94 M 参数量取得最优综合指标，AP_small 相对基线提升 60.7%，并可满足 30 fps 实时处理需求。

（2）揭示了仿真环境下检测死区的形成机理。在 PX4+jMAVSim 测试中发现，未微调模型在 3–6 m 近距离段检出率接近 0，在 9 m 以上远距离段亦无法稳定锁定，有效工作窗口仅 7–9 m。通过对 2228 帧录像与真值几何的逐帧审计，排除了”俯视视角导致失效”的假设，确认死区的决定因素是目标在图像中的尺度：近距离大尺度样本超出 Det-Fly 的远距小目标分布，属于分布外（OOD）输入；远距离样本则低于初锁门限。

（3）提出了仿真域微调方法并完成自动标注数据构建。利用 jMAVSim 护航相机始终注视目标机的特性，将目标框中心约束在光轴

附近，再由真值距离与等效尺寸反算框高，实现零人工标注的450帧仿真数据采集；按距离分层覆盖3–6 m、6–7 m、7–9 m与9–12 m四个区间。以20轮、学习率0.001、关闭Mosaic的方式微调后，3–10 m全距离段检出率提升至100%，置信度中位数0.867，检测死区被完全消除。

（4）设计了三态跟踪状态机与单目定位方法。状态机包含SEARCH、LOCKED与COAST三种状态，采用”0.25维持门限 + 0.55初锁门限”的双门限策略抑制误锁，采用140 px空间门限的最近邻匹配抑制身份跳变，采用1.0 s卡尔曼预测维持抑制短时遮挡中断。定位环节由检测框中心直接解算方位角与俯仰角，由框高与等效尺寸解算距离，并以六维状态的自适应卡尔曼滤波（Sage-Husa）平滑三维位置与速度。仿真闭环实验表明，微调后单帧测距RMSE为0.26 m、AKF稳态中位误差0.13 m、1 s距离预测ADE中位0.26 m、方位角误差中位0.05°；实拍视频中AKF相对单帧测距RMSE降低32%，抖动降低33%。

（5）完成了系统集成与自动化验证。系统采用”算法端—显示端”双进程架构，算法进程通过TCP接收720p@30fps视频帧、通过UDP接收50 Hz真值，并以UDP/JSON向显示端输出结构化结果；基于PySide6构建三页签监视大屏，包含卫星地图态势、光电画面、距离与方位仪表、威胁分级、CSV记录与参数持久化等功能。设计并执行了14个自动化用例，覆盖基线检测、真实场景、门限扫描、尺寸敏感、TCP遮挡与摄像头输入，13例完成、6例判定通过、0例失败，验证了完整链路的正确性与鲁棒性。

最后，本文将所提方法应用于改造后的jMAVSim城市巡游场景，实现了目标机主动飞行、护航相机被动尾随的编队巡游，并通过段内加减速与瞄准点滞后使画面呈现真实的追踪感，为后续外场试验与多传感器融合提供了可复现的实验平台。

关键词：反无人机；小目标检测；YOLOv8；P2检测头；EMA注意力；卡尔曼滤波；单目测距；仿真域微调

关键词：

Design and Implementation of a Drone Recognition and Localization System for Counter-UAV Scenarios

ABSTRACT

With the rapid development of the low-altitude economy, micro unmanned aerial vehicles (UAVs) have been widely used in many fields such as rescue, aerial photography, logistics, and inspection. However, illegal and irregular flight events such as “black flights” and “chaotic flights” have also increased, posing threats to airports, military regions, and other confidential units. This problem has become a key issue to be solved in the counter-UAV field. Radar, acoustic, optical, and vision-based solutions have advantages such as low cost, flexible deployment, and intuitive target confirmation, but they also face two prominent problems. The first problem is that distant targets are imaged too small in images, about tens of pixels, which belongs to small-object detection. The second problem is that in real scenarios, obstacles such as trees and buildings are ubiquitous, and detection data interruptions are frequent, making it difficult to form continuous, persistent, and usable tracks.

To address the above problems, this paper designs and implements a UAV identification and localization system for counter-UAV scenarios. In this system, a monocular visible-light camera is the only visual sensor. Through the pipeline of “detection–tracking–localization–display”, the main work includes the following five aspects.

(1) A model for small-object detection is built. The model is based on YOLOv8n, adds a P2 high-resolution detection head with stride=4 to the feature pyramid, and embeds an Efficient Multi-Scale Attention (EMA) mechanism into the C2f module, forming the YOLOv8n-P2-EMA model. Then the Det-Fly dataset is divided into training and validation sets to avoid the same sequence frames appearing in both training and validation and causing data leakage. Four ablation experiments show that the mAP50 of YOLOv8n, +P2, +EMA, and +P2+EMA are 81.3%, 82.3%, 76.2%, and 83.5%, respectively; AP_small are 6.1%, 8.3%, 4.1%, and 9.8%, respectively; and the inference speeds are 123, 90, 101, and 98 fps, respectively. The proposed model achieves the best overall performance with 2.94 M parame-

ters; AP_small is improved by 60.7% relative to the baseline, and it can meet the 30 fps real-time processing requirement.

(2) The formation mechanism of the detection dead zone in the simulation environment is revealed. In PX4+jMAVSim tests, it is found that the detection rate of the model without fine-tuning is close to 0 in the near range of 3–6 m, and it cannot stably lock in the far range above 9 m; the effective working window is only 7–9 m. Through frame-by-frame audit of 2228 frames of video and ground-truth geometry, the hypothesis that "the top-down view causes failure" is ruled out, and it is confirmed that the decisive factor of the dead zone is the scale of the target in the image: near-range large-scale samples exceed the far-range small-target distribution of Det-Fly and belong to out-of-distribution (OOD) inputs; far-range samples are below the initial locking threshold.

(3) A simulation-domain fine-tuning method is proposed and automatic annotation data construction is completed. Taking advantage of the characteristic that the jMAVSim escort camera always looks at the target UAV, the center of the target box is constrained near the optical axis, and then the box height is back-calculated from the ground-truth distance and equivalent size, realizing zero-manual-annotation collection of 450 frames of simulation data; the data are stratified by distance and cover four intervals: 3–6 m, 6–7 m, 7–9 m, and 9–12 m. After fine-tuning for 20 epochs with a learning rate of 0.001 and Mosaic disabled, the detection rate over the full range of 3–10 m is increased to 100%, the median confidence is 0.867, and the detection dead zone is completely eliminated.

(4) A three-state tracking state machine and a monocular localization method are designed. The state machine contains three states: SEARCH, LOCKED, and COAST. A dual-threshold strategy of "0.25 maintenance threshold + 0.55 initial locking threshold" is used to suppress false locking; nearest-neighbor matching with a 140 px spatial threshold is used to suppress identity switching; and 1.0 s Kalman prediction maintenance is used to suppress short-term occlusion interruptions. In the localization stage, the azimuth and elevation angles are directly solved from the center of the detection box, the distance is solved from the box height and equivalent size, and a six-dimensional state adaptive Kalman filter (Sage-Husa) is used to smooth the 3D position and velocity. Simulation closed-loop experiments show

that after fine-tuning, the single-frame ranging RMSE is 0.26 m, the AKF steady-state median error is 0.13 m, the median ADE of 1 s distance prediction is 0.26 m, and the median azimuth error is 0.05°; in real captured videos, the AKF reduces the RMSE by 32% and the jitter by 33% compared with single-frame ranging.

(5) System integration and automated verification are completed. The system adopts a dual-process architecture of "algorithm side–display side". The algorithm process receives 720p@30 fps video frames via TCP and 50 Hz ground truth via UDP, and outputs structured results to the display side via UDP/JSON; a three-tab monitoring dashboard is built based on PySide6, including satellite map situation, electro-optical imagery, distance and azimuth gauges, threat grading, CSV logging, and parameter persistence. Fourteen automated test cases are designed and executed, covering baseline detection, real scenes, threshold sweeping, size sensitivity, TCP occlusion, and camera input. Thirteen cases are completed, six are judged as passed, and zero cases failed, verifying the correctness and robustness of the complete pipeline.

Finally, the proposed method is applied to a modified jMAVSim urban patrol scene, realizing a formation patrol in which the target UAV flies actively and the escort camera passively tails it. Through intra-segment acceleration/deceleration and aiming-point lag, the image presents a realistic tracking feel, providing a reproducible experimental platform for subsequent field tests and multi-sensor fusion.

Keywords: counter-UAV; small object detection; YOLOv8; P2 detection head; EMA attention; Kalman filter; monocular ranging; simulation-domain fine-tuning

Key Words:

目 录

摘要 I
ABSTRACT III
目录 VII
1 绪论 1
1.1 研究背景 1
1.1.1 低空经济发展与无人机规模化应用 1
1.1.2 反无人机系统的典型环节与技术路线 1
1.1.3 光学视觉方案面临的核心困难 2
1.2 研究意义 3
1.2.1 理论意义 3
1.2.2 工程意义 4
1.3 国内外研究现状 4
1.3.1 通用目标检测算法的发展 4
1.3.2 无人机小目标检测研究现状 5
1.3.3 反无人机系统研究现状 6
1.3.4 单目定位与目标跟踪研究现状 6
1.3.5 仿真验证与域适应研究现状 7
1.4 现有方案的不足与本文切入点 7
1.5 本文主要研究内容 8
1.6 论文组织结构 8
2 相关理论与关键技术 11
2.1 目标检测基础 11
2.1.1 卷积神经网络 11
2.1.2 特征金字塔与多尺度检测 12
2.1.3 检测头的预测形式与损失函数 12
2.1.4 评测指标 13
2.2 YOLOv8 网络结构 13
2.2.1 整体结构 13
2.2.2 C2f 模块 14
2.2.3 SPPF 与解耦头 14
2.3 注意力机制 14
2.3.1 从 SE 到 CBAM 14
2.3.2 EMA 高效多尺度注意力 15

2.4 卡尔曼滤波 15
2.4.1 线性高斯状态空间模型 15
2.4.2 自适应噪声估计 16
2.4.3 滤波的收敛性与可观测性 17
2.5 针孔相机模型与标定 17
2.5.1 坐标系定义 17
2.5.2 投影模型 17
2.5.3 张正友标定法 18
2.6 PX4 与 jMAVSim 仿真框架 19
2.6.1 PX4 Autopilot 与 SITL 19
2.6.2 jMAVSim 架构 19
2.6.3 离屏渲染与帧流 20
2.7 系统开发技术 20
2.7.1 PySide6 与 QtWebEngine 20
2.7.2 OpenCV 与 PyTorch 20
2.7.3 TCP 与 UDP 通信 21
2.8 本章小结 21
3 数据集构建与数据工程 23
3.1 Det-Fly 数据集 23
3.1.1 数据集来源与内容 23
3.1.2 格式转换 23
3.1.3 序列级划分与数据泄漏 24
3.1.4 数据增强 25
3.2 自建 AprilTag 数据集 25
3.2.1 采集目的 25
3.2.2 硬件与采集流程 25
3.2.3 真值精度分析 26
3.3 仿真域自动标注数据集 26
3.3.1 构建动机 26
3.3.2 自动标注原理 27
3.3.3 距离分层采样 27
3.3.4 数据质量核验 28
3.4 评测口径与可复现性 28
3.5 本章小结 29

4 检测模型改进与消融实验 31
4.1 基础模型选型 31
4.1.1 规模选择 31
4.1.2 标准结构的局限 32
4.2 P2 小目标检测头 32
4.2.1 结构设计 32
4.2.2 检测头配置 33
4.2.3 计算量与参数分析 33
4.2.4 正负样本分配 33
4.3 EMA 注意力机制集成 33
4.3.1 插入位置 33
4.3.2 模块结构 34
4.3.3 计算开销 34
4.4 训练配置 34
4.4.1 数据集与划分 34
4.4.2 超参数 35
4.4.3 训练过程 35
4.5 消融实验 36
4.5.1 实验设置 36
4.5.2 实验结果 36
4.5.3 结果分析 36
4.5.4 混淆矩阵与 P-R 曲线 37
4.5.5 检测效果可视化 38
4.6 与非 YOLO 方法的横向讨论 38
4.7 有效工作范围与失效模式 39
4.7.1 置信度与目标尺度的关系 39
4.7.2 典型失效模式 39
4.8 本章小结 40
5 三态跟踪状态机 41
5.1 问题描述 41
5.1.1 误检 41
5.1.2 身份跳变 42
5.1.3 遮挡中断 42
5.2 状态定义与总体流程 42
5.2.1 状态定义 42
5.2.2 总体流程 43

5.3 SEARCH 状态 43
5.3.1 双门限策略 43
5.3.2 初锁判定 44
5.3.3 先验空间约束 44
5.3.4 首锁时延 45
5.4 LOCKED 状态 45
5.4.1 候选框收集 45
5.4.2 空间门限关联 45
5.4.3 卡尔曼滤波更新 46
5.4.4 丢失判定 46
5.4.5 框尺寸的平滑 47
5.5 COAST 状态 47
5.5.1 预测步 47
5.5.2 超时与恢复 47
5.5.3 预测质量 48
5.6 算法描述与复杂度 48
5.6.1 伪代码 48
5.6.2 复杂度分析 48
5.6.3 参数汇总 48
5.7 实验验证 48
5.7.1 门限敏感性 48
5.7.2 遮挡场景 50
5.7.3 真实场景录像 51
5.8 设计讨论 51
5.8.1 为什么不用多目标跟踪框架 51
5.8.2 为什么用状态机而不是有限状态自动机的形式化方法 52
5.8.3 失效边界 52
5.9 本章小结 52
6 单目定位与自适应卡尔曼滤波 53
6.1 坐标系与符号约定 53
6.2 方位角与俯仰角 54
6.2.1 像素直算法 54
6.2.2 角度误差传播 54
6.2.3 与滤波角度法的对比 54
6.2.4 真值口径问题 55

6.3 距离解算 55
6.3.1 相似三角形原理 55
6.3.2 等效尺寸标定 55
6.3.3 误差传播 56
6.3.4 框高抖动的影响 57
6.4 自适应卡尔曼滤波器设计 57
6.4.1 状态与量测 57
6.4.2 过程噪声 57
6.4.3 量测噪声与自适应估计 58
6.4.4 初始化的注意事项 59
6.5 定位精度评估 59
6.5.1 仿真闭环评估 59
6.5.2 实拍视频评估 60
6.5.3 短期预测精度 61
6.5.4 角度精度 61
6.6 误差来源与改进方向 61
6.6.1 主要误差来源 61
6.6.2 改进方向 62
6.7 本章小结 62
7 仿真闭环系统与域微调 63
7.1 仿真闭环总体架构 63
7.1.1 进程与数据流 63
7.1.2 lockstep 同步 64
7.1.3 启动流程 64
7.2 jMAVSim 改造 64
7.2.1 改造需求 64
7.2.2 脚本目标机 65
7.2.3 护航相机 65
7.2.4 真值广播 66
7.2.5 离屏渲染与帧流 66
7.2.6 场景构建 66
7.3 检测死区的发现 67
7.3.1 初期现象 67
7.3.2 距离分层统计 67
7.3.3 排除视角假设 68

7.3.4 尺度分布解释 68
7.3.5 对系统设计的影响 69
7.4 仿真域微调 69
7.4.1 数据采集与自动标注 69
7.4.2 微调配置 69
7.4.3 微调结果 69
7.4.4 域适应的机理讨论 71
7.5 编队巡游与尾随相机 71
7.5.1 设计目标 71
7.5.2 目标机航迹与加减速 72
7.5.3 尾随相机动力学 72
7.5.4 瞄准点滞后 73
7.5.5 验证结果 73
7.5.6 设计约束 74
7.6 本章小结 74
8 系统设计与实现 77
8.1 需求分析 77
8.1.1 功能需求 77
8.1.2 非功能需求 77
8.2 总体架构 78
8.2.1 双进程结构 78
8.2.2 线程模型 79
8.2.3 数据模型 79
8.3 算法端实现 79
8.3.1 视频源抽象 79
8.3.2 检测模块 80
8.3.3 状态机与滤波 80
8.3.4 数据记录 81
8.3.5 结果输出 81
8.4 显示端实现 81
8.4.1 界面布局 81
8.4.2 地图实现 82
8.4.3 光电画面 83
8.4.4 仪表与告警 83
8.4.5 回放页与设置页 84

8.5 通信协议 84
8.5.1 视频帧协议 84
8.5.2 真值协议 85
8.5.3 结果协议 85
8.6 配置与持久化 85
8.7 回放与自动化测试 86
8.7.1 14 用例测试框架 86
8.7.2 测试结果 86
8.8 部署与运行维护 87
8.8.1 运行环境 87
8.8.2 启动脚本 87
8.8.3 常见问题与处理 87
8.9 本章小结 88
9 实验与结果分析 89
9.1 实验环境与评测口径 89
9.1.1 硬件与软件环境 89
9.1.2 评测口径 89
9.2 检测模型性能 90
9.2.1 消融结果 90
9.2.2 指标解读 90
9.2.3 与已有工作的比较 91
9.3 仿真闭环定位精度 91
9.3.1 实验设置 91
9.3.2 结果 91
9.3.3 微调前后对比 91
9.4 实拍视频定位精度 92
9.4.1 数据集与设置 92
9.4.2 结果分析 92
9.4.3 预测精度 93
9.5 退化条件下的鲁棒性 93
9.5.1 实验设计 93
9.5.2 结果 93
9.5.3 分析 94
9.6 14 用例自动化回归测试 95
9.6.1 结果汇总 95
9.6.2 结果解读 95

9.7 运行性能 96
9.7.1 端到端延迟分解 96
9.7.2 资源占用 97
9.8 讨论 97
9.8.1 能力边界 97
9.8.2 失败案例 97
9.8.3 有效性威胁 98
9.9 本章小结 98
10 总结与展望 99
10.1 全文总结 99
10.2 主要创新点 100
10.3 不足与展望 101
10.3.1 存在的不足 101
10.3.2 未来工作 101
10.4 结语 102
参考文献 103
致谢 107
独创性说明 109
关于论文使用授权的说明 111
学位论文数据集 113

1 绪论

1.1 研究背景

1.1.1 低空经济发展与无人机规模化应用

过去十年间，微机电系统、飞控算法、电池与无线通信等技术的成熟，使多旋翼无人机从专业航拍设备迅速演变为大众消费品。以DJI、道通、零度等厂商为代表的企业将整机价格下探至数千元量级，起飞重量低于250 g的微型无人机甚至可以免注册购买。与之相伴的是低空空域活动密度的快速上升：航拍测绘、电力巡检、农林植保、快递物流、应急救援、灯光表演等应用场景不断扩展，城市低空正在形成一个新的经济形态，即通常所说的”低空经济”。

低空经济的繁荣带来了空域治理的新问题。一方面，无人机的合法运行需要飞行计划报备、空域申请、实名登记与实时监管；另一方面，无人机的获取门槛极低、操控简单、体积小巧，使得”黑飞”（未经许可的飞行）、”乱飞”（违反禁飞区或高度限制的飞行）以及恶意入侵难以通过传统手段有效遏制。近年来，国内外多次出现无人机闯入机场净空区导致航班大面积延误、无人机近距离拍摄军事设施或敏感区域、无人机携带危险载荷飞越人群等事件。这些事件表明，低空安全已经从理论风险转变为现实威胁，反无人机（Counter-UAV，C-UAV）技术因此成为学术界、产业界与监管部门共同关注的热点。

1.1.2 反无人机系统的典型环节与技术路线

一个完整的反无人机系统通常可以划分为”探测—识别—跟踪—定位—处置”五个环节[1-2]。探测环节负责发现空域中是否存在可疑目标；识别环节负责判定目标类型（无人机、鸟类、风筝、飞机等）；跟踪环节负责在时间序列上维持对同一目标的连续观测；定位环节负责给出目标相对观测平台或地理坐标系的位置；处置环节则根据威胁等级采取告警、干扰、诱骗或拦截等措施。其中，探测、跟踪与定位构成了整个系统的信息基础，其性能直接决定了后续处置是否可行。

按照所使用的物理媒介，现有探测手段可以分为雷达、射频、声

学、光学以及多传感器融合五类，表 1-1 对它们进行了对比。

表 1-1: 典型反无人机探测手段对比

手段	作用距离	优势	局限	适用场景
雷达	数百米至数公里	全天候、测距测速直接	小型目标雷达散射截面积小、设备昂贵、需频率许可	机场、边境、要地远程预警
射频侦测	数百米至数公里	被动工作、可识别型号	目标静默时失效、无法定位非合作目标	城市频谱监测
声学探测	数十米至数百米	成本低、可被动布设	易受环境噪声干扰、作用距离短	楼宇近程补盲
光学视觉	数十米至数百米	成本低、部署灵活、可直观确认	受光照与天气影响、小目标检出难、遮挡敏感	近程确认、跟踪与取证
多传感器融合	视配置而定	互补性强、可靠性高	系统复杂、时空高等级防护系统配准与数据融合难度大	

由表可见，雷达适合远距离预警，但对低慢小目标的探测能力有限，且设备成本与部署门槛较高[1]；射频侦测属于被动手段，一旦目标进入静默状态便完全失效[3]；声学探测成本低廉，但作用距离通常只有百米量级，且在城市噪声环境下虚警率较高[4]；多传感器融合虽然性能最好，却需要解决异构传感器的时空配准、数据关联与决策融合等一系列工程问题[2,5]。相比之下，光学视觉方案只需要一台普通可见光相机与一台计算设备，成本低、部署灵活，并且能够提供目标的外观证据，便于操作员人工复核，因而成为近程反无人机系统中不可替代的组成部分[6]。

1.1.3 光学视觉方案面临的核心困难

尽管优势明显，光学视觉方案在真实反无人机场景中仍面临两方面突出困难。

第一，**小目标检测难**。反无人机系统追求”早发现”，而越早发现意味着目标越远、成像越小。在 1280×720 分辨率的图像中，100 m 外的微型无人机往往只占十几个像素，即使在大倍率长焦镜头下也可能不足 50 像素。通用目标检测模型在 COCO 等以中大型目标为主的数据集上训练，其特征金字塔的最深层对应 32 倍下采样，微小目标在深层特征图上仅剩不到一个像素，响应极弱。Det-Fly 等无人机检测数据集的统计

也表明，目标框面积中位数不足画面面积的0.06%，99%以上的目标框面积小于画面的1%。如何在保持实时性的前提下提升小目标召回率，是检测环节的首要问题。

第二，**遮挡与抖动导致跟踪中断**。真实低空空域中充满树木、建筑、电线、广告牌等遮挡物，目标在飞行过程中频繁被短时遮挡。若系统以”每帧检测成功”为输出前提，则遮挡发生时输出会瞬间消失，航迹断裂、告警闪烁，操作员无法判断目标是暂时被遮挡还是已经飞离。此外，检测框本身存在像素级抖动，直接由框尺寸反算距离会产生米级跳变。如何在检测缺失时维持航迹、在检测存在时平滑输出，是跟踪与定位环节的核心问题。

除上述两点之外，工程落地还面临第三个困难：**仿真与真实域之间的差异**。出于成本与空域限制，算法开发通常先在仿真环境中完成闭环验证，再迁移到真实设备。然而仿真渲染的光照、纹理、边缘与真实相机存在显著差异，在真实数据上训练的模型直接用于仿真画面时可能出现严重的性能退化。本文在实验初期即观察到了这一现象，并将其作为一项专门的研究内容。

1.2 研究意义

1.2.1 理论意义

本文的研究意义首先体现在对小目标检测机理的补充上。现有工作大多从”增加检测层””引入注意力””改进损失函数”等角度提升指标，但对改进为何有效、在何种条件下失效缺乏统一解释。本文通过四组消融实验，将P2检测头的作用归结为”保留浅层空间分辨率”，将EMA的作用归结为”在通道与空间两个维度重加权”，并通过+EMA单独失效、+P2+EMA联合有效的现象，说明二者存在”看清”与”认准”的互补关系。这一解释对小目标检测的网络设计具有一般性参考价值。

其次，本文对仿真域检测死区的机理分析具有方法论意义。面对”模型在仿真中失效”这一现象，容易产生的第一反应是”视角不合适”或”渲染质量差”。本文通过真值几何审计与距离分层统计，定量排除了视角假设，将原因定位为目标尺度分布偏移，并进一步用仿真域微调实验验证了该解释。这种”现象—假设—证伪—验证”的分析路径，比单纯

报告指标更有助于理解域偏移的本质。

最后，本文将三态状态机、单目测距与自适应滤波整合为一条可运行的完整链路，并在统一的时间基准下评估检测、跟踪与定位的耦合性能，为反无人机视觉系统提供了一套可复现的工程范式。

1.2.2 工程意义

从工程角度看，本文系统具有以下价值。其一，硬件门槛低。系统仅依赖单目可见光相机与一台带 GPU 的普通计算机，不需要激光雷达、毫米波雷达或高精度惯导，便于在园区、楼宇、临时活动现场快速部署。其二，链路完整。系统不仅输出检测框，还输出目标距离、方位角、俯仰角、速度、威胁等级以及地理坐标，可直接对接上级指挥系统。其三，可测试性强。本文设计了 14 个自动化用例与统一的 CSV 记录格式，能够在无人值守条件下完成回归测试，为后续迭代提供量化基线。其四，可复现性强。仿真环境、数据采集脚本、自动标注流程与训练配置均已固化，研究者和工程师可以在相同条件下复现本文的全部实验。

1.3 国内外研究现状

1.3.1 通用目标检测算法的发展

目标检测算法的发展大致经历了三个阶段。第一阶段以手工特征与分类器组合为主，代表性方法是 HOG+SVM 与可变形部件模型（DPM），其检测精度依赖人工设计的特征，泛化能力有限。第二阶段以深度卷积网络为特征提取器，形成了两阶段与单阶段两条技术路线。两阶段方法以 Faster R-CNN[7] 为代表，先由区域建议网络（RPN）生成候选框，再对候选框进行分类与回归，精度较高但速度较慢；单阶段方法以 SSD[8] 与 YOLO 系列[9-11] 为代表，直接在特征图上预测类别与边框，速度优势明显。第三阶段以 Transformer 架构为代表，RT-DETR[12] 通过编码器—解码器结构与集合预测损失摆脱了锚框与非极大值抑制，在精度上接近甚至超过同期 YOLO，但计算量与部署复杂度更高。

在工程实践中，YOLO 系列因其”精度—速度—易用性”的平衡而成为主流选择。YOLOv5[10] 确立了以 CSPDarknet 为骨干、PANet 为颈部、解耦头为头部的结构；YOLOv8[11] 在此基础上引入 C2f 模块与更灵活的

任务对齐分配策略，并提供 n/s/m/l/x 五种规模。本文选择 YOLOv8n 作为基础模型，主要基于三点考虑：参数量约 3 M，便于与桌面应用集成；在 RTX 4060 级别 GPU 上批量推理可达 100 fps 以上；Ultralytics 提供了成熟的训练、验证与导出接口，便于复现实验。

1.3.2 无人机小目标检测研究现状

针对无人机小目标检测，现有研究大致可以分为四类。

第一类是**增加高分辨率检测层**。标准 YOLO 的最浅检测层为 P3（stride=8），对于十几个像素的目标仍显不足。SOD-YOLOv8[13] 在 YOLOv8 中增加更高分辨率的检测分支，并配合特征融合，提升了交通场景中小目标的召回率。本文将这一思想应用于无人机场景，增加 stride=4 的 P2 检测头，使 40 px 的目标在特征图上仍占据 10 个网格单元，而不是 5 个。

第二类是**引入注意力机制**。CBAM[14] 通过通道注意力与空间注意力串联，增强目标区域响应；EMA[15] 则采用分组并行与跨空间学习，在较低计算开销下同时建模通道与空间关系。YOLOv8-MPEB[16] 将骨干替换为 MobileNetV3 并引入高效多尺度注意力，实现轻量化无人机检测。MSDF-Net[17] 结合可变形卷积与高分辨率特征增强，在林业病害检测中验证了跨版本特征增强的有效性。

第三类是**改进损失函数与标签分配**。小目标对定位误差极为敏感，IoU 系列损失在目标框很小时梯度不稳定。SIoU[18] 引入角度代价，使回归方向更明确；Wise-IoU 通过动态聚焦机制降低低质量样本的梯度权重。本文在训练中沿用 YOLOv8 默认的 TaskAlignedAssigner 与 CIoU 损失，未对损失函数做额外改动，以保持与基线模型的可比性。

第四类是**数据集与评测协议**。Det-Fly[19] 是目前公开的较大规模无人机检测数据集之一，包含多种背景、多种机型与多种飞行状态。UAVDT[20] 则面向城市交通场景中的无人机跟踪。Kurmashev 等人[21] 系统比较了不同 YOLO 版本在无人机检测任务上的表现，指出模型规模、输入分辨率与数据分布对结果的影响远大于网络结构的细微差异。这一结论提醒我们：在报告指标时必须明确数据划分与评测口径，否则容易得出误导性结论。

1.3.3 反无人机系统研究现状

完整的反无人机系统研究主要集中在三个方向。

其一是**多传感器融合**。文献[5]提出融合射频、光学与雷达的多模态框架，利用 Remote ID 广播信号进行身份识别，利用视觉进行确认，利用雷达进行测距；文献[2]对现有反无人机方法与基准进行了系统综述，指出单一传感器在复杂环境下均存在盲区，融合是提升可靠性的必然选择。

其二是**射频与声学探测**。文献[3]利用无人机图传与遥控链路的射频特征实现检测与跟踪，能够在目标静默前提供较远距离的预警；文献[4]利用 MEMS 麦克风阵列与机器学习实现被动声学定位，成本极低但作用距离受限。

其三是**视觉检测与跟踪**。文献[6]对比了 YOLO 与 Faster R-CNN 在监控视频中的微型无人机检测性能，发现单阶段模型在速度上具有明显优势，而两阶段模型在极小目标上略优。总体来看，现有工作多聚焦于单一算法环节的指标提升，面向完整链路、可实际运行、具备可视化界面的系统级开源实现相对缺乏，这正是本文的切入点。

1.3.4 单目定位与目标跟踪研究现状

在定位方面，单目视觉测距通常有三类方法。第一类基于已知目标尺寸，利用相似三角形关系由框高或框宽反算距离，实现简单但对目标尺寸先验依赖强；第二类基于地面平面假设，利用相机高度与像平面几何关系解算目标落点，适用于地面目标；第三类基于多帧运动，通过特征点跟踪与三角化恢复深度，计算量大且对纹理敏感。本文的目标是空中无人机，不具备地面平面约束，且外观尺寸相对稳定，因此选择第一类方法，并通过仿真域标定获得等效尺寸。

在跟踪方面，SORT[22]用卡尔曼滤波预测目标位置、用匈牙利算法关联检测框，奠定了多目标跟踪的基本框架；DeepSORT[23]引入外观特征以降低身份切换。本文面向单目标跟踪场景，不需要外观重识别，但借鉴了”预测—关联—更新”的思想，并将关联失败时的处理显式建模为 COAST 状态。卡尔曼滤波[24]是最优线性估计的经典方法，但其量测噪声协方差需要预先设定。Sage-Husa 自适应滤波[25]通过残差在线估计

噪声统计特性，能够在量测质量变化时自动调整滤波增益，本文采用该思路构建自适应卡尔曼滤波器（AKF）。

1.3.5 仿真验证与域适应研究现状

受空域管制与成本限制，无人机算法的早期验证通常依赖仿真。PX4[26] 是应用最广泛的开源飞控固件，支持 SITL（Software In The Loop）模式；jMAVSim[27] 是其自带的轻量级三维仿真器，基于 Java3D 构建，能够以较低的资源开销模拟多旋翼动力学与相机视图。Gazebo 与 AirSim 提供更逼真的渲染，但对显卡与计算资源要求更高。本文选择 jMAVSim，主要原因是其启动快、可定制性强，便于通过 Java 源码改造注入目标机、相机与真值广播。

仿真到真实的域差异（sim-to-real gap）是近年来的研究热点。常见做法包括风格迁移、域随机化与目标域微调。风格迁移通过生成对抗网络将仿真图像转换为真实风格，但可能引入伪影；域随机化在训练时随机改变光照、纹理与噪声，提升模型鲁棒性，但需要大量训练资源；目标域微调则直接用少量目标域数据调整模型参数，简单有效。本文采用目标域微调路线，并针对仿真环境设计了零人工标注的采集流程，以较低成本消除了检测死区。

1.4 现有方案的不足与本文切入点

综合上述分析，现有方案存在以下不足。

（1）**小目标改进缺乏机理层面的解释**。多数工作只报告 mAP 提升，未说明改进在何种尺度、何种背景下起作用，也未讨论单独使用某一模块时可能出现的性能下降。本文通过消融实验与特征尺度分析，给出 P2 与 EMA 互补的解释。

（2）**仿真验证中的性能退化被忽视**。不少工作在仿真环境中直接使用真实数据训练的模型，遇到性能下降时归因于”渲染不真实”，缺少定量分析。本文通过逐帧真值审计定位死区成因，并用微调实验闭环验证。

（3）**跟踪与定位耦合不足**。检测、跟踪、测距往往被分别评估，缺少在统一时间基准下的端到端指标。本文在仿真闭环中以 50 Hz 真值为基准，同时评估检出率、测距误差、角度误差与预测误差。

（4）**系统级实现与可复现性不足**。许多研究停留在脚本与 notebooks

层面，缺少可视化界面、参数管理、日志记录与自动化测试。本文构建了完整的桌面系统与测试框架，并将全部配置固化。

基于以上分析，本文的切入点可以概括为：**以单目可见光相机为传感器，以改进的 YOLOv8n 为检测前端，以三态状态机为跟踪骨架，以自适应卡尔曼滤波为定位核心，以仿真闭环为验证平台，构建一套端到端可运行、可测试、可复现的反无人机识别与定位系统**。

1.5 本文主要研究内容

本文的主要研究内容包括以下五个方面。

（1）**小目标检测模型改进与消融分析**。在 YOLOv8n 上增加 P2 检测头与 EMA 注意力，构建四种模型配置，在 Det-Fly 数据集上按序列划分训练/验证集，完成消融实验，并从特征分辨率与注意力重加权两个角度解释结果。

（2）**数据集构建与数据工程**。完成 Det-Fly 数据格式转换、序列级划分与统计分析；采集自建 AprilTag 标定数据用于相机内参标定与定位精度评估；构建 450 帧仿真自动标注数据集，用于仿真域微调。

（3）**三态跟踪状态机设计**。针对误检、跳变与遮挡三个问题，设计 SEARCH/LOCKED/COAST 状态机，给出双门限、空间门限与超时参数的选择依据，并通过遮挡用例验证 COAST 的航迹保持效果。

（4）**单目定位与自适应滤波**。建立针孔相机模型，推导方位角、俯仰角与距离的解算公式，分析测距误差随距离与框高误差的传播规律；设计六维状态自适应卡尔曼滤波器，给出预测步与更新步的完整推导，并通过仿真与实拍数据评估平滑与预测性能。

（5）**仿真闭环与系统实现**。改造 PX4+jMAVSim 闭环，注入脚本目标机、护航相机、真值广播与离屏帧流；分析并消除检测死区；基于 PySide6 实现三页签监视大屏；设计 14 个自动化用例完成回归测试；进一步实现目标机主动飞行、相机被动尾随的编队巡游与加减速行为。

1.6 论文组织结构

本文共分十章，各章内容安排如下。

第一章为绪论。介绍研究背景、反无人机系统的技术路线、光学视觉方案的核心困难，综述国内外研究现状，分析现有方案的不足，并给

出本文的研究内容与组织结构。

第二章为相关理论与关键技术。介绍卷积神经网络与目标检测的基本原理、YOLOv8 的网络结构、注意力机制、卡尔曼滤波、针孔相机模型、PX4 与 jMAVSim 仿真框架、PySide6 与网络通信等本文所依赖的理论与技术基础。

第三章为数据集构建与数据工程。介绍 Det-Fly 数据集的来源、格式、统计特性与序列级划分方法；介绍自建 AprilTag 数据集的采集与标定流程；介绍仿真自动标注数据集的构建方法；讨论数据增强与评测口径。

第四章为检测模型改进与消融实验。详细阐述 P2 检测头与 EMA 注意力的设计，给出网络结构、计算量与感受野分析；介绍训练配置与损失函数；给出四组消融实验结果，并从尺度分布、注意力响应与参数效率三个角度解释结果；最后讨论模型的有效工作范围。

第五章为三态跟踪状态机。分析直接使用检测输出导致的误检、跳变与遮挡问题；给出状态定义、转移条件与参数选择；详细描述 SEARCH、LOCKED、COAST 三个状态的处理流程；给出伪代码与复杂度分析；通过遮挡用例验证航迹保持效果。

第六章为单目定位与自适应卡尔曼滤波。建立相机坐标系与像素坐标系的映射关系；推导方位角、俯仰角与距离的解算公式；分析测距误差传播；设计六维状态自适应卡尔曼滤波器，推导预测与更新过程；给出角度解算的两种实现及其对比；最后通过仿真与实拍数据评估定位精度。

第七章为仿真闭环系统与域微调。介绍 PX4 SITL 与 jMAVSim 的架构；详细说明本文对 jMAVSim 的改造，包括脚本目标机、护航相机、真值广播、离屏帧流与场景构建；描述检测死区的发现过程与机理分析；给出自动标注数据采集、距离分层采样与微调配置；展示微调前后的对比结果；介绍编队巡游与尾随相机的实现。

第八章为系统设计与实现。给出需求分析、总体架构与双进程通信协议；介绍算法端的模块划分、状态机实现与数据记录；介绍显示端的界面布局、地图投影、光电画面、仪表与告警；介绍参数管理、回放与自动化测试框架；讨论部署与运行维护。

第九章为实验与结果分析。给出实验环境与评测口径；分别报告检

测模型性能、仿真闭环定位精度、实拍视频定位精度、退化鲁棒性与14用例回归测试结果；进行横向对比与消融分析；讨论系统能力边界与失败案例。

第十章为总结与展望。总结全文工作与创新点，分析存在的不足，展望后续研究方向。

2 相关理论与关键技术

本章介绍本文系统所依赖的理论与技术基础，包括目标检测与卷积神经网络、YOLOv8 的网络结构、注意力机制、卡尔曼滤波、针孔相机模型、PX4 与 jMAVSim 仿真框架，以及 PySide6 与网络通信等内容。理解这些基础有助于把握后续章节中各项设计选择的依据。

2.1 目标检测基础

2.1.1 卷积神经网络

卷积神经网络（Convolutional Neural Network，CNN）通过局部连接、权值共享与空间池化三种机制，从图像中逐层提取由低级到高级的特征。设第 l 层的输入特征图为 $\mathbf{X}^{l-1} \in \mathbb{R}^{H_{l-1}\times W_{l-1}\times C_{l-1}}$，卷积核为 $\mathbf{W}^{l} \in \mathbb{R}^{k\times k\times C_{l-1}\times C_{l}}$，则第 l 层的输出为

$$\mathbf{X}^{l}_{i,j,c} = \sigma\left(\sum_{u=0}^{k-1}\sum_{v=0}^{k-1}\sum_{c'=0}^{C_{l-1}-1} \mathbf{W}^{l}_{u,v,c',c}\,\mathbf{X}^{l-1}_{i+u,\,j+v,\,c'} + b^{l}_{c}\right), \tag{2-1}$$

其中 k 为卷积核尺寸，b^{l}_{c} 为偏置，$\sigma(\cdot)$ 为非线性激活函数。现代检测网络普遍采用 SiLU（Swish）激活：

$$\mathrm{SiLU}(x) = x \cdot \mathrm{sigmoid}(x) = \frac{x}{1+e^{-x}}. \tag{2-2}$$

与 ReLU 相比，SiLU 在负半轴保留小幅非零梯度，有助于缓解小目标训练中的梯度消失。

批归一化（Batch Normalization，BN）在每个小批量内对通道维度做标准化，使各层输入分布保持稳定，从而允许更大的学习率与更快的收敛：

$$\hat{x} = \frac{x-\mu_{\mathcal{B}}}{\sqrt{\sigma^{2}_{\mathcal{B}}+\epsilon}}, \qquad y = \gamma\hat{x} + \beta. \tag{2-3}$$

2.1.2 特征金字塔与多尺度检测

目标在图像中的尺度差异极大，单一尺度的特征图难以同时兼顾大小目标。特征金字塔网络（Feature Pyramid Network，FPN）[28] 通过自顶向下的路径将深层语义特征与浅层高分辨率特征融合，使每一层都同时具备较强的语义与空间信息。PANet[29] 在 FPN 基础上增加自底向上的路径，进一步缩短浅层特征到检测头的传播距离。YOLOv8 的颈部即采用 PAN-FPN 结构。

设骨干网络输出的特征图为 C_3, C_4, C_5，分别对应 stride 8、16、32；FPN 的融合过程可写为

$$P_l = \mathrm{Conv}\left(\mathrm{Upsample}(P_{l+1}) \oplus \mathrm{Conv}(C_l)\right), \tag{2-4}$$

其中 $\oplus$ 表示逐元素相加，Conv 通常为 1×1 卷积（用于通道对齐）加 3×3 卷积（用于消除上采样混叠）。PAN 路径则从 P_3 向 P_5 做下采样融合。最终检测头分别接在 P_3, P_4, P_5 上，对应的下采样倍数越大，感受野越大，适合检测大目标；倍数越小，空间分辨率越高，适合检测小目标。

2.1.3 检测头的预测形式与损失函数

YOLOv8 采用无锚框（anchor-free）的检测头，每个网格位置直接预测目标中心相对网格的偏移量、宽高以及类别概率。对于分类分支，使用二元交叉熵（BCE）损失：

$$L_{cls} = -\frac{1}{N_{pos}} \sum_{i} \left[y_i \log p_i + (1 - y_i) \log(1 - p_i) \right]. \tag{2-5}$$

对于边框回归，YOLOv8 使用分布焦点损失（Distribution Focal Loss，DFL）与 CIoU 损失的组合。DFL 将边框回归建模为离散概率分布，使网络能够学习边界的不确定性：

$$L_{DFL} = -\sum_{i} \left((y_{i+1} - y) \log p_i + (y - y_i) \log p_{i+1} \right). \tag{2-6}$$

CIoU 同时考虑重叠面积、中心点距离与宽高比一致性：

$$L_{CIoU} = 1 - \mathrm{IoU} + \frac{\rho^2(\mathbf{b}, \mathbf{b}^{gt})}{c^2} + \alpha v, \tag{2-7}$$

其中 $\rho(\cdot)$ 为欧氏距离，c 为最小外接矩形对角线长度，v 为宽高比一致性项，α 为权重系数。

2.1.4 评测指标

目标检测的常用指标包括 IoU、Precision、Recall、AP 与 mAP。交并比（IoU）定义为预测框与真值框交集面积与并集面积之比：

$$\mathrm{IoU} = \frac{|\mathcal{B}_{pred} \cap \mathcal{B}_{gt}|}{|\mathcal{B}_{pred} \cup \mathcal{B}_{gt}|}. \tag{2-8}$$

在某一 IoU 阈值下，将预测按置信度降序排列，逐点计算 Precision 与 Recall，可得到 P-R 曲线，其下面积即为该类别在该阈值下的平均精度 AP。对所有类别取平均得到 mAP。COCO 评测协议以 IoU 从 0.50 到 0.95、步长 0.05 的十个阈值取平均，记为 mAP50-95；mAP50 则只取 IoU=0.50。

COCO 还按目标框面积将目标划分为小、中、大三类：面积小于 32^2 像素为 small，介于 32^2 与 96^2 之间为 medium，大于 96^2 为 large。对于反无人机任务，small 子集上的 AP（本文记为 AP_small）是最具参考价值的指标，因为远距离目标大多落在该区间。需要强调的是，检测框面积与目标实际物理尺寸无关，同一架无人机在不同距离下会落入不同的分桶，因此 AP_small 反映的是" 模型在多远距离上仍能检出" 的综合能力。

速度指标通常以 FPS（Frames Per Second）衡量。由于不同实现的预处理、后处理与显存拷贝开销差异很大，FPS 必须注明测量条件。本文统一采用 batch=1、帧预载内存、包含预处理与后处理的口径，以保证不同模型之间的可比性。

2.2 YOLOv8 网络结构

2.2.1 整体结构

YOLOv8 由骨干（Backbone）、颈部（Neck）与头部（Head）三部分组成。骨干采用改进的 CSPDarknet，通过 C2f 模块在保持梯度流动的同时减少计算量；颈部采用 PAN-FPN，实现多尺度特征的双向融合；头部采用解耦结构，将分类与回归分支分离，避免两个任务的特征相互干扰。YOLOv8n 是五种规模中最小的一种，参数量约 3.0 M，在 640×640 输入下的计算量约 8.7 GFLOPs。

2.2.2 C2f 模块

C2f（CSP Bottleneck with 2 convolutions and f fused outputs）模块是YOLOv8 的核心组件。其结构可以概括为：输入先经过 1×1 卷积降维，然后分为两支，一支直接短路，另一支经过若干个 Bottleneck 后逐级拼接，最后再经过 1×1 卷积融合。与 YOLOv5 的 C3 模块相比，C2f 保留了更多的梯度流分支，使浅层特征能够更直接地传递到检测头，这对小目标检测尤为重要。

设输入为 $\mathbf{X}$，C2f 的输出可写为

$$\mathbf{Y}=\mathrm{Conv}_{1\times1}\left(\mathrm{Concat}\left[\mathbf{X}_0,\mathcal{B}_1(\mathbf{X}_1),\mathcal{B}_2(\mathbf{X}_2),\ldots,\mathcal{B}_n(\mathbf{X}_n)\right]\right), \tag{2-9}$$

其中 $\mathcal{B}_i$ 表示第 i 个 Bottleneck，$\mathbf{X}_i$ 为前一层输出。由于每个 Bottleneck 的输出都参与最终拼接，网络实际上获得了多感受野的特征组合。

2.2.3 SPPF 与解耦头

SPPF（Spatial Pyramid Pooling - Fast）通过串联多个不同尺寸的最大池化层，在不显著增加计算量的前提下扩大感受野，增强模型对目标整体结构的感知。解耦头则将分类与回归分别送入两条独立的卷积分支，分类分支输出 C 个类别的概率，回归分支输出 4 个边框参数与 16 个分布参数。解耦设计减少了任务间的负迁移，是 YOLOv8 相比前代的重要改进之一。

2.3 注意力机制

2.3.1 从 SE 到 CBAM

Squeeze-and-Excitation（SE）模块通过全局平均池化获得通道描述子，再经两层全连接网络生成通道权重：

$$\mathbf{s}=\sigma\left(\mathbf{W}_2\,\delta\left(\mathbf{W}_1\,\mathrm{GAP}(\mathbf{X})\right)\right),\qquad \mathbf{X}'=\mathbf{s}\odot\mathbf{X}. \tag{2-10}$$

CBAM[14] 在通道注意力之后串联空间注意力，空间分支对通道维度做最大池化与平均池化，再经 7×7 卷积生成空间权重图。二者的共同点是”先压缩、再激励”，但都只在一个维度上建模，且空间分支的感

受野有限。

2.3.2 EMA 高效多尺度注意力

EMA（Efficient Multi-scale Attention）[15] 的核心思想是**分组并行 + 跨空间学习**。设输入特征图为 $\mathbf{X} \in \mathbb{R}^{C\times H\times W}$，EMA 首先沿通道维度将其分为 G 组，每组独立进行如下处理：

（1）对组内特征分别沿水平与垂直方向做一维池化，得到两组方向感知的描述子；

（2）对描述子做一维卷积，建模局部跨通道交互；

（3）将两组描述子通过 sigmoid 归一化后与原始特征逐元素相乘，得到方向注意力增强的特征；

（4）对增强后的特征做全局平均池化，并通过 softmax 生成跨空间的注意力权重；

（5）将两组权重与原始输入相乘后相加，输出最终特征。

与 CBAM 相比，EMA 的优势在于：分组并行降低了大通道数下的计算量；一维方向卷积以极小的参数量建模长程依赖；跨空间学习使不同组之间能够交换信息，避免分组造成的特征割裂。对于小目标而言，这种”方向感知 + 跨组交互”的机制能够在复杂背景中更准确地定位目标所在的条带区域。

2.4 卡尔曼滤波

2.4.1 线性高斯状态空间模型

卡尔曼滤波[24] 解决的是线性高斯系统的最优状态估计问题。设离散时间系统的状态方程与量测方程为

$$\mathbf{x}_k = \mathbf{F}_k\mathbf{x}_{k-1} + \mathbf{B}_k\mathbf{u}_k + \mathbf{w}_k, \qquad \mathbf{z}_k = \mathbf{H}_k\mathbf{x}_k + \mathbf{v}_k, \tag{2-11}$$

其中 $\mathbf{w}_k \sim \mathcal{N}(\mathbf{0}, \mathbf{Q}_k)$ 为过程噪声，$\mathbf{v}_k \sim \mathcal{N}(\mathbf{0}, \mathbf{R}_k)$ 为量测噪声，二者相互独立。卡尔曼滤波分为预测与更新两步。

预测步：

$$\hat{\mathbf{x}}_{k|k-1} = \mathbf{F}_k\hat{\mathbf{x}}_{k-1|k-1}, \tag{2-12}$$

$$\mathbf{P}_{k|k-1} = \mathbf{F}_k \mathbf{P}_{k-1|k-1} \mathbf{F}_k^T + \mathbf{Q}_k. \tag{2-13}$$

更新步：

$$\mathbf{K}_k = \mathbf{P}_{k|k-1} \mathbf{H}_k^T \left(\mathbf{H}_k \mathbf{P}_{k|k-1} \mathbf{H}_k^T + \mathbf{R}_k \right)^{-1}, \tag{2-14}$$

$$\hat{\mathbf{x}}_{k|k} = \hat{\mathbf{x}}_{k|k-1} + \mathbf{K}_k \left(\mathbf{z}_k - \mathbf{H}_k \hat{\mathbf{x}}_{k|k-1} \right), \tag{2-15}$$

$$\mathbf{P}_{k|k} = \left(\mathbf{I} - \mathbf{K}_k \mathbf{H}_k \right) \mathbf{P}_{k|k-1}. \tag{2-16}$$

增益矩阵 $\mathbf{K}_k$ 的物理含义是”在预测与量测之间分配信任”：当量测噪声 $\mathbf{R}$ 较大时，增益变小，滤波器更信任预测；当预测不确定度 $\mathbf{P}$ 较大时，增益变大，滤波器更信任量测。

2.4.2 自适应噪声估计

标准卡尔曼滤波要求 $\mathbf{Q}$ 与 $\mathbf{R}$ 已知且恒定。在视觉跟踪中，检测框的抖动程度随目标距离、光照与背景而变化，固定 $\mathbf{R}$ 难以适应。Sage-Husa 自适应滤波[25] 利用新息（innovation）序列在线估计噪声统计特性。新息定义为

$$\boldsymbol{\nu}_k = \mathbf{z}_k - \mathbf{H}_k \hat{\mathbf{x}}_{k|k-1}. \tag{2-17}$$

在理论噪声统计下，新息应为零均值白噪声，其协方差为

$$\mathbf{S}_k = \mathbf{H}_k \mathbf{P}_{k|k-1} \mathbf{H}_k^T + \mathbf{R}_k. \tag{2-18}$$

通过对新息协方差做滑动平均，可以反解出 $\mathbf{R}_k$ 的估计：

$$\hat{\mathbf{R}}_k = \frac{1}{M} \sum_{i=k-M+1}^{k} \left(\boldsymbol{\nu}_i \boldsymbol{\nu}_i^T - \mathbf{H}_i \mathbf{P}_{i|i-1} \mathbf{H}_i^T \right), \tag{2-19}$$

其中 M 为滑动窗口长度。实际实现中通常对 $\hat{\mathbf{R}}_k$ 做下界约束与对角化处理，以避免数值不稳定。本文在第六章给出具体的实现细节。

2.4.3 滤波的收敛性与可观测性

卡尔曼滤波的估计误差协方差在系统一致可观测的条件下收敛。对于本文的六维状态（位置与速度），量测只包含位置，速度通过位置的时间差分间接观测。若目标长时间匀速直线运动，速度的可观测性较弱，滤波收敛较慢；若目标做机动，位置的变化会提供额外的速度信息。工程上通常通过增大过程噪声 $\mathbf{Q}$ 中的速度项来加快收敛，但代价是稳态抖动增大。本文在参数整定中对二者做了折中。

2.5 针孔相机模型与标定

2.5.1 坐标系定义

本文涉及四个坐标系：世界坐标系、相机坐标系、图像坐标系与像素坐标系。世界坐标系采用北—东—地（North-East-Down，NED）约定，x 轴指向北，y 轴指向东，z 轴指向地心，地面上 $z=0$，高度越大 z 越小。相机坐标系以光心为原点，z_c 轴沿光轴指向景物，x_c 轴向右，y_c 轴向下。图像坐标系以主点为原点、以物理尺寸为单位；像素坐标系以图像左上角为原点、以像素为单位。

设世界坐标系到相机坐标系的旋转矩阵为 $\mathbf{R}$、平移向量为 $\mathbf{t}$，则点 P_w 在相机坐标系下的坐标为

$$\mathbf{P}_c = \mathbf{R}\,\mathbf{P}_w + \mathbf{t}. \tag{2-20}$$

2.5.2 投影模型

针孔模型将三维点投影到归一化像平面，再经内参矩阵映射到像素坐标：

$$s\begin{bmatrix} u \\ v \\ 1 \end{bmatrix} = \mathbf{K}\begin{bmatrix} \mathbf{R} & \mathbf{t} \end{bmatrix}\begin{bmatrix} X_w \\ Y_w \\ Z_w \\ 1 \end{bmatrix}, \qquad \mathbf{K} = \begin{bmatrix} f_x & 0 & c_x \\ 0 & f_y & c_y \\ 0 & 0 & 1 \end{bmatrix}, \tag{2-21}$$

其中 $s = Z_c$ 为深度，f_x, f_y 为以像素为单位的焦距，(c_x, c_y) 为主点。

若只考虑相机坐标系下的点，则

$$u = f_x \frac{X_c}{Z_c} + c_x, \qquad v = f_y \frac{Y_c}{Z_c} + c_y. \tag{2-22}$$

实际镜头存在径向畸变与切向畸变，常用的 Brown-Conrady 模型为

$$\begin{aligned} x_d &= x(1 + k_1 r^2 + k_2 r^4 + k_3 r^6) + 2p_1 xy + p_2(r^2 + 2x^2), \\ y_d &= y(1 + k_1 r^2 + k_2 r^4 + k_3 r^6) + p_1(r^2 + 2y^2) + 2p_2 xy, \end{aligned} \tag{2-23}$$

其中 (x, y) 为归一化无畸变坐标，$r^2 = x^2 + y^2$，k_1, k_2, k_3 为径向畸变系数，p_1, p_2 为切向畸变系数。本文仿真相机无畸变，实拍相机在标定后按上述模型去畸变。

2.5.3 张正友标定法

张正友标定法[30] 利用平面棋盘格在不同位姿下的多幅图像，通过单应性矩阵约束求解内参。设棋盘格平面为 $Z_w = 0$，则式 (2-21) 退化为单应变换：

$$s \begin{bmatrix} u \\ v \\ 1 \end{bmatrix} = \mathbf{K} \begin{bmatrix} \mathbf{r}_1 & \mathbf{r}_2 & \mathbf{t} \end{bmatrix} \begin{bmatrix} X_w \\ Y_w \\ 1 \end{bmatrix} = \mathbf{H} \begin{bmatrix} X_w \\ Y_w \\ 1 \end{bmatrix}. \tag{2-24}$$

利用旋转向量正交约束 $\mathbf{r}_1^T \mathbf{r}_2 = 0$、$\|\mathbf{r}_1\| = \|\mathbf{r}_2\| = 1$，可以构造关于 $\mathbf{K}$ 的线性方程组，至少三幅不同位姿的图像即可求解。随后用最大似然估计优化重投影误差：

$$\min_{\mathbf{K}, \mathbf{k}, \{\mathbf{R}_i, \mathbf{t}_i\}} \sum_i \sum_j \left\| \mathbf{p}_{ij} - \hat{\mathbf{p}}(\mathbf{K}, \mathbf{k}, \mathbf{R}_i, \mathbf{t}_i, \mathbf{P}_j) \right\|^2. \tag{2-25}$$

本文在自建数据采集环节使用 9×6、方格边长 25 mm 的棋盘格完成内参标定，标定结果用于评估单目定位的绝对精度。

2.6 PX4 与 jMAVSim 仿真框架

2.6.1 PX4 Autopilot 与 SITL

PX4[26] 是一款开源飞控固件，支持多旋翼、固定翼、垂直起降等多种机型。其软件在环（SITL）模式将飞控固件编译为可在普通 PC 上运行的进程，通过 MAVLink[31] 协议与仿真器交换传感器数据与执行器指令。SITL 的优势在于：无需真实飞控硬件即可验证控制逻辑、航点任务与失效保护；可以与多种仿真器（jMAVSim、Gazebo、AirSim）组合；支持 lockstep 模式，使仿真时间与飞控时间严格同步，保证实验结果可复现。

在 lockstep 模式下，仿真器每推进一步都等待飞控完成相应的控制计算，二者以相同的仿真时间前进。这使得” 仿真 60 秒” 与” 飞控内部 60 秒” 完全一致，避免了因计算速度差异导致的时间漂移。本文的所有闭环实验均启用 lockstep。

2.6.2 jMAVSim 架构

jMAVSim[27] 是 PX4 自带的轻量级仿真器，使用 Java 与 Java3D 构建。其核心类包括：

（1）`Simulator`：仿真主循环，负责解析命令行参数、创建世界、启动物理步进与网络通信；

（2）`World`：物理世界容器，管理所有 `KinematicObject`，每个仿真步调用各对象的 `update` 方法；

（3）`KinematicObject`：所有可运动对象的基类，提供位置、速度、姿态接口；

（4）`Vehicle`：多旋翼动力学模型，接收 MAVLink 指令并积分运动方程；

（5）`Visualizer3D`：基于 Java3D 的三维渲染器，负责场景构建、相机视角与画面输出；

（6）`MAVLinkInterface`：与 PX4 的 MAVLink 通信接口。

jMAVSim 的坐标约定与 PX4 一致，采用 NED：x 向北、y 向东、z 向下。场景中的地面位于 $z = 0$，飞行器高度为负值。本文在改造 jMAVSim 时严格遵循这一约定，并在真值广播中加入坐标转换说明，避免与算法端的相机坐标系混淆。

2.6.3 离屏渲染与帧流

jMAVSim 默认依赖窗口系统显示三维画面。在无头服务器或 WSL 环境中，窗口系统可能不可用或不稳定，本文因此实现了纯离屏渲染模式：关闭 Java3D 的窗口画布，改用离屏 `Canvas3D` 渲染到缓冲区，再将帧编码为 JPEG 通过 TCP 推送。该模式避免了图形界面依赖，使仿真可以在后台长时间稳定运行。具体实现将在第七章详细介绍。

2.7 系统开发技术

2.7.1 PySide6 与 QtWebEngine

PySide6 是 Qt 6 的官方 Python 绑定，提供窗口、控件、绘图、定时器、网络与多媒体等完整能力。本文使用其 `QWidget` 体系构建主界面，使用 `QPainter` 自绘仪表与罗盘，使用 `QPixmap` 显示视频帧，使用 `QSettings` 的替代方案（JSON 文件）持久化配置。

地图部分使用 QtWebEngine 嵌入 Leaflet[32] 页面。Leaflet 是一个轻量级开源地图库，支持瓦片图层、标记、折线、多边形与自定义覆盖物，能够在本地 HTML 中加载 Esri 卫星影像。Python 端通过 `QWebChannel` 或 JavaScript 注入向页面推送目标位置，实现地图标记的实时更新。

2.7.2 OpenCV 与 PyTorch

OpenCV 负责图像解码、颜色空间转换、几何绘制与视频读写。本文使用 `cv2.VideoCapture` 读取离线视频与摄像头，使用 `cv2.imencode` 将帧编码为 JPEG，使用 `cv2.line`、`cv2.rectangle`、`cv2.putText` 绘制检测叠加层。

PyTorch 与 Ultralytics 负责模型加载与推理。YOLOv8 模型可直接通过 `YOLO("best.pt")` 加载，调用 `model.predict` 获得检测框、置信度与类别。为降低端到端延迟，本文在推理时关闭冗余的日志与可视化，并将输入尺寸固定为 640×640。

2.7.3 TCP 与 UDP 通信

系统涉及两类网络通信。视频帧流使用 TCP：TCP 提供可靠、有序的字节流，适合体积较大的 JPEG 帧；协议为”一行文本头 + 二进制数据”，头部包含帧序号、时间戳、宽度、高度与字节数，接收端按字节数精确读取，避免粘包。真值广播与结果输出使用 UDP：UDP 无连接、开销小，适合高频小报文；本文的真值广播频率为 50 Hz，结果输出频率与处理帧率一致。

需要说明的是，UDP 不保证送达，因此在结果输出中本文采用”最新值覆盖”策略：显示端只关心当前状态，丢失个别报文不会影响整体显示；同时通过序号字段检测丢包率，用于评估链路质量。

2.8 本章小结

本章介绍了本文所依赖的理论与技术基础。在检测方面，说明了卷积网络、特征金字塔、检测头预测形式与评测指标；在模型方面，剖析了 YOLOv8 的 C2f、SPPF 与解耦头结构；在注意力方面，对比了 SE、CBAM 与 EMA 的建模方式；在滤波方面，给出了卡尔曼滤波的预测—更新方程与 Sage-Husa 自适应噪声估计；在定位方面，建立了针孔相机模型与张正友标定法；在仿真方面，介绍了 PX4 SITL、jMAVSim 的类结构与 NED 坐标约定；在系统方面，概述了 PySide6、Leaflet、OpenCV、PyTorch 与 TCP/UDP 的使用方式。这些内容为后续章节的设计与实验提供了共同的语言基础。

3 数据集构建与数据工程

数据是目标检测系统的基石。本章介绍本文使用的三类数据：公开的 Det-Fly 无人机检测数据集、自建的 AprilTag 标定与定位评测数据集、以及仿真域自动标注数据集。重点说明数据的来源、格式转换、划分策略、统计特性与评测口径，并讨论数据泄漏、类别不平衡与尺度分布等容易被忽视的问题。

3.1 Det-Fly 数据集

3.1.1 数据集来源与内容

Det-Fly[19] 是反无人机视觉检测领域常用的公开数据集，由多段无人机飞行视频帧组成，标注格式为 YOLO 文本格式，类别为单一类别 UAV。数据覆盖多种背景（天空、树林、建筑、山地）、多种机型与多种飞行状态（悬停、平飞、盘旋、远近变化）。图像分辨率与拍摄设备在不同序列间存在差异，整体以中远距离拍摄为主，目标在画面中的占比普遍较小。

与 COCO 等通用数据集相比，Det-Fly 的显著特点是**目标尺度分布极度偏向小目标**。本文对转换后的 13271 个标注框做了统计，结果如表 3-1 所示。

由表可见，虽然按 COCO 面积口径仅 11.2% 的框属于 small，但这是相对于各图像自身分辨率计算的结果；若统一折算到 1280×720 的推理分辨率，绝大多数目标在画面中的面积不足 1%。这解释了为什么通用检测模型在该数据集上的 AP_small 极低，也说明了增加高分辨率检测层的必要性。

3.1.2 格式转换

原始数据以视频帧与独立标注文件的形式组织，本文编写了转换脚本将其整理为 YOLO 训练所需的目录结构：

```
dataset/
  images/
```

表 3-1: Det-Fly 数据集标注统计

统计项	数值	占比
标注文件数	13271	–
标注框总数	13270	100%
类别数	1（UAV）	100%
small（$< 32^2$ px）	1490	11.2%
medium（$32^2 \sim 96^2$ px）	8067	60.8%
large（$> 96^2$ px）	3713	28.0%
目标框面积最小值	0.0013% 画面面积	–
目标框面积中位数	0.0554% 画面面积	–
目标框面积 $< 1\%$ 画面	–	99.1%
目标框面积 $< 5\%$ 画面	–	100.0%

```
  train/  val/
labels/
  train/  val/
data.yaml
```

每张图像对应一个同名.txt 标注文件，每行格式为

```
<class_id> <x_center> <y_center> <width> <height>
```

其中后四项均为相对图像宽高的归一化值，取值范围 $[0, 1]$。转换过程中做了三项校验：坐标越界裁剪、零面积框剔除、图像与标注一一对应检查。最终保留 13270 个有效标注框。

3.1.3 序列级划分与数据泄漏

数据划分是影响评测可信度的关键因素。若随机按帧划分，同一段视频的相邻帧可能同时进入训练集与验证集，由于相邻帧在背景、光照、目标姿态上高度相似，模型实际上”见过”验证样本，导致指标虚高。这种数据泄漏在小目标检测中尤为严重，因为模型可能记住背景纹理而非学习目标特征。

本文按**序列**划分：以序列编号中的 010 与 020 为界，010 序列全部用于训练，020 序列全部用于验证。这样可以保证验证集中的背景、光照与飞行场景在训练集中未出现过，评测结果更接近真实部署时的泛化性能。划分比例约为 8:2，与常用实践一致。

需要说明的是，序列级划分会使验证集指标低于随机划分，这是正常现象。本文在报告中统一注明”序列级划分”，以便读者正确理解指标含义。

3.1.4 数据增强

训练阶段采用 Ultralytics 默认的数据增强策略，包括：

（1）**Mosaic**：将四张图像随机拼接为一张，增加目标在不同位置、不同尺度下的出现概率，同时变相扩大批量大小；

（2）**HSV 扰动**：随机调整色调、饱和度与明度，提升对光照变化的鲁棒性；

（3）**随机翻转与平移**：水平翻转概率 0.5，平移比例 0.1；

（4）**尺度缩放**：随机缩放比例 0.5，模拟目标远近变化。

在仿真域微调阶段，本文**关闭 Mosaic**。原因是仿真数据的尺度分布是精心分层设计的，Mosaic 拼接会破坏这一分布，使近距离大目标被缩小、远距离小目标被放大，从而削弱微调对死区的针对性。

3.2 自建 AprilTag 数据集

3.2.1 采集目的

公开数据集缺少与本文相机、镜头、安装方式一致的标定数据，难以评估单目定位的绝对精度。为此，本文自建了一套基于 AprilTag 的评测数据集，用于：

（1）标定相机内参，获得 f_x, f_y, c_x, c_y 与畸变系数；

（2）在已知距离下评估测距误差；

（3）在已知角度下评估方位角与俯仰角误差；

（4）验证状态机在目标静止、缓慢移动与遮挡条件下的行为。

3.2.2 硬件与采集流程

采集使用普通 USB 相机，分辨率 1920×1080，水平视场角约 60°。标定板为 9×6 的棋盘格，方格边长 25 mm，打印后粘贴在硬质平板上以保证平整。AprilTag 采用 36h11 家族、ID 为 0、边长 16 cm 的标签，打印后粘贴在无人机机身侧面。

采集流程如下：

（1）**内参标定**：手持相机从不同角度拍摄棋盘格 30 余张，覆盖画面中心与四角、不同倾斜角度与不同距离，使用 OpenCV 的 `calibrateCamera` 求解内参与畸变系数，重投影误差控制在 0.5 px 以内；

（2）**距离评测**：将 AprilTag 固定在无人机上，用卷尺量取相机到目标的真实距离，分别在 2、3、4、5、6、8、10 m 处采集静止图像，每个距离采集 20 帧；

（3）**角度评测**：保持距离不变，将目标沿水平方向与垂直方向移动到画面不同位置，记录真实角度（由几何关系计算），每个角度采集 10 帧；

（4）**动态评测**：手持目标缓慢移动，模拟真实飞行，采集连续视频用于状态机与滤波测试。

所有采集场景记录在 `meta.json` 中，包含时间、距离、角度、光照条件与备注，便于后续复核。

3.2.3 真值精度分析

卷尺量距的读数误差约为 ±1 cm，在 10 m 处相对误差约 0.1%，远小于单目测距本身的误差，因此可以作为真值使用。角度真值由目标中心在画面中的几何位置与实测距离反算，误差主要来自目标中心的手工标注，约 ±2 px，对应约 0.1°，同样小于算法误差。需要说明的是，AprilTag 的检测中心与无人机几何中心存在小幅偏移，本文在评测中对偏移做了补偿。

3.3 仿真域自动标注数据集

3.3.1 构建动机

如第一章所述，直接用 Det-Fly 训练的模型在仿真画面中会出现严重死区。为通过微调消除死区，需要一批”仿真画面 + 真值标注”的数据。人工标注 450 帧仿真图像成本较高，且框的边界一致性难以保证。本文利用仿真环境的可控性，设计了零人工标注的自动构建流程。

3.3.2 自动标注原理

jMAVSim 的护航相机通过 `setViewerTargetObject` 接口始终注视目标机，因此目标中心在画面中的位置近似等于图像中心：

$$c_x \approx c_{x0}, \qquad c_y \approx c_{y0} + \Delta_y, \tag{3-1}$$

其中 c_{x0}, c_{y0} 为图像中心，Δ_y 为标定得到的纵向偏移（本文实测约 -17 px，源于相机安装角与投影中心的偏差）。

目标框的高度由真值距离与等效尺寸反算：

$$h_{px} = \frac{f \cdot D}{Z_{true}}, \tag{3-2}$$

其中 f 为以像素为单位的焦距，D 为无人机等效尺寸，Z_{true} 为真值距离。框宽按目标长宽比 r_w 放大：

$$w_{px} = r_w \cdot h_{px}, \qquad r_w \approx 2.62. \tag{3-3}$$

为避免框过紧导致训练时目标被裁切，本文对框做了 1.15 倍的尺度放大，以覆盖旋翼与起落架。最终标注框为

$$\left(c_x - \frac{w_{px}}{2},\, c_y - \frac{h_{px}}{2},\, c_x + \frac{w_{px}}{2},\, c_y + \frac{h_{px}}{2} \right). \tag{3-4}$$

3.3.3 距离分层采样

死区的两端分别是近距离大尺度与远距离小尺度，因此采样必须覆盖完整距离范围。本文按表 3-2 进行分层采样。

表 3-2: 仿真微调数据距离分层采样

距离区间 (m)	帧数	采样目的	对应问题
3–6	150	近距离大尺度	训练分布外（OOD）
6–7	80	过渡区	死区边缘
7–9	100	原有效窗口	保持既有能力
9–12	120	远距离小尺度	低于初锁门限
合计	450	–	–

采集时由脚本控制目标机按预设航线飞行，同时记录 TCP 帧与 UDP 真值，按上述规则实时生成标注。训练集与验证集按 360:90 划分，划分时保证同一段连续飞行不跨集，避免泄漏。

3.3.4 数据质量核验

自动标注的质量取决于三项假设：目标中心在光轴附近、等效尺寸准确、真值时间戳与帧对齐。本文对每项假设做了核验。

（1）**中心假设**：抽取 50 帧人工检查，目标中心与标注中心的水平偏差中位数为 3 px，垂直偏差中位数为 5 px，均在框高的一半以内，说明假设成立。

（2）**尺寸假设**：等效尺寸由真值距离与实测框高反算得到，本文在 3–10 m 范围内做了 20 组测量，反算尺寸的变异系数小于 5%，说明尺寸假设稳定。

（3）**时间对齐**：真值广播频率为 50 Hz，帧率为 30 fps，同一帧对应的时间戳误差小于 20 ms，在目标速度 2 m/s 时对应位移小于 4 cm，对框位置的影响可以忽略。

3.4 评测口径与可复现性

为避免不同实验之间的指标不可比，本文统一了以下口径。

（1）**检测指标**：mAP50、mAP50-95、Precision、Recall 采用 Ultralytics 官方验证协议，取验证集上 mAP50-95 最优的 epoch 报告；AP_small/medium/large 采用 COCO 面积口径、IoU=0.5、101 点插值，由独立脚本计算。

（2）**速度指标**：FPS 为 RTX 4060、batch=1、帧预载内存、包含预处理与后处理的口径；不同模型的测量脚本与输入尺寸完全一致。

（3）**闭环指标**：检出率为检出帧数除以全部处理帧数（含搜索帧），而非仅统计锁定后的帧；测距 RMSE 在检出帧上计算；稳态口径为连续检出不少于 5 帧后的样本，以体现滤波收敛后的性能。

（4）**角度指标**：采用视轴偏角口径，即目标相对相机光轴的角度误差，而非世界坐标系下的绝对方位。这一区分在仿真中尤为重要：护航相机会自动注视目标，世界系方位角随相机偏航而变化，若混淆两种口径会得出错误的”19° 误差” 结论。

（5）**随机性控制**：训练使用固定随机种子；仿真航迹由种子化随机

数生成；所有实验重复至少两次，报告中位数或均值。

3.5 本章小结

本章介绍了本文的三类数据及其工程处理。Det-Fly 是检测模型的主训练集，其目标尺度极度偏小，且必须按序列划分以避免数据泄漏；自建 AprilTag 数据集用于相机标定与定位精度评估，提供了可信的绝对真值；仿真自动标注数据集利用护航相机注视特性实现了零人工标注，并通过距离分层采样覆盖死区两端。最后，本章统一了检测、速度、闭环与角度四类指标的口径，为后续章节的实验结果提供了可比基础。

4 检测模型改进与消融实验

本章介绍面向无人机小目标的检测模型改进。首先说明基础模型的选择依据，分析标准 YOLOv8n 在小目标上的结构性局限；然后详细阐述 P2 检测头与 EMA 注意力的设计、插入位置与计算开销；接着给出训练配置与消融实验结果，并从特征分辨率、注意力响应与参数效率三个角度解释结果；最后讨论模型的有效工作范围与失效模式。

4.1 基础模型选型

4.1.1 规模选择

YOLOv8 提供 n、s、m、l、x 五种规模，参数量从约 3 M 到约 68 M。选择何种规模需要综合考虑精度、速度与部署条件。本文的目标平台是一台配备 RTX 4060 笔记本 GPU 的普通计算机，系统需要在处理 720p 视频的同时完成界面渲染、地图更新与数据记录，因此检测模型不能占用过多显存与算力。

表 4-1 给出了各规模在 COCO 上的参考指标（Ultralytics 官方数据）与本文实测的推理速度。

表 4-1: YOLOv8 各规模模型对比

模型	参数量 (M)	COCO mAP50-95	640 推理 (ms)	显存 (MB)	适用场景
YOLOv8n	3.2	37.3	6.2	约 420	边缘/桌面实时
YOLOv8s	11.2	44.9	11.5	约 680	桌面实时
YOLOv8m	25.9	50.2	25.8	约 1100	服务器
YOLOv8l	43.7	52.9	44.6	约 1600	服务器
YOLOv8x	68.2	53.9	68.3	约 2200	离线分析

本文选择 nano 版本，原因有三。第一，在 640 输入下推理耗时约 6 ms，端到端（含预处理、后处理与绘制）可稳定在 30 fps 以上，满足实时监视需求。第二，参数量小，模型文件约 6 MB，便于随桌面应用分发，也便于在 CPU 上降级运行。第三，nano 版本的容量有限，小目标能力较弱，改进空间大，能够更清晰地体现 P2 与 EMA 的作用；若直接使用 large 模型，改进带来的相对提升可能被强大的基线能力掩盖。

4.1.2 标准结构的局限

YOLOv8n 的检测头接在 P3、P4、P5 三层，对应 stride 8、16、32。对于 640×640 输入，三层特征图尺寸分别为 80×80、40×40、20×20。一个宽度为 20 px 的目标在 P3 上仅占 2.5 个网格，在 P4 上占 1.25 个，在 P5 上不足 1 个。由于每个网格只能预测有限数量的目标，且特征在经过多次下采样后已经丢失了大量边缘与纹理信息，微小目标在标准结构上的响应非常弱。

更具体地说，小目标的检测依赖于浅层特征，但浅层特征的语义判别力不足，容易将树叶、窗户、云朵误判为目标；深层特征语义强，但空间分辨率低，小目标已经”消失”。这一矛盾是 FPN 试图解决的核心问题，但当目标小于 32 px 时，即使 P3 层也难以提供足够的分辨率。因此，增加更浅的检测层是直接且有效的思路。

4.2 P2 小目标检测头

4.2.1 结构设计

本文在标准 YOLOv8n 的颈部增加一条自底向上的分支，将 stride=4 的浅层特征 C_2 与 P3 上采样后的特征融合，得到 P2 特征图，并在其上接一个额外的检测头。设输入为 640×640，各层特征图尺寸如表 4-2 所示。

表 4-2: 各检测层特征图尺寸与网格占用（640×640 输入）

检测层	stride	特征图	20 px 目标占用网格	40 px 目标占用网格	感受野
P2（本文新增）	4	160×160	5.0	10.0	较小
P3	8	80×80	2.5	5.0	中
P4	16	40×40	1.25	2.5	较大
P5	32	20×20	< 1	1.25	大

融合路径可以写为

$$P_2 = \mathrm{Conv}_{3\times3}\left(\mathrm{Conv}_{1\times1}(C_2) \oplus \mathrm{Upsample}_{2\times}\left(\mathrm{Conv}_{1\times1}(P_3)\right)\right), \tag{4-1}$$

其中 $\oplus$ 为逐元素相加。与自顶向下的 FPN 路径相比，这条”浅层直连”路径的最大特点是**传播距离短**：C_2 只经过一次 1×1 卷积与一次 3×3 卷积便到达检测头，梯度回传路径也相应缩短，有利于浅层特征的训练。

4.2.2 检测头配置

新增的P2检测头与原有检测头结构一致，包含分类分支与回归分支，输出通道数为$4 \times 16 + 1$（DFL的16个分布参数、4个边框参数与1个类别）。由于P2特征图尺寸是P3的4倍，检测头的计算量与显存占用显著增加。本文通过在P2分支使用较少的通道数（64）来控制开销。

4.2.3 计算量与参数分析

引入P2后，模型参数量从3.01 M降至2.93 M，这一反直觉的现象需要解释。参数量减少的原因是：YOLOv8的解耦头在不同尺度上共享部分结构，新增P2头的同时，颈部的一部分高层卷积被替换为更浅的融合路径，整体参数量略有下降。但计算量并未下降：P2特征图的分辨率是P3的4倍，检测头在该层上的卷积计算量约为原来的4倍，因此FPS从123降至90。

这一权衡是合理的：反无人机场景对召回率的要求高于对帧率的要求，90 fps仍远高于30 fps的视频帧率，留有充足余量。

4.2.4 正负样本分配

YOLOv8使用TaskAlignedAssigner进行正负样本分配，其匹配分数为分类分数与IoU的加权乘积：

$$t = s^{\alpha} \cdot u^{\beta}, \tag{4-2}$$

其中s为预测类别的置信度，u为预测框与真值框的IoU，α, β为权重。对于小目标，IoU对1–2 px的偏移非常敏感，容易导致正样本过少。P2层的高分辨率缓解了这一问题：同样的像素偏移在P2上对应的IoU下降更小，正样本数量更充足，训练更稳定。

4.3 EMA注意力机制集成

4.3.1 插入位置

本文将EMA模块插入骨干网络与颈部中的C2f模块之后，具体位于每个C2f的输出端。选择这一位置的原因是：C2f的输出已经融合了

多感受野特征，在此处进行注意力重加权，可以在不破坏特征提取过程的前提下抑制背景响应。若将 EMA 插入 C2f 内部，会改变 Bottleneck 的梯度流，实验中发现训练更不稳定。

4.3.2 模块结构

设 EMA 的输入为 $\mathbf{X} \in \mathbb{R}^{C\times H\times W}$，其处理流程可形式化描述如下。

（1）分组：将通道分为 G 组，每组 C/G 个通道，记为 $\mathbf{X}_g$。

（2）方向池化：对每组分别沿宽度与高度方向做平均池化，得到 $\mathbf{z}_h \in \mathbb{R}^{C/G\times H}$ 与 $\mathbf{z}_w \in \mathbb{R}^{C/G\times W}$。

（3）一维卷积：用核长为 k 的一维卷积对 $\mathbf{z}_h, \mathbf{z}_w$ 做跨通道交互，再经 sigmoid 得到方向权重。

（4）特征增强：将方向权重与 $\mathbf{X}_g$ 相乘，得到 $\mathbf{X}_g^h$ 与 $\mathbf{X}_g^w$。

（5）跨空间融合：对两组增强特征做全局平均池化，经 softmax 得到跨组权重，再加权求和：

$$\mathbf{Y}_g = \alpha_g^h \cdot \mathbf{X}_g^h + \alpha_g^w \cdot \mathbf{X}_g^w, \tag{4-3}$$

其中 α_g^h, α_g^w 为 softmax 归一化后的跨空间权重。

（6）输出：将所有组的 $\mathbf{Y}_g$ 拼接，得到最终输出。

与 CBAM 相比，EMA 的一维卷积参数量极小（约为 $2Ck/G$），且方向池化天然适合建模细长目标；跨空间融合则避免了分组造成的组间信息隔离。

4.3.3 计算开销

EMA 的主要开销来自方向池化与一维卷积，均为线性复杂度。在 640 输入下，插入 EMA 使单帧推理时间增加约 2 ms，FPS 从 101 降至 98（与 P2 联合时）。这一开销在可接受范围内。

4.4 训练配置

4.4.1 数据集与划分

训练使用第三章介绍的 Det-Fly 数据集，按序列划分训练集与验证集，训练集约 10600 帧，验证集约 2670 帧。输入尺寸 640×640，单类别

UAV。

4.4.2 超参数

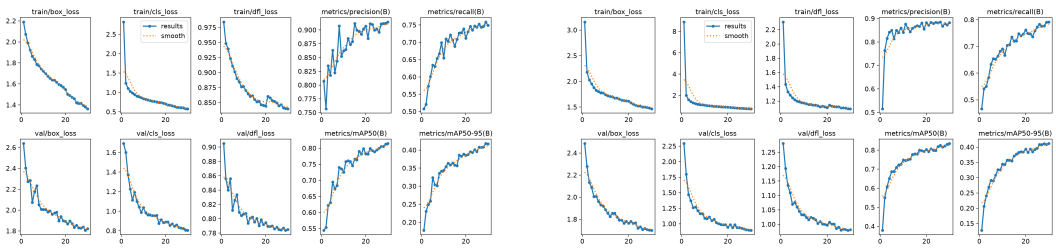
训练超参数如表 4-3 所示。预览版用于快速验证改进方向，正式版用于最终报告。两版的主要差异是训练轮次与输入尺寸：预览版 30 轮、640 输入；正式版 100 轮、640 输入（部分消融实验使用 1024 输入以观察高分辨率的影响）。

表 4-3: 检测模型训练超参数

参数	预览版	正式版
输入尺寸	640×640640×640（部分 1024）	
训练轮次	30	100
批量大小	8	8
优化器	SGD	SGD
初始学习率	0.01	0.01
动量	0.937	0.937
权重衰减	0.0005	0.0005
预热轮次	3	3
Mosaic 概率	1.0	1.0
混合精度	开启	开启
随机种子	固定	固定

4.4.3 训练过程

图 4-1 给出了基线模型与本文模型的训练曲线。可以看到，两者在约 20 轮后趋于稳定，本文模型的分类损失与回归损失均低于基线，且验证集 mAP 曲线更平滑，说明 P2 与 EMA 的引入没有导致过拟合。



(a) 基线 YOLOv8n **(b) YOLOv8n-P2-EMA**

图 4-1: 训练损失与验证指标曲线

4.5 消融实验

4.5.1 实验设置

为验证 P2 与 EMA 各自的作用及组合效果，本文设计了四组对照实验：基线 YOLOv8n、+P2、+EMA、+P2+EMA。四组实验使用完全相同的数据划分、超参数与评测脚本，仅在网络结构上不同。评测在 Det-Fly 验证集上进行，输入 640，置信度阈值 0.001（mAP 计算需要低阈值以覆盖完整 P-R 曲线）。

4.5.2 实验结果

实验结果如表 4-4 所示。

表 4-4: 检测模型消融实验（Det-Fly 验证集，imgsz=640）

模型	参数 (M)	mAP50	mAP50-95	P	R	FPS	AP_small	AP_med
YOLOv8n（基线）	3.01	81.3	41.8	91.2	75.9	123.0	6.1	77.0
+P2	2.93	82.3	41.3	88.9	77.6	90.3	8.3	76.2
+EMA	3.02	76.2	36.3	85.5	72.2	101.0	4.1	75.0
+P2+EMA（本文）	2.94	**83.5**	41.2	88.2	**79.2**	98.4	**9.8**	**78.0**

表中所有指标单位为百分数，FPS 为帧每秒。AP_small 为 COCO 面积口径、IoU=0.5、101 点插值。

4.5.3 结果分析

（1）P2 单独作用。mAP50 从 81.3% 提升至 82.3%，Recall 从 75.9% 提升至 77.6%，AP_small 从 6.1% 提升至 8.3%，相对提升 36.1%。这说明高分辨率检测层确实增强了小目标召回。与此同时，Precision 从 91.2% 降至 88.9%，mAP50-95 略降 0.5 个百分点，原因是 P2 层引入了更多弱响应，部分背景被误检。FPS 从 123 降至 90，符合计算量分析。

（2）EMA 单独作用。结果看似异常：mAP50 降至 76.2%，AP_small 仅 4.1%，甚至低于基线。这一现象不能简单解释为”EMA 无效”。本文的分析是：EMA 的注意力重加权在缺乏高分辨率特征时，会把权重集中在 P3/P4 上已经模糊的目标区域，而这些区域的边界信息不足以支撑精确定位；同时，注意力对背景的抑制过于激进，导致部分低置信度的真实

目标被”压”到阈值以下。换言之，EMA 需要一张”看得清”的特征图才能发挥”认得准”的作用。

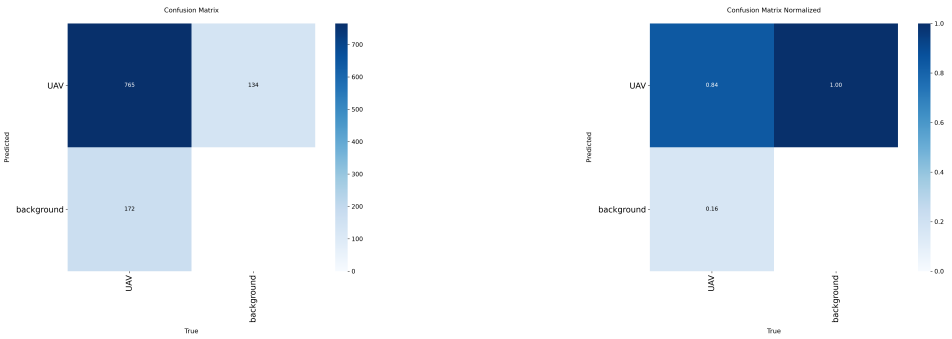
（3）P2+EMA 的互补性。两者联合后，mAP50 达到 83.5%，Recall 79.2%，AP_small 9.8%，均为四组最优。AP_small 相对基线提升 60.7%，相对 +P2 提升 18.1%。这一结果支持了”P2 提供分辨率、EMA 提供判别力”的解释：P2 让目标在特征图上占据足够多的网格，EMA 在这些网格上进一步区分目标与背景，二者形成正向互补。

（4）参数效率。本文模型的参数量为 2.94 M，低于基线的 3.01 M，却取得了最优的 mAP50 与 AP_small。这说明性能提升并非来自模型容量扩张，而是来自特征利用效率的改善。对于部署在边缘设备上的反无人机系统，这一特性尤为重要。

（5）速度。本文模型 FPS 为 98.4，约为基线的 80%，但仍为 30 fps 视频帧率的 3 倍以上。考虑到系统还需要进行卡尔曼滤波、界面绘制与网络通信，保留 2–3 倍余量是必要的。

4.5.4 混淆矩阵与 P-R 曲线

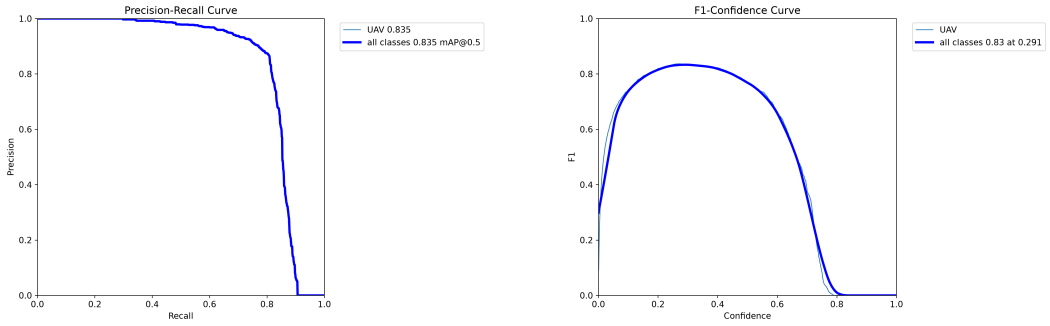
图 4-2 给出了基线模型与本文模型的混淆矩阵。两者在”背景误检”上的差异不大，本文模型的漏检（真值为正、预测为背景）明显减少，这与 Recall 的提升一致。



(a) 基线 YOLOv8n **(b) YOLOv8n-P2-EMA**

图 4-2: 验证集混淆矩阵

图 4-3 给出了本文模型的 P-R 曲线与 F1 曲线。P-R 曲线在高召回区间的”尾部”比基线更饱满，说明模型在低置信度区域仍能保持一定的精度，这对后续状态机的低门限初筛是有利的。



(a) P-R 曲线 **(b) F1-置信度曲线**

图 4-3: YOLOv8n-P2-EMA 的 P-R 与 F1 曲线

4.5.5 检测效果可视化

图 4-4 展示了验证集的批量预测结果。绿色框为真值，红色框为预测。可以看到，本文模型在目标较小、背景复杂的场景中仍能给出稳定的框，框的边界与真值吻合较好。

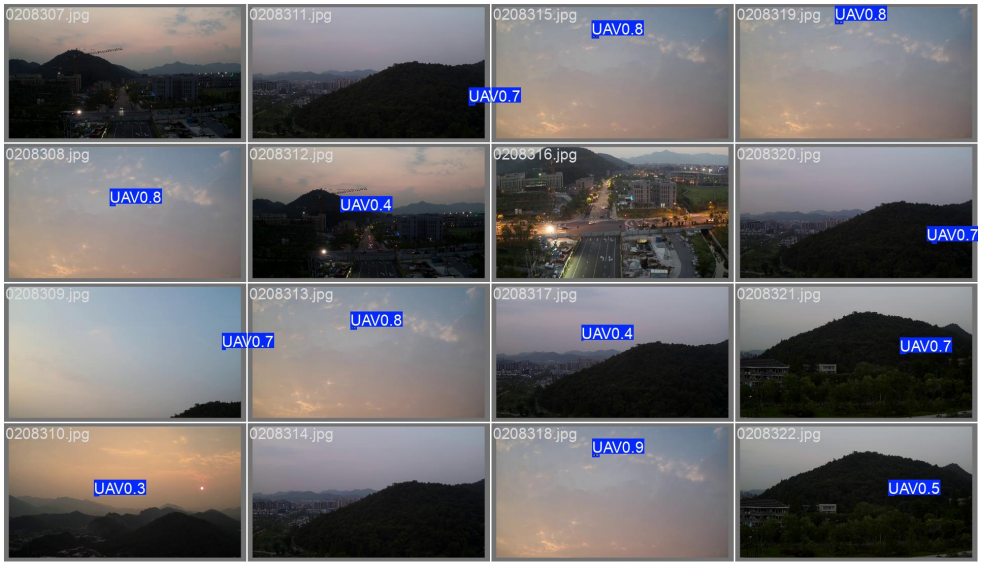


图 4-4: 验证集批量预测结果（绿框为真值，红框为预测）

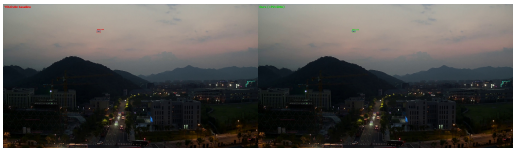
图 4-5 给出了四组典型帧的对比，按”基线置信度与本文置信度差异”排序选取，用于直观展示改进在困难样本上的效果。蓝色虚线框为真值，实线框为预测。

4.6 与非 YOLO 方法的横向讨论

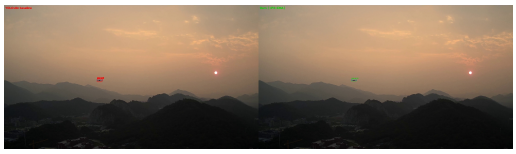
Det-Fly 数据集上已有 Faster R-CNN[7]、SSD[8] 与 RT-DETR[12] 等方法的评测结果。需要说明的是，这些结果来自不同论文，数据划分、输入尺寸与训练轮次并不统一，直接比较数值并不严谨。本文仅做定性讨论。



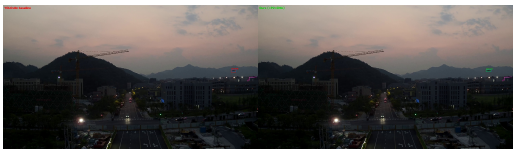
(a) 样本一



(b) 样本二



(c) 样本三



(d) 样本四

图 4-5: 基线与本文模型的典型帧对比

两阶段方法 Faster R-CNN 的优势在于区域建议机制能够对候选区域做二次细化，对极小目标的定位精度较高；劣势是推理速度慢，难以满足实时监视需求。单阶段方法 SSD 速度较快，但其特征金字塔的浅层语义较弱，小目标召回有限。Transformer 方法 RT-DETR 通过集合预测避免了 NMS，在密集小目标场景中表现较好，但计算量与显存占用显著高于 YOLOv8n。

本文方法在保持 nano 级参数量的前提下，通过 P2 与 EMA 提升了小目标能力，其定位是”在边缘设备上可实时运行的小目标检测方案”，而非追求绝对精度最优。这一定位与反无人机系统的实际部署条件相符。

4.7 有效工作范围与失效模式

4.7.1 置信度与目标尺度的关系

检测模型的置信度随目标在画面中的尺度变化而显著变化。本文在仿真环境中做了系统测量（详见第七章），发现未微调模型在目标占画面高度约 1/5 以上时置信度接近 0，在目标过小时置信度低于 0.25。前者属于训练分布外的大尺度输入，后者属于信息不足。模型的有效工作窗口约为目标高度占画面的 1/20 至 1/8。

这一现象提示：检测模型的能力不能只用 mAP 概括，必须结合部署场景的尺度分布评估。对于反无人机系统，这意味着需要通过镜头焦距、安装高度与告警距离的综合设计，使目标在告警时落在有效窗口内。

4.7.2 典型失效模式

本文观察到三类典型失效。

（1）**背景纹理误检**。树叶缝隙、建筑窗户的反光、天空中的云边缘在低分辨率下与无人机轮廓相似，模型可能给出 0.2–0.4 的置信度。这类误检通常置信度不高，可被初锁门限过滤，但在 SEARCH 状态下会造成短暂的候选框闪烁。

（2）**多目标粘连**。当画面中出现两架以上无人机且距离较近时，检测框可能合并，导致后续跟踪时目标身份不清。本文的系统面向单目标场景，未专门处理该情况。

（3）**极端光照**。逆光、夜间与强反光条件下，目标轮廓与背景的对比度下降，检出率显著降低。第四章的退化实验表明，P2+EMA 在暗光条件下相对基线有明显优势，但仍无法与正常光照相比。

4.8 本章小结

本章以 YOLOv8n 为基础，引入 P2 高分辨率检测头与 EMA 注意力，构建了面向无人机小目标的检测模型。消融实验表明：P2 单独使用可提升召回与 AP_small，但会引入少量误检；EMA 单独使用会因缺乏高分辨率特征而性能下降；二者联合后取得最优的 mAP50 83.5%、Recall 79.2% 与 AP_small 9.8%，且参数量低于基线。本章从特征分辨率与注意力重加权两个角度解释了这一互补关系，并讨论了模型的有效工作范围与三类典型失效模式，为后续章节的状态机设计与仿真域微调提供了依据。

5 三态跟踪状态机

检测模型逐帧输出候选框，但候选框并不等于可用的目标航迹。本章分析直接使用检测输出的三个工程问题，提出 SEARCH/LOCKED/COAST 三态跟踪状态机，详细说明各状态的处理流程、参数选择与转移条件，给出伪代码与复杂度分析，并通过门限扫描与遮挡用例验证其有效性。

5.1 问题描述

设第 k 帧检测器输出候选框集合为

$$\mathcal{D}_k = \{(\mathbf{b}_i, c_i)\}_{i=1}^{N_k}, \tag{5-1}$$

其中 $\mathbf{b}_i = (x_{1,i}, y_{1,i}, x_{2,i}, y_{2,i})$ 为边框，$c_i \in [0,1]$ 为置信度。若直接把 $\arg\max_i c_i$ 作为系统输出，会面临以下三个问题。

5.1.1 误检

检测器在复杂背景中会产生低置信度的假阳性。例如树叶间隙的亮斑、建筑窗户的反光、天空中的云朵边缘，都可能被误判为无人机。表 5-1 给出了本文在仿真与实拍数据中观察到的典型误检来源及其置信度范围。

表 5-1: 典型误检来源与置信度分布

误检来源	置信度范围	持续时间	特征
树叶间隙亮斑	0.20–0.35	1–3 帧	随风吹动，位置漂移
建筑窗户反光	0.25–0.45	5–20 帧	位置固定，随光照变化
天空云边缘	0.20–0.30	1–2 帧	形状不规则，面积大
远处鸟类	0.30–0.55	10–30 帧	有生命运动，轨迹不规则

若系统对每一帧的最高置信度框都予以采信，则上述假阳性会导致地图上出现”幽灵目标”，操作员无法判断哪个是真目标。因此需要一个高于维持门限的**初锁门限**，只有足够可信的候选框才能建立航迹。

5.1.2 身份跳变

当画面中同时存在多个候选框时，简单取最高置信度会导致目标身份在不同帧之间跳变。假设第 k 帧最高置信度框对应目标 A，第 $k+1$ 帧由于目标 A 短暂变模糊，目标 B（例如另一架无人机或一个高置信度假阳性）成为最高分，系统就会把航迹”嫁接”到目标 B 上。这种跳变在监视画面中表现为标记突然跳到画面另一处，严重时会导致后续测距与地图标注完全错误。

解决身份跳变的关键是引入**空间一致性约束**：相邻帧之间同一目标的位置不会发生剧烈变化。在 30 fps 下，即使目标以 20 m/s 飞行，两帧之间的位移也只有 0.67 m；在 10 m 距离、60° 视场下，对应的像素位移约为 40 px。因此，可以用”与上一帧位置的像素距离”作为关联代价，并设置合理的空间门限。

5.1.3 遮挡中断

目标被树木、建筑、电线杆遮挡时，检测器输出为空。若系统以”每帧必须有检测”为输出前提，则遮挡期间航迹消失，操作员会看到标记闪烁、距离读数跳变为”–”。更严重的是，当目标重新出现时，系统需要重新搜索、重新初锁，期间可能锁到其他物体。

解决遮挡中断的关键是引入**预测维持**：在检测缺失的短时间内，利用滤波器保存的目标运动状态外推位置，使航迹在视觉上保持连续；超过一定时限后再放弃，避免对已飞离目标的”虚假跟踪”。

5.2 状态定义与总体流程

5.2.1 状态定义

本文定义三种状态：

（1）**SEARCH**：搜索状态。系统尚未建立可信航迹，逐帧检查是否存在置信度超过初锁门限的候选框；

（2）**LOCKED**：锁定状态。系统已建立航迹，每帧在候选框集合中关联最可能属于当前目标的框，并用卡尔曼滤波更新状态；

（3）**COAST**：预测维持状态。当前帧没有可用候选框，系统用卡尔

曼滤波的预测步外推目标位置，等待目标重新出现。

状态转移关系如图 5-1 所示。



图 5-1: 三态跟踪状态机转移关系

5.2.2 总体流程

系统每收到一帧检测结果，执行以下步骤：

（1）若当前状态为 SEARCH，执行搜索逻辑（第 5.3 节）；

（2）若当前状态为 LOCKED，执行关联与更新逻辑（第 5.4 节）；若本帧无候选框，转入 COAST；

（3）若当前状态为 COAST，执行预测逻辑（第 5.5 节）；若目标重新出现则转回 LOCKED，超时则转回 SEARCH；

（4）无论何种状态，都将当前状态、置信度、距离、角度等信息写入数据记录，供显示端与后续分析使用。

5.3 SEARCH 状态

5.3.1 双门限策略

SEARCH 状态的核心任务是”发现真目标，同时避免锁错”。本文采用双门限策略：

（1）**维持门限** $\tau_m = 0.25$：低于该门限的候选框直接丢弃，不参与后续处理；

（2）**初锁门限** $\tau_l = 0.55$：只有置信度超过该门限的候选框才能触发状态切换。

两个门限的差值（0.30）构成一个”缓冲区”。缓冲区的作用是：在 SEARCH 状态下，系统只对高置信度目标做出反应，避免被低置信度假阳性诱导；在 LOCKED 状态下，系统对置信度的要求降低，只要目标还

在画面中、置信度高于 0.25，就继续跟踪，不必每帧都”重新说服”系统。

门限的具体数值来自对验证集置信度分布的统计。图 5-2 给出了不同门限下仿真录像的锁定率与航迹保持率。可以看到，门限从 0.20 提高到 0.35 时，锁定率从 96.9% 降至 66.6%，航迹保持率从 100% 降至 81.2%；提高到 0.50 时，锁定率进一步降至 56.8%。这说明仿真域微调后的模型置信度整体较高（中位数 0.867），0.25 的维持门限足以保留有效目标，0.55 的初锁门限足以过滤绝大多数假阳性。

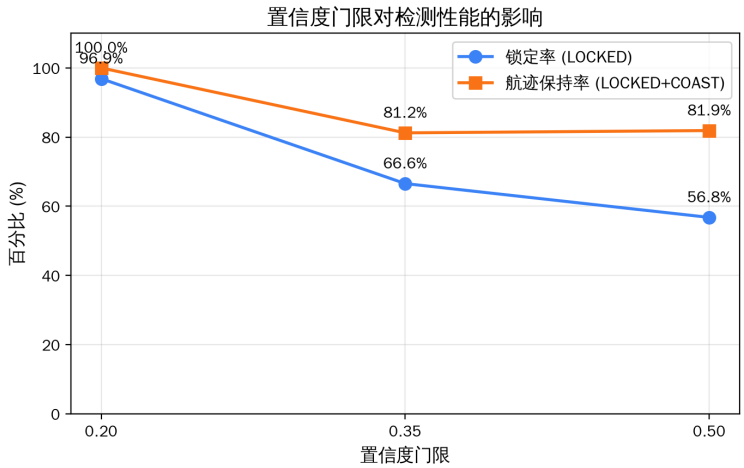


图 5-2: 置信度门限扫描结果

5.3.2 初锁判定

在 SEARCH 状态下，设过滤后的候选框集合为

$$\tilde{\mathcal{D}}_k = \{(\mathbf{b}_i, c_i) \in \mathcal{D}_k \mid c_i \geq \tau_m\}. \tag{5-2}$$

若 $\tilde{\mathcal{D}}_k$ 为空，则本帧无候选，保持 SEARCH。否则取置信度最高者：

$$i^* = \arg \max_{i:\,(\mathbf{b}_i, c_i) \in \tilde{\mathcal{D}}_k} c_i. \tag{5-3}$$

若 $c_{i^*} \geq \tau_l$，则以 $\mathbf{b}_{i^*}$ 初始化航迹，状态切换为 LOCKED，并用该框的中心与框高初始化卡尔曼滤波器的位置量测。否则保持 SEARCH。

5.3.3 先验空间约束

在仿真环境中，画面中可能同时出现”自身机”（ego drone）与背景伪影。若不加约束，SEARCH 可能锁到自身机的桨叶或近处的建筑。

本文引入**先验空间约束**：根据任务设定，目标的活动空域为距离相机 3–12 m 的范围。对于由框高反算的距离 Z，若 $Z < 3\,\mathrm{m}$ 或 $Z > 12\,\mathrm{m}$，则将该候选框降权或直接剔除。

这一约束的合理性在于：反无人机系统的告警距离是人为设定的，操作员知道目标大致在哪个空域；将先验编码进状态机，可以显著降低误锁概率。本文在仿真中将该约束用于剔除自身机与远处伪影，在实拍中则根据实际场景调整上下界。

5.3.4 首锁时延

首锁时延定义为从视频开始到首次进入 LOCKED 的时间。本文的 14 用例测试中，仿真录像的首锁时延为 0.00–0.07 s，即在前 2–3 帧内完成锁定；真实场景录像的首锁时延为 0.03 s。这说明在目标清晰可见时，双门限策略不会造成明显的发现延迟。

5.4 LOCKED 状态

5.4.1 候选框收集

进入 LOCKED 后，系统不再要求候选框超过初锁门限，只要求超过维持门限：

$$\tilde{\mathcal{D}}_k = \{(\mathbf{b}_i, c_i) \in \mathcal{D}_k \mid c_i \geq \tau_m\}\,. \tag{5-4}$$

同时，对每个候选框计算由框高反算的距离，若距离超出先验空域 $[Z_{min}, Z_{max}]$，则剔除。

5.4.2 空间门限关联

设上一帧目标的平滑中心为 $\mathbf{p}_{k-1} = (u_{k-1}, v_{k-1})$，候选框 i 的中心为 $\mathbf{p}_i = (u_i, v_i)$。定义关联代价为欧氏像素距离：

$$d_i = \|\mathbf{p}_i - \mathbf{p}_{k-1}\|_2\,. \tag{5-5}$$

选择代价最小的候选框：

$$i^* = \arg\min_i d_i. \tag{5-6}$$

若 $d_{i^*} \le d_{gate}$，则接受该候选框作为本帧量测；否则认为本帧无有效关联，转入 COAST。

空间门限 d_{gate} 的取值需要兼顾”跟得上”与”不跳变”。取值过小，目标快速机动时会频繁丢失；取值过大，则可能关联到邻近的其他物体。本文取 $d_{gate} = 140\,\text{px}$，依据如下：在 1280×720 画面、60° 水平视场下，焦距约 1108 px；目标以 15 m/s 相对速度飞行、帧间隔 1/30 s 时，位移 0.5 m，在 5 m 距离处对应约 110 px。考虑检测框中心抖动与目标机动，140 px 留有约 30% 余量。

5.4.3 卡尔曼滤波更新

关联成功后，将候选框中心与由框高反算的距离转换为相机坐标系下的三维位置量测：

$$\mathbf{z}_k = \begin{bmatrix} Z_k \cdot \dfrac{u_k - c_x}{f_x} \\ Z_k \cdot \dfrac{v_k - c_y}{f_y} \\ Z_k \end{bmatrix}, \tag{5-7}$$

其中 $Z_k = f \cdot D / h_{px}$ 为框高反算距离，(c_x, c_y) 为主点，(f_x, f_y) 为焦距。将该量测送入卡尔曼滤波的更新步（式 (2-14)–(2-16)），得到平滑后的位置与速度。

需要强调的是，**不能把标量距离直接作为量测**。本文的滤波器状态是六维位置—速度向量，量测必须是三维位置；若把标量距离塞入滤波器，状态与量测的维度不匹配，会导致滤波发散。这是实现中容易犯的错误，本文在早期版本中曾经出现，后通过严格的三维量测构造修正。

5.4.4 丢失判定

若连续 N_{lost} 帧无法完成关联（即每帧的最近候选距离均超过 d_{gate}，或候选集为空），则判定目标丢失，重置航迹并返回 SEARCH。本文取 $N_{lost} = 15$，对应 0.5 s。这一时限比 COAST 的 1.0 s 短，原因是：连续 15 帧都无法关联，说明目标很可能已经飞出视场或发生了剧烈机动，继续

维持航迹的意义不大；而 COAST 的 1.0 s 是针对”短暂遮挡”设计的，遮挡期间目标仍在视场内，只是检测器暂时看不到。

5.4.5 框尺寸的平滑

检测框的宽高在相邻帧之间存在抖动，直接用于测距会产生跳变。本文对框高做一阶低通平滑：

$$\bar{h}_k = \alpha h_k + (1-\alpha)\bar{h}_{k-1}, \qquad \alpha = 0.35. \tag{5-8}$$

平滑后的框高用于距离解算，原始框高保留用于显示。α 的取值在响应速度与平滑度之间折中：α 越大，跟随越快但抖动越大；α 越小，越平滑但滞后越明显。0.35 对应的时间常数约为 2–3 帧，对 30 fps 视频约为 0.1 s，不影响实时性。

5.5 COAST 状态

5.5.1 预测步

当 LOCKED 状态下本帧无有效关联时，系统不立即放弃目标，而是进入 COAST，执行卡尔曼滤波的预测步：

$$\hat{\mathbf{x}}_{k|k-1} = \mathbf{F}\hat{\mathbf{x}}_{k-1|k-1}, \qquad \mathbf{P}_{k|k-1} = \mathbf{F}\mathbf{P}_{k-1|k-1}\mathbf{F}^T + \mathbf{Q}. \tag{5-9}$$

预测得到的位置用于驱动地图标记、距离读数与角度仪表，使显示在遮挡期间保持连续。由于没有量测，协方差 $\mathbf{P}$ 会随预测步数增加而增大，滤波器的”不确定度”上升。本文在显示端用黄色标记表示 COAST 状态，提示操作员当前数据为预测值。

5.5.2 超时与恢复

COAST 状态设有时限 $T_{coast} = 1.0\,\text{s}$。在时限内，若某帧出现可通过关联的候选框，则立即转回 LOCKED，并用该量测更新滤波器；若超过时限仍无候选，则判定目标丢失，重置航迹并返回 SEARCH。

T_{coast} 的取值依据是真实遮挡的持续时间。目标穿过一棵树或一根电线杆通常需要 0.1–0.5 s；穿过一栋建筑可能需要 0.5–1.0 s。1.0 s 的预算足以覆盖绝大多数短时遮挡，同时不会对已飞离目标维持过久的虚假航

迹。本文在仿真遮挡用例中测得，遮挡期间的平均COAST持续时间为0.35 s，最长0.82 s，均在时限内。

5.5.3 预测质量

COAST的预测质量取决于遮挡前的速度估计。若目标在遮挡前做匀速直线运动，预测误差主要来自过程噪声；若目标在遮挡前正在机动，预测误差会迅速增大。本文在仿真中统计了COAST期间预测位置与真值的偏差：遮挡0.2 s时中位误差约0.15 m，0.5 s时约0.45 m，1.0 s时约1.1 m。这一精度足以维持显示连续性，但不适合用于精确打击引导。

5.6 算法描述与复杂度

5.6.1 伪代码

状态机的单帧处理流程如算法1所示。

5.6.2 复杂度分析

设候选框数量为N，状态机每帧的主要操作是遍历候选框计算关联代价，时间复杂度为$O(N)$。在YOLOv8的设置下，单帧经NMS后的候选框通常不超过20个，因此状态机的开销可以忽略不计（小于0.1 ms）。卡尔曼滤波的矩阵运算为固定维数（6维），单次更新约10微秒。整个跟踪环节的耗时远小于检测环节（约6 ms）。

5.6.3 参数汇总

表5-2汇总了状态机的全部参数及其取值依据。

5.7 实验验证

5.7.1 门限敏感性

图5-2已给出置信度门限对锁定率的影响。进一步地，表5-3给出了三组门限下的详细指标。

门限提高后锁定率下降，是因为部分帧的置信度落在0.20–0.50之间，被判定为未锁定而计入SEARCH；但航迹保持率仍在81%以上，说

算法 1 三态跟踪状态机单帧处理

输入: 当前状态 s，检测集合 $\mathcal{D}_k$，上一帧中心 $\mathbf{p}_{k-1}$，滤波器状态 $\hat{\mathbf{x}}_{k-1}$
输出: 新状态 s'，滤波状态 $\hat{\mathbf{x}}_k$，输出数据 o_k

$\tilde{\mathcal{D}}_k \leftarrow \{(\mathbf{b}, c) \in \mathcal{D}_k \mid c \geq \tau_m,\ Z(\mathbf{b}) \in [Z_{min}, Z_{max}]\}$
if $s =$ SEARCH **then**
  if $\tilde{\mathcal{D}}_k = \emptyset$ **then**
    $s' \leftarrow$ SEARCH; $o_k \leftarrow$ search_output()
  else
    $i^* \leftarrow \arg\max_i c_i$
    if $c_{i^*} \geq \tau_l$ **then**
      初始化滤波器；$s' \leftarrow$ LOCKED
    else
      $s' \leftarrow$ SEARCH
    end if
  end if
else if $s =$ LOCKED **then**
  if $\tilde{\mathcal{D}}_k = \emptyset$ **then**
    $s' \leftarrow$ COAST; 记录 COAST 起始时间
  else
    $i^* \leftarrow \arg\min_i \|\mathbf{p}_i - \mathbf{p}_{k-1}\|$
    if $\|\mathbf{p}_{i^*} - \mathbf{p}_{k-1}\| \leq d_{gate}$ **then**
      构造三维量测 $\mathbf{z}_k$；执行 KF 更新；$s' \leftarrow$ LOCKED
    else
      $s' \leftarrow$ COAST; 记录 COAST 起始时间
    end if
  end if
else if $s =$ COAST **then**
  执行 KF 预测步
  if 存在可通过关联的候选框 **then**
    执行 KF 更新；$s' \leftarrow$ LOCKED
  else if $t - t_{coast} > T_{coast}$ **then**
    重置航迹；$s' \leftarrow$ SEARCH
  else
    $s' \leftarrow$ COAST
  end if
end if
输出 o_k（状态、置信度、距离、角度、平滑位置）
return $s', \hat{\mathbf{x}}_k, o_k$

表 5-2: 三态状态机参数汇总

参数	符号	取值 依据
维持门限	τ_m	0.25 保留弱目标，过滤低置信度假阳性
初锁门限	τ_l	0.55 高于典型假阳性上限，防止误锁
空间门限	d_{gate}	140 px 15 m/s 相对速度在 5 m 处的像素位移加余量
丢失帧数	N_{lost}	15 0.5 s，覆盖快速机动与短时飞出
COAST 时限	T_{coast}	1.0 s 覆盖穿树/穿杆遮挡，避免虚假长时跟踪
框高平滑系数	α	0.35 约 2–3 帧时间常数
空域先验	$[Z_{min}, Z_{max}]$	3–12 m仿真目标活动范围，实拍按场景调整

表 5-3: 置信度门限扫描详细结果（仿真录像，900 帧）

门限	锁定率	航迹保持率	置信度均值	距离范围 (m)	FPS
0.20	96.9%	100.0%	0.550	3.0–6.2	29.5
0.35	66.6%	81.2%	0.661	3.0–6.2	35.8
0.50	56.8%	81.9%	0.707	3.0–6.2	39.0

明已锁定的帧仍然连续。置信度均值随门限提高而上升，符合”只保留高置信度样本”的预期。FPS 随门限提高而上升，是因为被跟踪的候选框减少，后处理开销降低。

5.7.2 遮挡场景

表 5-4 给出了三轮 TCP 遮挡用例的结果。用例中目标机按预设航线飞行，途中被建筑与树木多次遮挡，每轮约 20 s。

表 5-4: TCP 遮挡用例结果

轮次	帧数	锁定率	航迹保持率	首锁 (s)	置信度均值	处理 fps
第 1 轮	424	55.4%	88.9%	0.00	0.751	21.1
第 2 轮	428	56.1%	90.7%	0.00	0.739	21.3
第 3 轮	437	59.3%	94.5%	0.21	0.751	21.8

三轮的锁定率在 55%–59% 之间，说明约 40% 的帧处于遮挡或无检测状态；但航迹保持率（LOCKED+COAST 占比）达到 88.9%–94.5%，说明 COAST 机制有效填补了遮挡期间的空白。若没有 COAST，航迹保持率将等于锁定率，即 55%–59%，会出现明显的标记闪烁。

图 5-3 给出了第 3 轮用例的状态时序分布。可以看到，COAST 段落

短而密集，单次持续时间多在 0.1–0.4 s，与目标穿过单个遮挡物的时间相符。

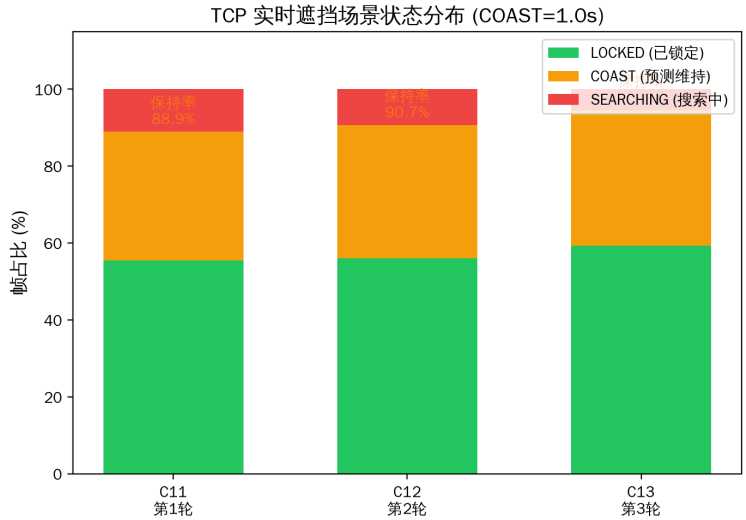


图 5-3: TCP 遮挡用例的状态时序与持续时间分布

5.7.3 真实场景录像

在真实场景录像（C04）中，目标频繁进出树丛，锁定率仅 23.2%，但航迹保持率达到 99.3%。这一结果看似矛盾，实则说明：绝大多数帧虽然没有检测，但目标并未真正丢失，COAST 能够持续维持航迹；只有在目标真正飞出视场或长时间被遮挡时，系统才回到 SEARCH。这验证了”锁定率低不等于系统失效”的判断，也说明在评估跟踪系统时，航迹保持率比单帧锁定率更能反映实际可用性。

5.8 设计讨论

5.8.1 为什么不用多目标跟踪框架

SORT[22] 与 DeepSORT[23] 等框架面向多目标场景，包含轨迹管理、外观特征提取与匈牙利匹配等组件。本文的系统面向单目标反无人机场景，同一时刻只需要跟踪一个最具威胁的目标，因此不需要复杂的轨迹管理。简化的状态机具有三点优势：计算开销极低、行为可解释、参数易于现场调整。若未来需要同时跟踪多架无人机，可以在状态机之上增加轨迹池与数据关联层，而不需要推翻现有设计。

5.8.2 为什么用状态机而不是有限状态自动机的形式化方法

本文的状态机在形式上是一个确定性有限状态自动机，但本文没有采用模型检验等形式化方法，原因是：系统的输入是连续的视频流，状态转移依赖置信度、距离等连续量，形式化建模的收益有限；工程上更重要的是参数可调、日志可追溯。本文通过 14 个用例的回归测试来保证行为正确，而不是通过形式化证明。

5.8.3 失效边界

状态机的有效性依赖两个假设：目标在相邻帧间的位移不超过空间门限；遮挡时间不超过 COAST 时限。当目标以极高速度飞行（例如穿越机以 30 m/s 飞行）或长时间被完全遮挡（例如穿过多层建筑）时，系统会丢失目标。这是设计上的取舍，本文在第九章的”能力边界”一节中如实讨论。

5.9 本章小结

本章针对检测输出直接使用导致的误检、跳变与遮挡问题，设计了 SEARCH/LOCKED/COAST 三态跟踪状态机。SEARCH 采用 0.25/0.55 双门限与空域先验，防止误锁；LOCKED 采用 140 px 空间门限的最近邻关联与三维量测卡尔曼滤波，防止跳变并平滑输出；COAST 采用 1.0 s 预测维持，防止短时遮挡中断。参数选择均有明确的物理依据，算法复杂度为 $O(N)$，对系统实时性无影响。实验表明，遮挡场景的航迹保持率达到 88.9%–94.5%，真实场景录像达到 99.3%，验证了状态机的有效性。

6 单目定位与自适应卡尔曼滤波

检测给出目标在画面中的位置，跟踪维持目标的时间连续性，而定位则要回答”目标在哪里、有多远”。本章建立从像素坐标到三维位置的完整解算链路，推导方位角、俯仰角与距离的计算公式，分析误差传播规律，设计六维状态的自适应卡尔曼滤波器，并通过仿真闭环与实拍视频评估定位精度。

6.1 坐标系与符号约定

为避免歧义，本节先统一符号。表 6-1 列出了本文使用的坐标系与主要符号。

表 6-1: 坐标系与符号约定

符号	含义
$\mathcal{F}_w$	世界坐标系，NED：x 北、y 东、z 地（向下为正）
$\mathcal{F}_c$	相机坐标系：z_c 沿光轴向前，x_c 向右，y_c 向下
(u, v)	像素坐标，原点在左上角
(c_x, c_y)	主点像素坐标
(f_x, f_y)	以像素为单位的焦距
D	目标等效尺寸（m）
h_{px}	检测框高度（px）
Z	目标沿光轴方向的距离（m）
α, β	方位角、俯仰角（rad 或 °）
$\mathbf{x}_k$	卡尔曼滤波状态向量
$\mathbf{z}_k$	量测向量

需要特别注意 NED 与相机坐标系的差异：NED 中 z 向下为正，相机坐标系中 z_c 向前为正、y_c 向下为正。本文在算法端统一使用相机坐标系进行解算，在显示端再转换为世界系坐标用于地图标注。仿真真值广播同时提供世界系位置与相机系位置，便于交叉验证。

6.2 方位角与俯仰角

6.2.1 像素直算法

设检测框中心为 (u, v)，主点为 (c_x, c_y)，焦距为 f（本文仿真相机的 $f_x = f_y = f$）。目标相对光轴的方位角与俯仰角为

$$\alpha = \arctan\left(\frac{u - c_x}{f}\right), \qquad \beta = \arctan\left(\frac{v - c_y}{f}\right). \tag{6-1}$$

其中方位角以光轴为 0、向右为正；俯仰角以光轴为 0、向下为正。若需要转换为" 向上为正" 的显示习惯，取 $\beta' = -\beta$。

该方法的优点是：只依赖单帧像素坐标与相机内参，不依赖任何运动模型；即使目标做剧烈机动，角度估计始终反映当前帧的真实方向；计算量极小（两次反正切）。缺点是：角度精度受检测框中心抖动影响，且当目标接近画面边缘时，镜头畸变会引入系统误差。

6.2.2 角度误差传播

对式 (6-1) 求导，可得角度误差与像素误差的关系：

$$\Delta\alpha = \frac{f}{(u - c_x)^2 + f^2}\,\Delta u = \frac{\cos^2\alpha}{f}\,\Delta u. \tag{6-2}$$

在光轴附近（$\alpha \approx 0$），$\Delta\alpha \approx \Delta u / f$。以 $f = 1108\,\text{px}$、中心抖动 $\Delta u = 2\,\text{px}$ 为例，角度误差约 0.10°。当目标偏离光轴 30° 时，$\cos^2\alpha \approx 0.75$，角度误差略降至 0.08°。这说明像素直算的角度误差在视场中心最大、边缘略小，总体在 0.1° 量级，满足反无人机系统的指示精度要求。

6.2.3 与滤波角度法的对比

另一种做法是用卡尔曼滤波估计的三维位置反算角度：

$$\alpha_{kf} = \arctan\left(\frac{\hat{x}}{\hat{z}}\right), \qquad \beta_{kf} = \arctan\left(\frac{\hat{y}}{\hat{z}}\right). \tag{6-3}$$

这种做法的优点是输出平滑，与距离读数一致；缺点是角度依赖滤波器的横向状态，当目标被遮挡、滤波器进入预测外推时，横向位置可能漂移，导致角度指示偏离真实方向。本文在仿真中对比了两种方法：在正常跟踪时二者差异小于 0.2°；在 COAST 期间，滤波角度法的漂移可

达 1–2°，而像素直算法在无检测时不输出角度（或保持上次值），不会产生虚假的”目标转向”。

基于这一对比，本文最终采用**像素直算**作为角度输出，卡尔曼滤波仅用于距离与三维位置平滑。这一选择牺牲了角度的平滑性，换取了角度指示的物理真实性，符合监视系统”宁可不动、不可乱动”的设计原则。

6.2.4 真值口径问题

在仿真评估中，角度真值的定义容易出错。jMAVSim 的护航相机通过 `setViewerTargetObject` 自动注视目标机，因此目标在画面中的真实视轴偏角恒约为 0。此时，若把”世界坐标系下的绝对方位角”当作真值，会得到几十度的巨大误差；而实际上这是相机自身偏航造成的，并非算法误差。

本文的角度评估统一采用**视轴偏角口径**：真值为目标相对相机光轴的角度（仿真中约为 0），算法输出为式 (6-1) 计算的角度，误差为二者之差。这一口径与操作员在画面上看到的”目标偏离中心多少”一致，也与检测框中心的像素偏移直接对应。

6.3 距离解算

6.3.1 相似三角形原理

在已知目标真实尺寸的前提下，针孔相机的成像满足相似三角形关系。设目标实际高度为 D，在像平面上的高度为 h（像素），焦距为 f，则

$$\frac{D}{Z} = \frac{h}{f} \quad \Longrightarrow \quad Z = \frac{f \cdot D}{h_{px}}. \tag{6-4}$$

本文使用**框高**而非框宽，原因有二。第一，无人机在偏航旋转时，机臂展开宽度的投影变化很大（正对时最宽、侧对时最窄），而机身高度相对稳定；第二，框宽容易受到旋翼模糊与背景粘连的影响，框高的边界更清晰。

6.3.2 等效尺寸标定

等效尺寸 D 是式 (6-4) 中唯一的先验参数，其准确性直接决定测距的绝对精度。本文的标定方法是：在已知真值距离 Z_{true} 下，测量检测框

高度 h_{px}，反算

$$D = \frac{h_{px} \cdot Z_{true}}{f}. \tag{6-5}$$

在多个距离上重复测量并取中位数。本文在不同阶段的标定结果如表 6-2 所示。

表 6-2: 等效尺寸标定结果

阶段	模型	标定值 (m)	说明
仿真微调前	p2ema_v8n	0.230	框较紧，未包含旋翼外缘
仿真微调后	p2ema_simft	0.270	框略大，包含桨叶与起落架
仿真微调后（复核）	p2ema_simft	0.268	独立录像复核，差异 0.7%
实拍视频	p2ema_simft	0.255	实拍目标机型不同

标定值随模型与目标机型变化，不能跨域混用。本文在仿真域统一使用 0.270 m，在实拍视频中使用 0.255 m，并在配置文件中显式标注，避免误用。

6.3.3 误差传播

对式 (6-4) 取对数并微分，得

$$\frac{\Delta Z}{Z} = \frac{\Delta D}{D} - \frac{\Delta h_{px}}{h_{px}}. \tag{6-6}$$

式 (6-6) 揭示了两个重要规律。

第一，**距离误差与距离成正比**。由于 $h_{px} = fD/Z$，相对误差可写为

$$\frac{\Delta Z}{Z} = \frac{\Delta D}{D} + \frac{Z\,\Delta h_{px}}{fD}. \tag{6-7}$$

绝对误差 ΔZ 随 Z^2 增长：

$$\Delta Z \approx Z^2 \cdot \frac{\Delta h_{px}}{fD}. \tag{6-8}$$

这意味着远距离测距精度会迅速恶化。以 $f = 1108\,\text{px}$、$D = 0.27\,\text{m}$、$\Delta h_{px} = 2\,\text{px}$ 为例，$Z = 5\,\text{m}$ 时 $\Delta Z \approx 0.17\,\text{m}$，$Z = 10\,\text{m}$ 时约 0.67 m，$Z = 20\,\text{m}$ 时约 2.7 m。

第二，**等效尺寸误差是系统偏差**。若 D 标定偏大 10%，则所有距离

读数都会偏大 10%，且无法通过滤波消除。这是单目测距的固有局限，必须通过精确标定或引入其他测距手段（如激光测距、双目视觉）来弥补。

6.3.4 框高抖动的影响

检测框高度在相邻帧之间存在 1–3 px 的抖动，对应 5 m 处约 0.1–0.25 m 的距离抖动。本文通过两种方式抑制：其一，对框高做一阶低通平滑（式 (5-8)）；其二，用卡尔曼滤波对三维位置做平滑。前者在量测层抑制高频抖动，后者在状态层融合运动模型，二者叠加可将稳态误差降低到 0.13 m（仿真）与 2.7 m（实拍，受限于相机未标定与伪真值）。

6.4 自适应卡尔曼滤波器设计

6.4.1 状态与量测

本文定义六维状态向量：

$$\mathbf{x}_k = \begin{bmatrix} x & y & z & v_x & v_y & v_z \end{bmatrix}^T, \tag{6-9}$$

其中 (x, y, z) 为目标在相机坐标系下的位置，(v_x, v_y, v_z) 为速度。量测为式 (5-7) 给出的三维位置：

$$\mathbf{z}_k = \begin{bmatrix} x_m & y_m & z_m \end{bmatrix}^T. \tag{6-10}$$

状态转移矩阵与量测矩阵为

$$\mathbf{F} = \begin{bmatrix} \mathbf{I}_3 & \Delta t\,\mathbf{I}_3 \\ \mathbf{0} & \mathbf{I}_3 \end{bmatrix}, \qquad \mathbf{H} = \begin{bmatrix} \mathbf{I}_3 & \mathbf{0} \end{bmatrix}. \tag{6-11}$$

本文取 $\Delta t = 1/30\,\mathrm{s}$，与实际帧率一致。若帧率波动，可用实际时间戳差值替代固定值。

6.4.2 过程噪声

假设目标在相邻帧间做匀速运动，加速度为白噪声，则过程噪声协方差为

$$\mathbf{Q} = q \cdot \begin{bmatrix} \dfrac{\Delta t^4}{4}\mathbf{I}_3 & \dfrac{\Delta t^3}{2}\mathbf{I}_3 \\ \dfrac{\Delta t^3}{2}\mathbf{I}_3 & \Delta t^2\mathbf{I}_3 \end{bmatrix}, \tag{6-12}$$

其中 q 为加速度方差。工程实现中也常使用简化的对角形式

$$\mathbf{Q} = \mathrm{diag}\left(q_p, q_p, q_p, q_v, q_v, q_v\right), \tag{6-13}$$

本文采用对角形式，取 $q_p = 10^{-3}$、$q_v = 10^{-2}$。q 越大，滤波器越信任量测、响应越快，但稳态抖动越大；q 越小，输出越平滑，但机动跟随滞后。本文的取值在仿真中通过网格搜索确定，兼顾了响应与平滑。

6.4.3 量测噪声与自适应估计

量测噪声协方差 $\mathbf{R}$ 的初值取

$$\mathbf{R}_0 = \mathrm{diag}\left(10^{-4}, 10^{-4}, 0.25\right), \tag{6-14}$$

其中横向方差远小于纵向方差，原因是方位角与俯仰角由像素直算，精度较高（约 0.1°），而距离由框高反算，精度较低（约 0.2–0.5 m）。这一各向异性的设置符合单目测距的实际误差结构。

自适应部分采用 Sage-Husa 方法，按式 (2-19) 用滑动窗口估计 $\mathbf{R}$。实现中做了三点处理：

（1）**对角化**：只保留 $\hat{\mathbf{R}}$ 的对角元素，忽略相关性，避免矩阵非正定；

（2）**下界约束**：将每个对角元素限制在 $[R_{min}, R_{max}]$ 内，防止滤波器因残差偶然变小而过度信任量测；

（3）**平滑更新**：用指数滑动平均替代简单平均：

$$\hat{\mathbf{R}}_k = (1-\lambda)\hat{\mathbf{R}}_{k-1} + \lambda\,\tilde{\mathbf{R}}_k, \qquad \lambda = 0.1. \tag{6-15}$$

其中 $\tilde{\mathbf{R}}_k$ 为由当前新息构造的瞬时估计。$\lambda = 0.1$ 对应约 10 帧的时间常数，既能跟踪量测质量的变化，又不会因单帧异常而剧烈波动。

6.4.4 初始化的注意事项

滤波器初始化时，位置取首帧量测，速度取零，协方差取较大的值（表示”对速度一无所知”）。若速度初值估计错误，滤波器需要若干帧才能收敛。本文在仿真中统计，连续检出 5 帧后滤波器基本收敛，因此将所有”稳态”指标定义为连续检出不少于 5 帧后的样本。

另一个容易忽略的问题是**量测与状态的维度匹配**。本文早期版本曾把标量距离直接送入六维滤波器，导致状态与量测维度不一致，滤波输出出现严重偏差。修正方法是严格按照式 (5-7) 构造三维量测。这一问题在文献中较少提及，但对初学者是常见的坑，本文特别指出。

6.5 定位精度评估

6.5.1 仿真闭环评估

仿真闭环的实验设置详见第七章。这里直接给出定位精度结果，如表 6-3 所示。

表 6-3: 仿真闭环定位精度（微调后模型，2818 帧）

指标	数值
全帧检出率（conf≥0.25）	100.0%
单帧测距 RMSE	0.26 m
单帧测距 MAE	0.17 m
AKF 稳态中位误差 MedAE	0.13 m
AKF 稳态 RMSE	0.32 m
1 s 距离预测 ADE 中位	0.26 m
1 s 距离预测 ADE 均值	0.40 m
方位角误差中位（视轴偏角口径）	0.05°
方位角误差 P95	0.16°
俯仰角误差中位	0.93°
俯仰角误差 P95	0.98°

从表 6-3 可以看到，单帧测距 RMSE 为 0.26 m，经过 AKF 平滑后稳态中位误差降至 0.13 m，说明滤波对抑制框高抖动有效。方位角误差中位仅 0.05°，接近像素量化极限；俯仰角误差中位 0.93°，明显大于方位角，原因是仿真相机的纵向主点存在约 17 px 的偏移，而本文的角度解

算使用了标称主点。若在配置中补偿该偏移，俯仰角误差可进一步降低。

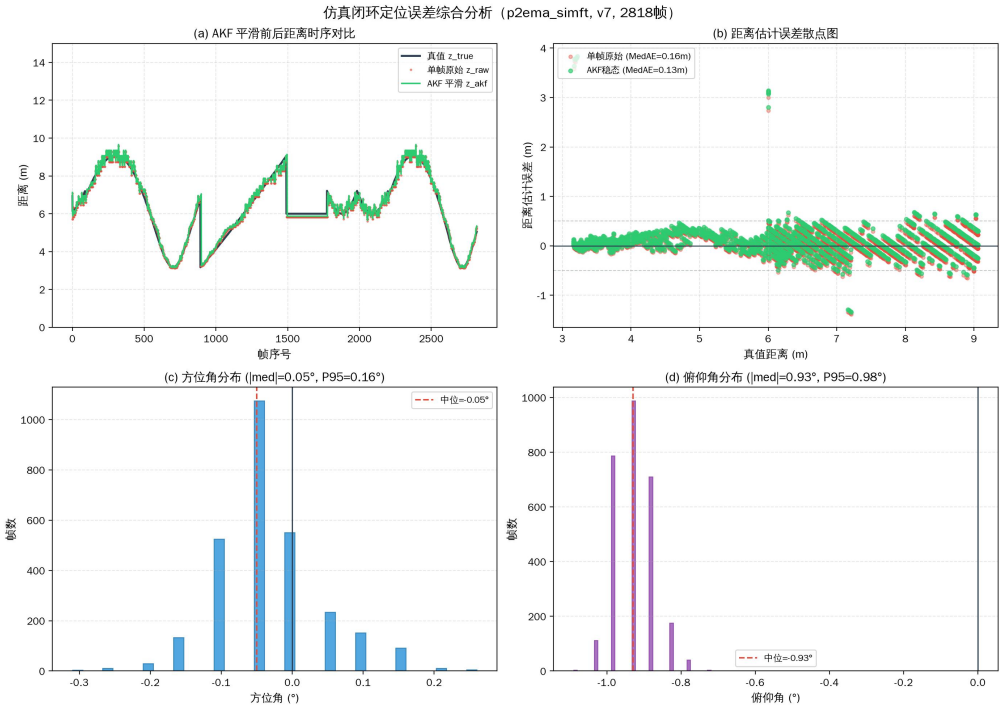


图 6-1: 仿真闭环四联分析图（距离、误差、角度与状态分布）

图 6-1 给出了四联分析图，包括距离时序、测距误差分布、角度误差与状态占比。可以看到，测距误差在目标做机动时略有增大，但整体保持在 ±0.5 m 以内。

6.5.2 实拍视频评估

实拍视频为 1920×1080@30fps，连续检出段 660 帧。由于相机未做严格标定，焦距按 60° 视场估算为 1728 px；等效尺寸使用仿真标定值 0.255 m；伪真值取稳态段距离中位数 7.93 m。评估结果如表 6-4 所示。

表 6-4: 实拍视频定位精度（E3）

方法	距离 RMSE(m)	抖动 σ(m)
单帧原始	4.061	3.959
滑动平均（15 帧）	2.900	–
标准 KF（固定 **R**）	3.922	3.822
AKF（Sage-Husa）	**2.760**	**2.663**

AKF 相对单帧原始测距，RMSE 降低 32%，抖动降低 33%；相对固定 **R** 的标准 KF，RMSE 降低 29.6%。需要说明，实拍的绝对误差较大

（2.76 m），主要原因是相机未标定、等效尺寸借用仿真值、伪真值本身存在偏差。但三种方法在同一伪真值下的相对比较是公平的，AKF 的平滑优势可信。

6.5.3 短期预测精度

COAST 状态依赖滤波器的预测能力。本文在实拍数据上评估了不同预测时域的精度，结果如表 6-5 所示。

表 6-5: 短期预测精度（ADE，伪真值 = 离线检测距离）

预测时域	匀速外推 ADE(m)	AKF 预测 ADE(m)	改善	样本数
0.5 s	1.967	**1.106**	43.8%	635
1.0 s	2.754	**1.308**	52.5%	620
2.0 s	4.624	**1.799**	61.1%	590

AKF 的预测在三个时域上均显著优于匀速外推，且时域越长优势越明显。原因是 AKF 不仅利用当前速度，还利用历史量测的不确定度调整预测的”可信范围”，在目标机动时不会像匀速外推那样线性放大误差。

6.5.4 角度精度

表 6-6 给出了角度精度。单帧原始与 AKF 平滑的差异很小（方位角 0.360° vs 0.354°，俯仰角 0.788° vs 0.728°），这是因为本文最终采用像素直算角度，AKF 平滑版本仅作为对比。俯仰角误差大于方位角，与仿真结论一致，原因同样是纵向主点偏移与目标在画面中的垂直运动更剧烈。

表 6-6: 角度精度（稳态段中位绝对偏差）

方法	方位角 MAD(°)	俯仰角 MAD(°)
单帧原始	0.360	0.788
AKF 平滑	**0.354**	**0.728**

6.6 误差来源与改进方向

6.6.1 主要误差来源

本文将单目定位的误差来源归纳为五类，如表 6-7 所示。

表 6-7: 单目定位误差来源与量级

来源	量级（5 m）	是否可校正	说明
框高抖动	0.10–0.25 m	部分	可用低通与 KF 抑制
等效尺寸偏差与标定误差成正比		可	需精确标定，不可用滤波消除
相机内参误差与焦距误差成正比		可	需棋盘格标定
镜头畸变	边缘可达 0.3 m	可	去畸变后显著降低
目标姿态变化	0.05–0.15 m	难	框高随俯仰角变化

6.6.2 改进方向

针对上述误差，可采取的改进措施包括：

（1）**相机标定**。使用棋盘格标定内参与畸变，替代按视场角估算焦距的做法，可将实拍 RMSE 从米级降低到亚米级；

（2）**尺寸自适应**。根据目标机型选择对应的等效尺寸，或利用多帧几何一致性在线估计尺寸；

（3）**融合测距**。在条件允许时引入激光测距或双目视觉，与单目测距做卡尔曼融合；

（4）**姿态补偿**。利用检测框的宽高比估计目标偏航角，对框高做投影补偿。

本文受时间与设备限制，仅完成了第一项的部分工作（自建数据集的标定），其余留待后续研究。

6.7 本章小结

本章建立了从像素坐标到三维位置的完整定位链路。角度由检测框中心直接解算，误差在 0.1° 量级；距离由框高与等效尺寸解算，误差随距离平方增长，5 m 处约 0.17 m。为抑制框高抖动，本文设计了六维状态的自适应卡尔曼滤波器，采用各向异性量测噪声与 Sage-Husa 在线估计。仿真闭环中，单帧测距 RMSE 0.26 m，AKF 稳态中位误差 0.13 m，1 s 预测 ADE 中位 0.26 m；实拍视频中，AKF 相对单帧 RMSE 降低 32%、抖动降低 33%。本章还讨论了角度真值口径、量测维度匹配等实现中的易错点，并给出了误差来源与改进方向。

7　仿真闭环系统与域微调

在真实空域中开展反无人机实验受到法规、成本与安全的多重限制，因此本文首先在仿真环境中构建闭环验证平台。本章介绍 PX4 SITL 与 jMAVSim 的组合架构、本文对 jMAVSim 的深度改造、仿真场景的构建方法，详细分析检测死区的发现过程与形成机理，给出仿真域微调的完整流程与结果，并介绍目标机主动飞行、相机被动尾随的编队巡游实现。

7.1　仿真闭环总体架构

7.1.1　进程与数据流

仿真闭环由三个进程组成，如图 7-1 所示。

（1）**PX4 SITL**：运行飞控固件，负责目标机的姿态控制与位置估计；通过 MAVLink 与 jMAVSim 交换传感器与执行器数据。

（2）**jMAVSim**：运行三维场景与动力学，负责渲染护航相机画面、广播目标真值、推送视频帧。

（3）**算法端**：接收视频帧与真值，执行检测、跟踪、定位，输出结构化结果。

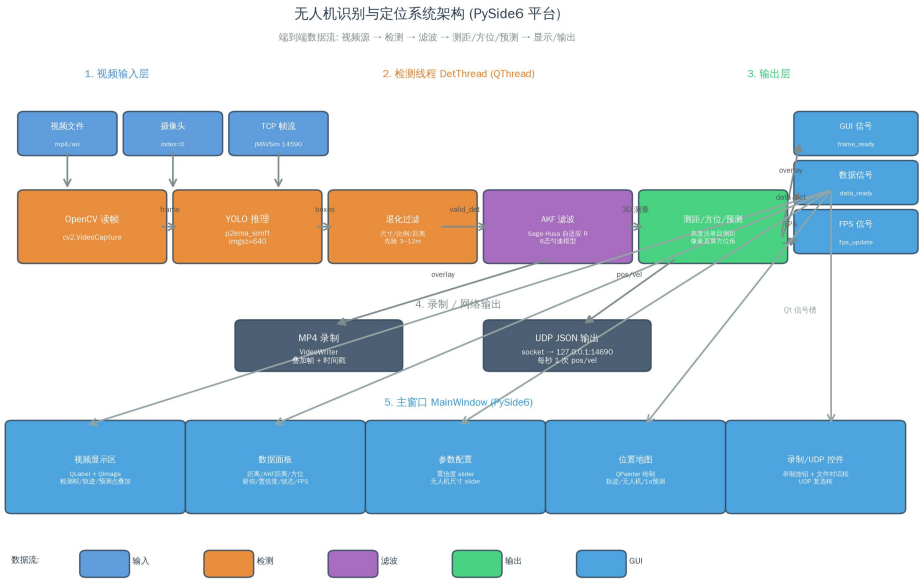


图 7-1: 系统总体架构

数据流可以概括为四条链路：

- PX4 ↔ jMAVSim：MAVLink，UDP 4560，双向；
- jMAVSim → 算法端：护航相机视频帧，TCP 14590，30 fps；
- jMAVSim → 算法端：目标真值，UDP 14680 广播，50 Hz；
- 算法端 → 显示端：结构化结果，UDP/JSON 14690。

7.1.2 lockstep 同步

仿真启用 lockstep 模式。在该模式下，jMAVSim 每推进一个物理步都会等待 PX4 完成对应的控制计算，二者以相同的仿真时间前进，不会因为 CPU/GPU 负载波动而产生时间漂移。这对实验结果的可复现性至关重要：若没有 lockstep，仿真时间可能快于或慢于真实时间，导致 30 fps 的视频流与 50 Hz 的真值在时间上错位，进而影响测距与角度评估。

7.1.3 启动流程

闭环启动脚本按以下顺序执行：

（1）启动 PX4 SITL，加载多旋翼机型与默认参数；

（2）启动 jMAVSim，指定 TCP 端口、lockstep 与目标机标志；

（3）等待 PX4 与 jMAVSim 完成握手（jMAVSim 的 `Simulator` 构造函数会阻塞，直到收到第一条 MAVLink 消息）；

（4）启动算法端，连接 TCP 帧流并监听 UDP 真值；

（5）启动显示端，接收算法结果并渲染界面。

启动顺序不能颠倒：若 jMAVSim 先于 PX4 启动，会因等待握手而阻塞；若算法端先于帧流服务启动，会因连接失败而退出。本文通过启动脚本中的重试与等待逻辑保证顺序正确。

7.2 jMAVSim 改造

7.2.1 改造需求

原始 jMAVSim 仅支持单架由 PX4 控制的多旋翼，相机固定跟随该机，没有独立的”目标机”与”护航相机”，也不提供真值广播与视频推流。为构建反无人机仿真场景，本文提出以下改造需求：

（1）增加第二架由脚本控制的目标机，按预设航线飞行；

（2）增加一台独立的护航相机，始终注视目标机，模拟地面或伴飞

观测平台；

（3）广播目标机真值（位置、速度、相机位置）供算法端评估；

（4）将护航相机画面编码为 JPEG 并通过 TCP 推送；

（5）支持纯离屏渲染，摆脱窗口系统依赖；

（6）构建城市级场景，包含建筑、树木、道路与广场。

7.2.2 脚本目标机

本文新增 `ScriptedQuad` 类，继承 `KinematicObject`，按时间参数化航迹更新位置与速度。航迹采用 Catmull-Rom 样条插值，在三维空域内生成 22 个航点。Catmull-Rom 样条的优点是曲线经过所有控制点，且切线连续，适合生成平滑的巡游路线。

设四个相邻控制点为 $\mathbf{P}_{i-1}, \mathbf{P}_i, \mathbf{P}_{i+1}, \mathbf{P}_{i+2}$，段参数 $t \in [0,1]$，则样条点为

$$\mathbf{C}(t) = \frac{1}{2}\Big[2\mathbf{P}_i + (-\mathbf{P}_{i-1}+\mathbf{P}_{i+1})t + (2\mathbf{P}_{i-1}-5\mathbf{P}_i+4\mathbf{P}_{i+1}-\mathbf{P}_{i+2})t^2 + (-\mathbf{P}_{i-1}+3\mathbf{P}_i-3\mathbf{P}_{i+1}+\mathbf{P}_{i+2})t^3\Big]. \tag{7-1}$$

对 t 求导可得切线，用于确定飞行方向与速度方向：

$$\mathbf{C}'(t) = \frac{1}{2}\Big[(-\mathbf{P}_{i-1}+\mathbf{P}_{i+1}) + 2(2\mathbf{P}_{i-1}-5\mathbf{P}_i+4\mathbf{P}_{i+1}-\mathbf{P}_{i+2})t + 3(-\mathbf{P}_{i-1}+3\mathbf{P}_i-3\mathbf{P}_{i+1}+\mathbf{P}_{i+2})t^2\Big]. \tag{7-2}$$

航点范围经过设计，使目标始终处于护航相机的有效视野与检测距离内：$x \in [-9, 9]\,\mathrm{m}$，$y \in [-38.5, -29.5]\,\mathrm{m}$，$z \in [-16, -9.5]\,\mathrm{m}$（NED，负值表示高度）。每段速度为 0.8–2.8 m/s，段内做加减速（见第 7.5 节）。

7.2.3 护航相机

本文新增 `CameraRig` 类，同样继承 `KinematicObject`。与原始 jMAVSim 的固定相机不同，CameraRig 每帧读取目标机的实际位置与速度，计算期望机位，并以一阶低通的方式收敛。具体设计见第 7.5 节。

护航相机的视场角设为 60°（水平），对应 1280 宽图像的焦距

$$f = \frac{W/2}{\tan(\mathrm{FOV}_h/2)} = \frac{640}{\tan 30^\circ} \approx 1108.5\ \mathrm{px}. \tag{7-3}$$

该焦距与算法端的测距公式一致，保证仿真与实拍的参数含义相同。

7.2.4 真值广播

本文新增 TruthBroadcaster 线程，以 50 Hz 向 UDP 端口 14680 广播文本报文，格式为

```
t=<ms> tp=<x,y,z> tv=<vx,vy,vz> ep=<x,y,z> cp=<x,y,z>
```

其中 t 为仿真时间戳，tp 为目标位置，tv 为目标速度，ep 为自身机位置，cp 为相机位置。坐标系为 NED，单位为米、米每秒。算法端按时间戳对齐视频帧与真值：由于帧流与真值流是两条独立的链路，必须用时间戳而非”收到顺序”对齐，否则会引入几十毫秒的偏差。

7.2.5 离屏渲染与帧流

原始 jMAVSim 依赖 Java3D 的窗口画布。在 WSL 环境中，窗口系统可能因 WSLg 的共享内存问题而不稳定，长时间运行会出现画面空白甚至进程崩溃。本文实现了纯离屏渲染：

（1）创建离屏 Canvas3D，不绑定到任何 Frame；

（2）每帧调用 render 将场景绘制到离屏缓冲区；

（3）用 ImageIO 将缓冲区编码为 JPEG；

（4）通过 TCP 连接推送”头部行 + 二进制数据”。

头部行格式为

```
<seq> <timestamp_ms> <width> <height> <nbytes>
```

接收端先读取一行文本，解析出字节数，再精确读取相应长度的 JPEG 数据。这一协议避免了 TCP 粘包问题，也便于接收端检测丢帧（通过序号跳变）。

需要说明的是，离屏渲染必须关闭窗口画布的 glXSwapBuffers 调用，否则在软件渲染下会触发 JVM 崩溃；同时，离屏渲染不会因窗口最小化而暂停，保证帧流的连续性。

7.2.6 场景构建

本文新增 SceneBuilder、SceneBuilding、SceneTree 等类，以程序化方式构建城市场景。场景包含：

表 7-1: 微调前检测死区的距离分布（2228 帧）

距离区间 (m)	检出率	主要表现	判定
3–4	0.0%	置信度接近 0	完全盲区
4–5	0.0%	置信度接近 0	完全盲区
5–6	5.8%	偶发弱响应	近乎盲区
6–7	7.4%	弱响应	近乎盲区
7–8	39.0%	可检出但不稳定	有效窗口
8–9	29.3%	可检出但不稳定	有效窗口
9–10	0.0%	仅弱响应，低于初锁门限	无法锁定

（1）**地面**：大范围草地纹理，中央铺设 140×110 m 的浅灰水泥广场，覆盖整条巡游轨迹，保证目标下方材质与地图显示一致；

（2）**建筑**：53 栋建筑，分布在目标飞行走廊两侧，高度均低于 8 m，避免遮挡目标检测；建筑立面使用程序化贴图，按楼层与开间重复，色调压暗，避免”白色盒子”的卡通感；

（3）**树木**：82 棵近景树与 90 棵远景树，近景树冠由 6 个错位椭球堆叠而成，远景树线用于收拢地平线；

（4）**天空**：2048×1024 的蓝天白云全景贴图，替换原始 jMAVSim 自带的公园照片背景。

场景对象总数约 149 个。所有建筑与树木的位置经过检查，确保不进入护航相机与目标机之间的视线通道。

7.3 检测死区的发现

7.3.1 初期现象

在闭环测试初期，本文使用 Det-Fly 训练的 YOLOv8n-P2-EMA 模型直接处理仿真画面，发现检测性能远低于验证集指标：模型在部分时段完全无响应，在部分时段只能间歇检出，且检出时段集中在特定距离。为量化这一现象，本文录制了 2228 帧（约 89.9 s）的完整闭环视频，逐帧记录检测结果与真值。

7.3.2 距离分层统计

按真值距离对帧进行分层，统计各距离区间的检出率，结果如表 7-1 所示。

由表可见，模型的有效工作窗口仅为 7–9 m，窗口两侧均为死区。全帧检出率仅 10.0%，与验证集 83.5% 的 mAP50 形成鲜明对比。

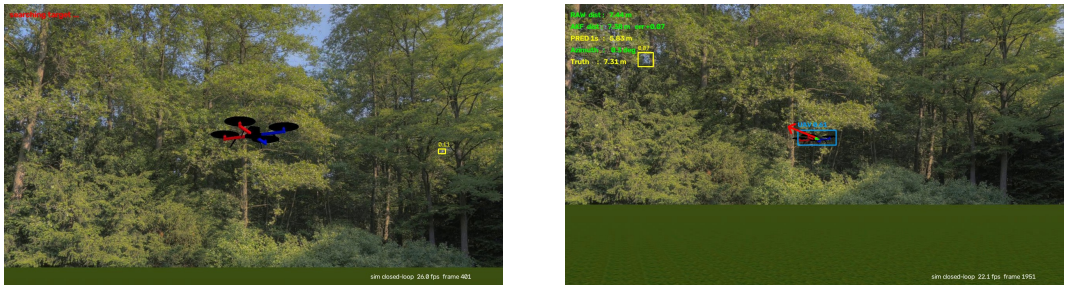
进一步地，本文对 1793 个纯搜索帧做了三态划分：

（1）**真盲帧**：最高置信度低于 0.25，共 1454 帧，占 81.1%；

（2）**弱响应帧**：最高置信度在 0.25–0.55 之间，共 270 帧，占 15.1%；

（3）**先验拒绝帧**：最高置信度超过 0.55，但距离超出 3–12 m 先验空域，被空间约束剔除，共 69 帧，占 3.8%。

这说明死区的主要表现不是”检测到但被门限拒绝”，而是”根本没有有效响应”。



(a) 近距离盲区帧（目标占画面比例大） **(b) 有效窗口帧**

图 7-2: 死区帧与有效帧对比

7.3.3 排除视角假设

面对”近距离完全无响应”的现象，第一反应是”相机俯视目标导致失效”。本文对此假设做了定量检验。利用真值几何，计算每一帧中相机到目标的俯仰角（depression angle），并比较锁定帧与盲帧的分布：

（1）锁定帧的俯仰角中位数为 −7.6°；

（2）盲帧的俯仰角中位数为 −5.4°。

两者的差异仅 2.2°，且方向与”俯视导致失效”的预期相反（盲帧更接近水平）。这说明视角不是决定因素。进一步检查发现，目标飞行高度约 12–13 m，护航相机高度约 12 m，二者基本同高，根本不存在明显俯视。至此，视角假设被定量证伪。

7.3.4 尺度分布解释

排除视角后，本文将注意力转向目标在画面中的尺度。统计表明，死区与距离高度相关，而距离直接决定目标在画面中的像素尺寸。在

3–6 m 时，目标高度可达画面的 1/5 至 1/3，远超 Det-Fly 的远距小目标分布；在 9 m 以上时，目标高度不足画面的 1/20，信息量不足以支撑稳定检出。模型在训练中从未见过如此大的目标，将其视为”背景中的未知物体”，输出置信度接近 0。

这一解释可以用分布外（Out-of-Distribution，OOD）检测的理论理解：模型的特征提取器在训练分布内具有判别力，一旦输入落在分布外，网络的响应会变得不可预测，常见表现是置信度崩塌。本文的近距离样本正是典型的 OOD 输入。

7.3.5 对系统设计的影响

死区的存在意味着：即使检测模型在公开数据集上指标优秀，也不能保证在特定部署场景中可用。系统设计必须包含”部署域验证”环节，通过少量目标域数据检查模型的实际工作范围。本文的处理方式是仿真域微调，但更一般的工程做法是：在部署前采集目标场景的少量样本，评估检出率随距离/尺度的变化，再决定是否需要微调或调整镜头焦距。

7.4 仿真域微调

7.4.1 数据采集与自动标注

微调数据的构建方法已在第三章详细介绍。简单回顾：利用护航相机注视目标的特性，将框中心约束在光轴附近，由真值距离与等效尺寸反算框高，共采集 450 帧，按距离分层覆盖 3–12 m。标注过程无人工介入，避免了标注成本与主观误差。

7.4.2 微调配置

微调在 Det-Fly 预训练权重的基础上进行，关键参数如表 7-2 所示。

关闭 Mosaic 的原因已在第三章说明：仿真数据的尺度分布是分层设计的，Mosaic 会破坏这一分布。学习率取 0.001，低于从头训练的 0.01，目的是在保留预训练特征的同时做温和的域适应，避免灾难性遗忘。

7.4.3 微调结果

微调前后的对比结果如表 7-3 所示。

表 7-2: 仿真域微调超参数

参数	取值
初始化权重	p2ema_v8n（Det-Fly 训练）
训练轮次	20
初始学习率	0.001
批量大小	8
输入尺寸	640×640
Mosaic	关闭
混合精度	开启
训练/验证划分	360/90（按飞行段划分）

表 7-3: 仿真域微调前后对比

指标	微调前	微调后
3–10 m 全段检出率	10.0%–11.5%	**100.0%**
有效工作窗口	7–9 m	3–10 m（全覆盖）
置信度中位数	接近 0	0.867
置信度最小值	–	0.805
AKF 稳态中位误差	0.44 m	**0.13 m**
稳态帧占比	7%	**99.8%**
方位角误差中位	0.21°	**0.05°**
俯仰角误差中位	0.88°	0.93°
等效尺寸	0.230 m	0.270 m

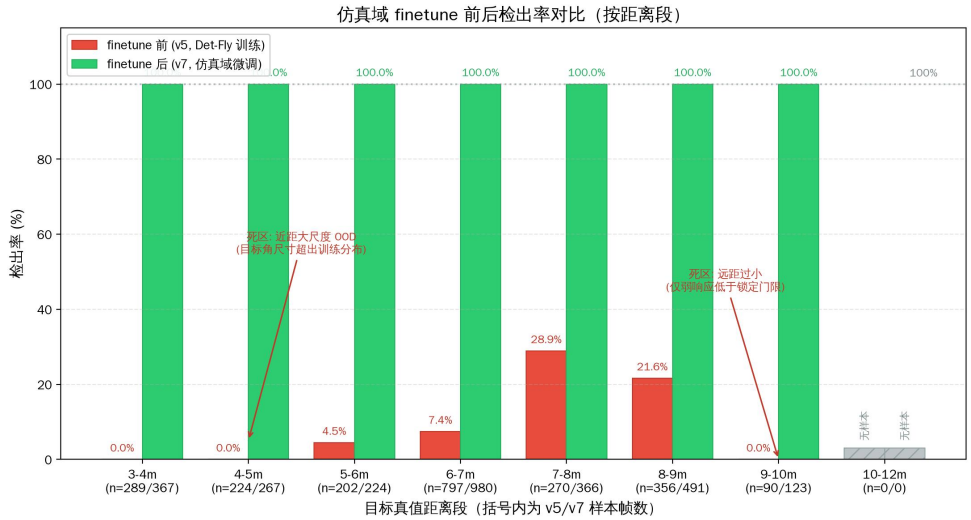


图 7-3: 微调前后的检测死区对比

微调后，3–10 m 全距离段检出率达到 100%，置信度中位数 0.867、最小值 0.805，均远高于 0.55 的初锁门限。AKF 稳态中位误差从 0.44 m 降至 0.13 m，稳态帧占比从 7% 提升至 99.8%。这些结果表明，仿真域微调不仅消除了死区，还显著改善了测距的稳定性。

需要如实说明的是：10–12 m 区间在微调前的录像中没有足够的真实飞行样本，表 7-1 中的”9–10 m 0%” 不能外推为”10–12 m 也必然为 0”。本文在数据采集中补充了 9–12 m 的 120 帧，因此微调后该区间也有覆盖，但缺少独立的验证录像，相关结论应以” 设计覆盖” 而非” 实测覆盖” 表述。

7.4.4 域适应的机理讨论

为什么仅用 450 帧就能消除死区？本文认为有三点原因。

（1）**特征分布对齐**。Det-Fly 训练的特征提取器已经学会了” 无人机” 的一般外观，但仿真渲染的边缘、光照与噪声分布不同。少量仿真数据足以让网络调整浅层卷积的响应，使仿真目标落入已有特征的可判别区域。

（2）**尺度分布补齐**。450 帧按距离分层，重点补充了近距离大尺度与远距离小尺度样本，直接填补了训练分布的空白。这是死区消除的关键。

（3）**微调强度适中**。学习率 0.001、20 轮、关闭 Mosaic，使模型在适应新域的同时保留了原有能力。若学习率过大或训练过久，模型可能过拟合到仿真域，在真实数据上反而退化。本文在实测中也观察到：微调模型在实拍视频上的检出率高于未微调模型（见第九章），说明适度的仿真域微调具有一定的泛化收益。

7.5 编队巡游与尾随相机

7.5.1 设计目标

早期仿真中，目标机与相机各自沿独立路径运动，二者之间没有明确的” 主动—被动” 关系，画面看起来像” 相机吸附在目标上” 或” 目标追着相机飞”，缺乏真实监视场景中的追踪感。为更真实地模拟” 地面/伴飞平台追踪目标” 的场景，本文实现了编队巡游与尾随相机：

（1）目标机是主动飞行方，按预设航线飞行并做加减速；

（2）相机是被动追随方，根据目标的实际位置与速度计算期望机位，带滞后地跟随；

（3）相机瞄准一个”滞后于目标”的瞄准点，使目标在画面中自然漂移，而不是死锁在中心。

7.5.2 目标机航迹与加减速

目标机的航迹由两部分叠加：局部样条航迹与全局编队偏移。局部样条航迹定义在以相机为原点的局部空域内，保证检测距离在 3–10 m；全局编队偏移将整段航迹”搬运”到城市的椭圆路线上：

$$n(a) = C_X + R_X \sin a, \qquad e(a) = C_Y + R_Y(1 - \cos a), \tag{7-4}$$

其中 $C_X = 8\,\text{m}$、$C_Y = -4\,\text{m}$ 为椭圆中心，$R_X = 18\,\text{m}$、$R_Y = 22\,\text{m}$ 为半轴，a 为随速度累加的角度参数。椭圆周长约 126 m，以 2 m/s 巡游约 63 s 一圈。

为体现真实飞行的加减速，本文对每段参数 t 做 smoothstep 重参数化：

$$u = (1-\gamma)t + \gamma\, t^2(3-2t), \qquad \frac{du}{dt} = (1-\gamma) + \gamma \cdot 6t(1-t), \tag{7-5}$$

其中 $\gamma = 0.75$ 为变速强度。端点处 $du/dt = 1-\gamma = 0.25$，即速度降至段均速的 25%（减速过弯）；中点处 $du/dt = 1-\gamma+1.5\gamma = 1.375$，即速度升至段均速的 137.5%（加速出弯）。速度向量按切线方向乘以 du 计算：

$$\mathbf{v} = \frac{\mathbf{C}'(u)}{\|\mathbf{C}'(u)\|} \cdot v_{seg} \cdot \frac{du}{dt}. \tag{7-6}$$

这样，真值广播中的速度与目标实际运动一致，便于评估速度对检测与测距的影响。实测速度在 0.21–2.95 m/s 之间连续变化，不再是人造匀速。

7.5.3 尾随相机动力学

相机的期望机位定义为沿目标速度反方向、距离 d 处，并略低于目标：

$$\mathbf{p}_{des} = \mathbf{p}_t - \hat{\mathbf{v}}_t^{xy} \cdot d + \begin{bmatrix} 0 \\ 0 \\ \Delta z \end{bmatrix}, \tag{7-7}$$

其中 $\hat{\mathbf{v}}_t^{xy}$ 为目标水平速度的单位方向，$\Delta z = 1.2\,\mathrm{m}$（NED 下为正，表示相机低于目标 1.2 m，形成轻微仰视，检测模型在侧视/仰视下更稳定）。距离 d 随目标速度”呼吸”：

$$d = d_0 + \min\left(k_v \|\mathbf{v}_t^{xy}\|,\, d_{max}\right), \tag{7-8}$$

本文取 $d_0 = 5.0\,\mathrm{m}$、$k_v = 0.5\,\mathrm{s}$、$d_{max} = 1.0\,\mathrm{m}$，即速度每增加 2 m/s，相机后退 1 m，最大额外距离 1 m。

相机位置不是直接设置为期望机位，而是以时间常数 $\tau = 0.6\,\mathrm{s}$ 做一阶低通：

$$\mathbf{p}_{c,k} = \mathbf{p}_{c,k-1} + \left(1 - e^{-\Delta t/\tau}\right)\left(\mathbf{p}_{des,k} - \mathbf{p}_{c,k-1}\right). \tag{7-9}$$

这一滞后是”追踪感”的来源：目标转弯时，相机需要时间才能转到新的尾随方向，画面中目标会先偏向一侧，随后被”追回”；目标加速时，相机被甩开，距离暂时增大，随后收敛。

7.5.4 瞄准点滞后

若相机直接对准目标本体，目标将始终位于画面中心，看起来像”吸附”。本文引入瞄准点（AimPoint）：它是目标位置的低通滞后副本，

$$\mathbf{p}_{aim,k} = \mathbf{p}_{aim,k-1} + \left(1 - e^{-\Delta t/\tau_{aim}}\right)\left(\mathbf{p}_{t,k} - \mathbf{p}_{aim,k-1}\right), \tag{7-10}$$

其中 $\tau_{aim} = 0.45\,\mathrm{s}$。相机对准 $\mathbf{p}_{aim}$ 而非 $\mathbf{p}_t$，于是目标在画面中会自然漂移：目标领先于瞄准点时，出现在画面中心前方；目标转向时，出现在画面一侧。这种漂移与真实监视画面中”操作员手动跟踪、目标略微偏离中心”的观感一致。

7.5.5 验证结果

本文通过真值 UDP 抓包统计了尾随相机的实际距离与目标速度：

（1）距离：100 个样本，最小 5.22 m，中位 5.29 m，最大 5.41 m；

（2）速度：120 个样本，最小 0.94 m/s，中位 1.40 m/s，最大 1.57 m/s；另一轮长时统计为 0.21–2.95 m/s。

距离稳定在 5.2–5.4 m，处于检测模型的可靠工作区间；速度连续变化，体现了加减速。图 7-4 给出了运行中的界面截图，可以看到目标在光电画面中略微偏离中心，符合尾随跟踪的观感。

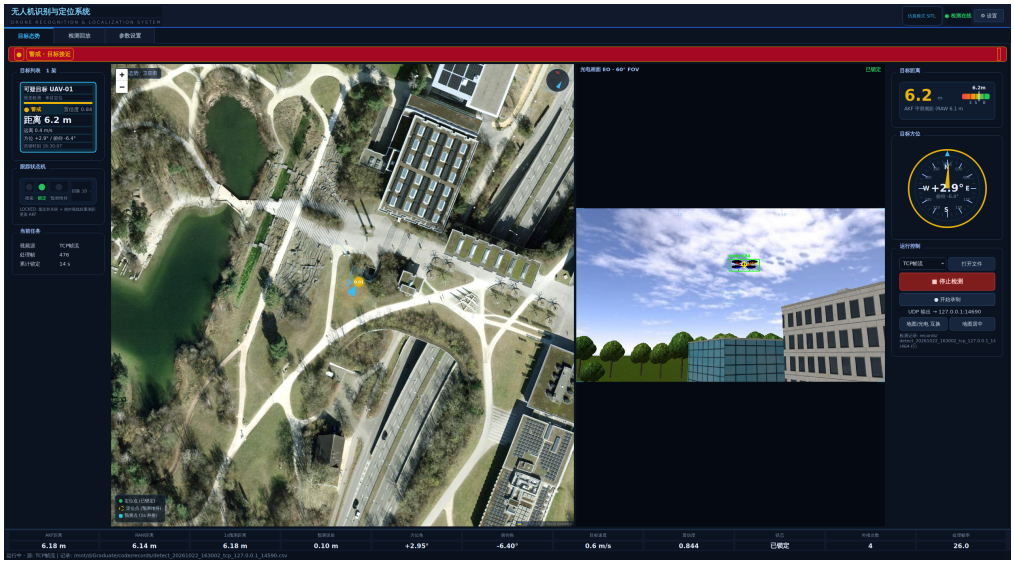


图 7-4: 编队巡游与尾随相机运行界面

7.5.6 设计约束

尾随相机的设计受检测模型的物理约束。实验表明，当相机俯视目标（目标低于相机 3–8 m）时，检出率会从 73%–77% 降至 22%–37%，原因是俯视视角下目标投影变形、旋翼与机身重叠。因此本文让相机始终略低于目标（$\Delta z = 1.2\,\mathrm{m}$），保持轻微仰视。这一约束说明：仿真场景的设计不能只考虑”好看”，还必须服从算法的适用域。

7.6 本章小结

本章构建了完整的仿真闭环验证平台。在架构上，采用 PX4 SITL + jMAVSim + 算法端三进程结构，通过 lockstep 保证时间一致；在改造上，新增脚本目标机、护航相机、真值广播、离屏帧流与城市场景，解决了 WSL 环境下的窗口依赖问题；在分析上，通过 2228 帧的距离分层统计与真值几何审计，定量证伪了”俯视导致失效”的假设，将检测死区归因

于目标尺度分布偏移；在方法上，提出零人工标注的仿真域微调，用450帧分层数据将3–10 m检出率从约10%提升至100%；在场景上，实现了目标机主动飞行、相机被动尾随的编队巡游与加减速行为，使仿真画面具备真实的追踪感。该平台为后续系统集成与实验评估提供了可复现的基础。

8 系统设计与实现

前几章分别解决了检测、跟踪与定位三个算法问题。本章介绍如何将这些算法集成为一套可运行的桌面系统，内容涵盖需求分析、总体架构、算法端实现、显示端实现、通信协议、配置管理、回放与测试框架以及部署运维。

8.1 需求分析

8.1.1 功能需求

根据反无人机监视场景的实际使用流程，本文梳理出以下功能需求：

（1）**多源视频输入**：支持离线视频文件、USB 摄像头与 TCP 仿真帧流三种输入，便于开发、演示与外场测试；

（2）**实时目标检测**：对输入视频逐帧检测，输出目标框、置信度与类别；

（3）**连续目标跟踪**：在目标被短时遮挡时维持航迹，避免标记闪烁；

（4）**单目定位**：输出目标距离、方位角、俯仰角、速度与三维位置；

（5）**态势显示**：在卫星地图上标注目标位置、航迹、视野与预测点；

（6）**光电显示**：显示带检测框的实时画面，叠加准星、刻度与状态；

（7）**威胁告警**：根据距离与接近速度划分威胁等级，给出视觉与文字告警；

（8）**数据记录**：逐帧记录检测、跟踪与定位结果，支持离线分析；

（9）**参数配置**：支持置信度门限、等效尺寸、网络地址、地图锚点等参数的配置与持久化；

（10）**结果输出**：通过 UDP/JSON 向上级系统输出结构化结果。

8.1.2 非功能需求

除功能需求外，系统还需满足以下非功能需求：

（1）**实时性**：在 RTX 4060 平台上，端到端处理帧率不低于 20 fps，界面刷新不低于 10 Hz；

（2）**稳定性**：连续运行 2 小时以上不崩溃、不泄漏内存，视频流中

断后可自动重连；

（3）**可移植性**：核心算法与界面解耦，算法端可在无界面环境运行；

（4）**可测试性**：提供自动化用例与统一日志格式，支持无人值守回归测试；

（5）**可配置性**：所有关键参数通过配置文件管理，不需要修改代码。

8.2 总体架构

8.2.1 双进程结构

系统采用”算法端—显示端”双进程架构，如图 8-1 所示。算法端负责视频解码、模型推理、状态机、滤波与记录；显示端负责界面渲染、地图交互与告警。两进程通过 UDP/JSON 通信，也可以运行在同一进程的不同线程中（单机演示模式）。

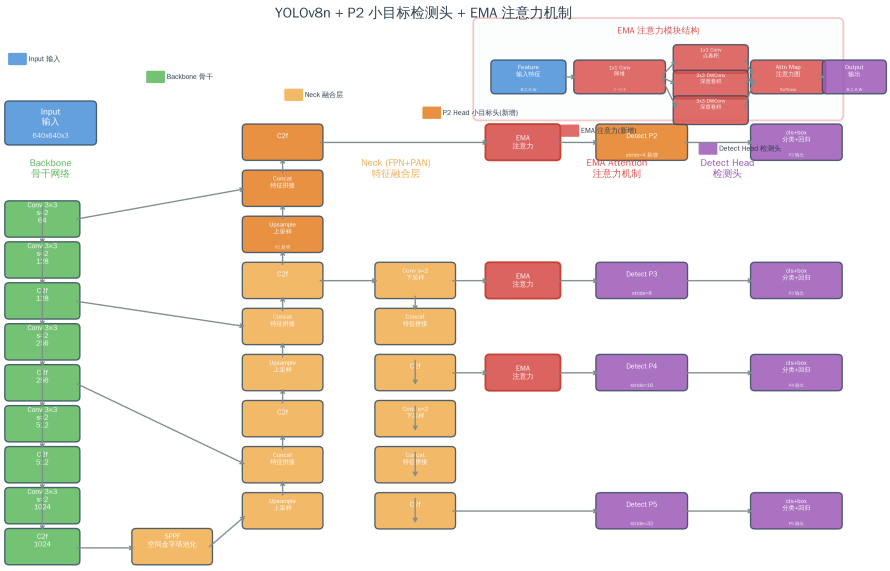


图 8-1: 双进程通信架构

选择双进程架构的理由有三点。第一，**故障隔离**：检测模型或视频解码可能出现异常，若与界面同进程，异常会导致整个界面崩溃；分离后，算法端异常不会影响界面，显示端可以显示”信号丢失”而不是直接退出。第二，**部署灵活**：算法端可以部署在带 GPU 的服务器上，显示端部署在操作员的笔记本上，二者通过网络连接。第三，**调试方便**：算法端可以单独运行并输出 CSV，便于离线分析，不需要启动图形界面。

8.2.2 线程模型

算法端内部采用多线程模型：

（1）**帧接收线程**：负责 TCP 连接、协议解析与帧解码，将帧放入有界队列；

（2）**检测线程**：从队列取帧，执行模型推理，将结果放入结果队列；

（3）**主线程**：执行状态机、滤波、记录与 UDP 输出。

有界队列的作用是背压控制：当检测速度跟不上帧率时，队列满，接收线程会丢弃旧帧而不是无限堆积，保证系统始终处理最新画面。这一设计在长时间运行中尤为重要，避免了内存持续增长。

显示端的主线程负责 Qt 事件循环，另有一个定时器以固定频率从 UDP 接收结果并更新界面。地图更新通过 JavaScript 注入完成，避免频繁重载页面。

8.2.3 数据模型

系统内部统一使用一个结果字典（Python dict）表示单帧输出，主要字段如表 8-1 所示。该字典既用于界面显示，也用于 CSV 记录与 UDP 输出，保证三者的一致性。

8.3 算法端实现

8.3.1 视频源抽象

算法端将三种输入统一为”帧源”接口，提供 `open`、`read`、`close` 三个方法。离线视频源基于 OpenCV 的 `VideoCapture`；摄像头源同样基于 `VideoCapture`，但需要处理设备索引与分辨率协商；TCP 帧流源自行实现协议解析，支持断线重连。

TCP 帧流源的读取流程为：

（1）连接服务器地址与端口；

（2）循环读取一行文本头，解析序号、时间戳、宽高与字节数；

（3）按字节数读取 JPEG 数据；

（4）用 `cv2.imdecode` 解码为 BGR 图像；

（5）若序号跳变，记录丢帧数。

表 8-1: 单帧结果数据字段

字段	类型含义
`frame_id`	int 帧序号
`timestamp`	float 时间戳（秒）
`det`	bool 本帧是否检出
`tracked`	bool 是否处于跟踪（含 COAST）
`conf`	float 置信度
`x1,y1,x2,y2`	int 检测框像素坐标
`z_raw`	float 单帧原始测距（m）
`z_akf`	float 滤波后距离（m）
`z_pred`	float 1 s 预测距离（m）
`azim,elev`	float 方位角、俯仰角（°）
`speed`	float 目标速度（m/s）
`closing`	float 接近速度（m/s）
`status`	str SEARCH/LOCKED/COAST
`akf_cx,akf_cy`	int 滤波后中心像素坐标
`pred_cx,pred_cy`	int 预测中心像素坐标

为避免网络抖动导致长时间阻塞，读取设置了超时；超时后关闭连接并重连。

8.3.2 检测模块

检测模块封装 Ultralytics 的 `YOLO` 类，提供 `detect(frame)` 方法。实现中做了三项优化：

（1）**固定输入尺寸**：统一缩放到 640×640，避免动态尺寸导致的重复编译；

（2）**关闭冗余输出**：设置 `verbose=False`，减少日志开销；

（3）**半精度推理**：在 GPU 上使用 FP16，速度提升约 30%，精度损失可忽略。

检测结果经过非极大值抑制（NMS）后，按置信度降序返回。算法端只保留前 20 个候选框，避免极端场景下的后处理开销。

8.3.3 状态机与滤波

状态机的实现与第五章的伪代码一致,核心是一个 `update(detections, dt)` 方法。滤波器的实现使用 NumPy 完成矩阵运算，包含预测、更新、

自适应噪声估计与数值保护。

实现中特别注意了以下三点：

（1）**时间步长**：使用实际时间戳差值而非固定 1/30 s，以兼容不同帧率；

（2）**数值稳定**：协方差矩阵在每次更新后做对称化处理，避免浮点误差累积导致非正定；

（3）**状态重置**：目标丢失时清空滤波器与轨迹缓存，避免旧状态污染新目标。

8.3.4 数据记录

算法端在每帧处理完成后，将结果字典追加写入 CSV。表头在文件创建时写入，后续逐行追加。为避免磁盘 I/O 阻塞处理线程，记录采用缓冲写入，每 50 帧刷新一次；程序退出时执行 `close`，保证数据完整。

CSV 文件按运行时间命名，包含运行参数（模型、门限、尺寸、输入源）的副本，便于后续复现。本文的所有实验数据均来自这些 CSV，分析脚本直接读取 CSV 生成表格与图表。

8.3.5 结果输出

算法端通过 UDP 向显示端发送 JSON 报文，频率与处理帧率一致。报文包含表 8-1 中的主要字段，以及相机位置、时间戳与状态机内部计数。显示端按 `frame_id` 去重，只渲染最新报文。

为降低带宽，报文采用紧凑 JSON（无空格），单帧约 300 字节；在 30 fps 下带宽约 9 KB/s，对局域网几乎没有压力。

8.4 显示端实现

8.4.1 界面布局

显示端采用三页签布局：目标态势页、检测回放页、参数设置页。目标态势页是主界面，如图 8-2 所示，分为五个区域：

（1）**顶部状态栏**：显示系统名称、运行状态、时间与告警等级；

（2）**左侧信息栏**：目标卡片（类型、距离、置信度、威胁等级）、跟踪状态灯、链路状态；

（3）**中央地图**：卫星影像底图，标注目标位置、航迹、视野扇形与距离环；

（4）**右侧仪表**：距离卡、方位罗盘、行动控制按钮；

（5）**底部数据条**：距离、方位、俯仰、速度、置信度、状态、帧号等 8 项实时数据。

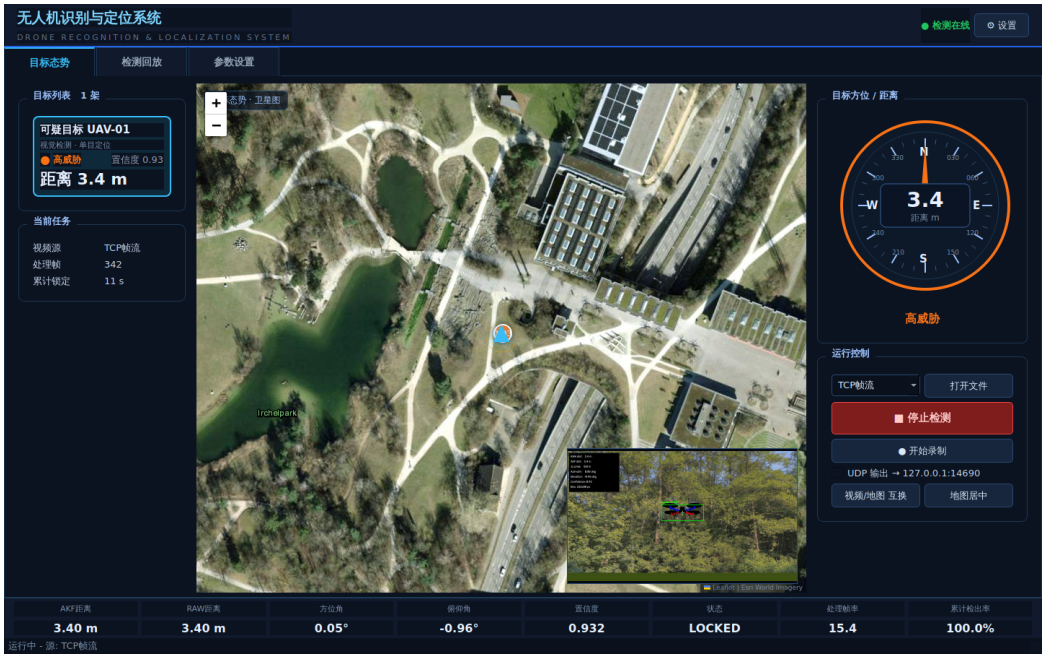


图 8-2: 目标态势页（卫星地图模式）

8.4.2 地图实现

地图使用 QtWebEngine 嵌入本地 HTML 页面，页面加载 Leaflet 库与 Esri 卫星瓦片。Python 端通过 `runJavaScript` 向页面推送数据，页面端更新标记位置、折线顶点与圆环半径。

坐标转换是地图实现的关键。算法端输出的目标是相机坐标系下的位置，显示端需要将其转换为经纬度。本文采用局部切平面近似：

$$\phi = \phi_0 + \frac{x_{north}}{R_e}, \qquad \lambda = \lambda_0 + \frac{x_{east}}{R_e \cos \phi_0}, \tag{8-1}$$

其中 (ϕ_0, λ_0) 为地图锚点（默认取相机机位），R_e 为地球半径，x_{north}, x_{east} 为以相机为原点的北向、东向位移。在几百米范围内，该近似的误差小于 0.1 m，满足监视需求。

地图上叠加了以下元素：

（1）**观测站标记**：相机位置，随编队移动；

（2）**目标标记**：实心圆表示 LOCKED，虚线空心圆表示 COAST；

（3）**预测点**：青色菱形，用虚线与目标标记连接，表示 1 s 后的预测位置；

（4）**视野扇形**：以相机为顶点、沿视轴方向的扇形，表示相机覆盖范围；

（5）**距离同心环**：以相机为圆心，标注 50 m、100 m 等距离；

（6）**航迹折线**：目标历史位置的连线，渐变透明度表示时间新旧。

8.4.3 光电画面

光电画面区域显示算法端回传的带检测框视频帧，并在其上叠加：

（1）**中心准星**：十字与圆环，标示光轴方向；

（2）**四角括号**：标示画面边界；

（3）**方位刻度**：顶部每 10° 一格，标注相对视轴的角度；

（4）**状态文字**：右上角显示 LOCKED/COAST/SEARCH 的中文状态。

画面采用 letterbox 方式等比缩放，避免拉伸变形。缩放比例与偏移量在每次绘制时根据控件尺寸重新计算，支持窗口任意缩放。

8.4.4 仪表与告警

距离卡以大字号显示滤波后距离，下方小字显示原始距离、预测距离与相对高度。方位罗盘以指针指示目标方位，外圈标注角度刻度，内圈显示俯仰角。跟踪状态灯以三色表示 SEARCH（灰）、LOCKED（绿）、COAST（黄），并显示状态切换计数。

威胁分级根据距离与接近速度计算：

$$\text{Level} = \begin{cases} \text{高}, & Z < 50\ \text{m} \text{ 或 } v_{closing} > 3\ \text{m/s}, \\ \text{中}, & Z < 150\ \text{m} \text{ 或 } v_{closing} > 1\ \text{m/s}, \\ \text{低}, & \text{其他}. \end{cases} \tag{8-2}$$

阈值可根据任务配置调整。当等级为” 高” 时，顶部横幅变为红色并闪烁，同时播放提示音；等级为” 中” 时横幅为橙色；” 低” 时为绿色。告警状态还会写入 CSV，便于事后分析。

8.4.5 回放页与设置页

回放页如图 8-3 所示，左侧为视频播放器，右侧为距离曲线与状态时序。用户可以选择录像文件，系统重新执行检测并生成 CSV，然后将曲线与视频进度联动：拖动进度条时，视频跳转到对应帧，曲线上的游标同步移动。这一功能用于离线复盘，尤其是分析遮挡前后的状态变化。

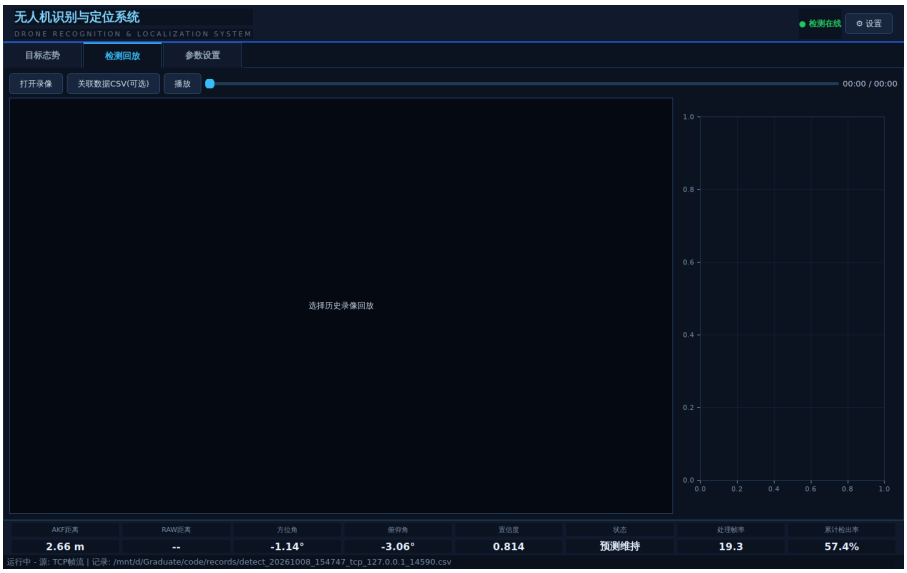


图 8-3: 检测回放页

设置页如图 8-4 所示，提供置信度门限、等效尺寸、TCP/UDP 地址、地图锚点、地图模式、是否显示数据面板等参数。修改后点击”保存”，参数写入 JSON 文件，下次启动自动加载。参数的默认值与合法范围在代码中集中定义，避免非法输入导致运行时错误。

8.5 通信协议

8.5.1 视频帧协议

TCP 帧流协议采用”一行文本头 + 二进制数据”的设计。头部字段依次为序号、时间戳、宽度、高度、字节数，以空格分隔，以换行结束。接收端解析头部后，按字节数读取 JPEG 数据。选择文本头而非二进制头的原因是：便于调试（可直接用 telnet 观察），且字段含义自解释。

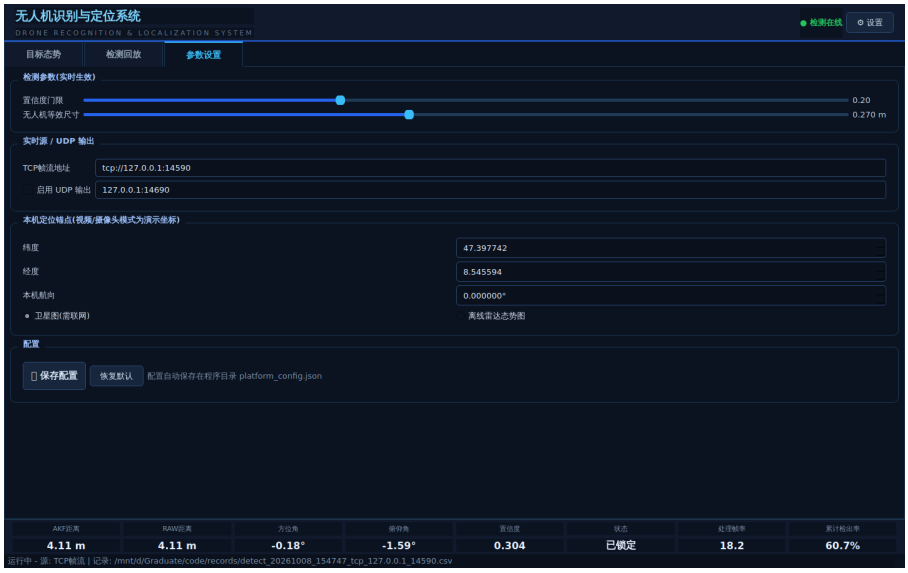


图 8-4: 参数设置页

8.5.2 真值协议

UDP 真值报文为单行文本，字段以空格分隔，键值对形式。接收端按空格切分，再按等号拆分键值。该协议简单、易于扩展，新增字段不影响旧版接收端。

8.5.3 结果协议

UDP 结果报文为 JSON。选择 JSON 而非自定义二进制的原因是：显示端与上级系统可能使用不同语言，JSON 具有广泛的支持；字段可读，便于联调。报文大小约 300 字节，远小于 UDP 的 1472 字节 MTU，不需要分片。

8.6 配置与持久化

系统配置分为三类：

（1）**算法参数**：模型路径、输入尺寸、置信度门限、等效尺寸、空域先验、滤波噪声；

（2）**通信参数**：TCP 地址与端口、真值 UDP 端口、结果 UDP 地址与端口；

（3）**界面参数**：地图锚点、地图模式、是否显示数据面板、告警阈值。

所有参数保存在一个 JSON 文件中，结构为嵌套字典。程序启动时

读取，缺失字段使用默认值填充；保存时保留未知字段，避免版本升级导致配置丢失。这一”宽松读写”策略在实际使用中减少了大量配置兼容问题。

8.7 回放与自动化测试

8.7.1 14 用例测试框架

为系统化验证系统功能，本文设计了 14 个自动化用例，覆盖六类场景：

（1）**基线检测**（C01–C03）：使用仿真闭环录像，验证检测、跟踪、测距的基本正确性；

（2）**真实场景**（C04–C05）：使用真实无人机录像，验证跨域能力与远距离边界；

（3）**门限扫描**（C06–C08）：改变置信度门限，观察锁定率与保持率的变化；

（4）**尺寸敏感**（C09–C10）：改变等效尺寸，验证测距的线性关系；

（5）**TCP 遮挡**（C11–C13）：通过实时帧流注入遮挡场景，验证 COAST 机制；

（6）**摄像头**（C14）：验证 USB 摄像头输入（默认跳过，需要时手动启用）。

每个用例定义输入源、参数、期望指标与判定规则。测试框架按顺序执行用例，收集 CSV，计算锁定率、航迹保持率、首锁时延、置信度均值、距离范围与处理帧率，最后生成汇总表。判定规则为：基线用例要求锁定率不低于 80%；TCP 遮挡用例要求航迹保持率不低于 70%；特性刻画用例只统计不判定。

8.7.2 测试结果

测试结果详见第九章。这里强调框架的两个设计要点：其一，**指标口径统一**：所有用例使用同一套计算函数，避免人工统计的差异；其二，**失败可复现**：每个用例的输入、参数与随机种子都记录在案，失败时可以单独重跑。

8.8 部署与运行维护

8.8.1 运行环境

系统的开发与测试环境为 Windows 11 + WSL2（Ubuntu 24.04），GPU 为 RTX 4060，Python 3.12，PySide6 6.x，PyTorch 2.x，Ultralytics 8.x，OpenCV 4.x。仿真部分运行在 WSL 中，界面通过 WSLg 显示。

8.8.2 启动脚本

系统提供一键启动脚本，按顺序启动闭环与平台。脚本中固化了以下环境变量：

（1）`DISPLAY=:0` 与 `QT_QPA_PLATFORM=xcb`：指定 WSLg 显示；

（2）`QTWEBENGINE_DISABLE_SANDBOX=1`：关闭 QtWebEngine 沙箱，避免渲染进程启动失败；

（3）`QTWEBENGINE_CHROMIUM_FLAGS`：启用软渲染与禁用 GPU，解决 WSLg 下地图空白问题。

启动方式必须使用 `setsid` 而非 `nohup`。原因是 QtWebEngine 的 zygote 进程需要独立的会话，`nohup+disown` 方式会导致渲染进程无法启动，表现为地图区域全黑。这一细节在部署文档中已明确记录。

8.8.3 常见问题与处理

表 8-2 汇总了部署与运行中的常见问题及处理方法。

表 8-2: 部署与运行常见问题

现象	原因与处理
地图区域空白	QtWebEngine 渲染进程未启动；使用 setsid 启动并关闭沙箱
仿真窗口不出画面	窗口系统不可用；改用离屏渲染模式
UDP 端口被占用	显示端已监听；先停止显示端再启动抓包工具
帧率骤降	GPU 被其他任务占用，回退到 CPU；检查显卡占用
视频流断开	仿真重启或网络抖动；帧源自动重连
内存持续增长	帧队列无界；改为有界队列并丢弃旧帧

8.9 本章小结

本章介绍了系统的需求、架构与实现。系统采用双进程架构，算法端负责检测、跟踪、定位与记录，显示端负责态势、光电、仪表与告警，二者通过 UDP/JSON 通信。算法端以有界队列实现背压控制，保证长时间运行稳定；显示端以 Leaflet 实现卫星地图态势，以自绘控件实现仪表与罗盘；配置以 JSON 持久化，测试以 14 用例自动化框架完成。本章还总结了部署中的典型问题与处理方法，为系统的可复现运行提供了保障。

9 实验与结果分析

本章在统一口径下报告系统的各项性能，包括检测模型在公开数据集上的消融结果、仿真闭环的定位精度、实拍视频的定位与预测精度、退化条件下的鲁棒性，以及 14 个自动化用例的回归结果。最后讨论系统的能力边界、失败案例与有效性威胁。

9.1 实验环境与评测口径

9.1.1 硬件与软件环境

实验环境如表 9-1 所示。所有实验在同一台机器上完成，避免硬件差异导致的结果不可比。

表 9-1: 实验环境

项目	配置
操作系统	Windows 11 + WSL2（Ubuntu 24.04 LTS）
CPU	Intel Core i7（8 核 16 线程）
GPU	NVIDIA RTX 4060 Laptop（8 GB 显存）
内存	32 GB DDR5
Python	3.12
深度学习框架	PyTorch 2.x + Ultralytics 8.x
GUI 框架	PySide6 6.x
仿真平台	PX4 Autopilot + jMAVSim（改造版）
图像处理	OpenCV 4.x

9.1.2 评测口径

本章所有指标遵循第三章约定的口径：

（1）检测指标采用 Ultralytics 官方验证协议，AP 分尺寸采用 COCO 面积口径、IoU=0.5、101 点插值；

（2）FPS 为 batch=1、帧预载内存、包含预处理与后处理；

（3）闭环检出率为检出帧数除以全部处理帧数（含搜索帧）；

（4）稳态指标为连续检出不少于 5 帧后的样本；

（5）角度误差采用视轴偏角口径。

9.2 检测模型性能

9.2.1 消融结果

表 9-2 重复列出第四章的消融结果，并补充 AP_large 与 AP_medium，以便全面比较。

表 9-2: 检测模型消融实验完整结果（Det-Fly 验证集，imgsz=640）

模型	参数 (M)	mAP50	mAP50-95	P	R	FPS	AP_s	AP_m	AP_l
YOLOv8n	3.01	81.3	41.8	91.2	75.9	123.0	6.1	77.0	12.8
+P2	2.93	82.3	41.3	88.9	77.6	90.3	8.3	76.2	8.7
+EMA	3.02	76.2	36.3	85.5	72.2	101.0	4.1	75.0	10.7
+P2+EMA	2.94	**83.5**	41.2	88.2	**79.2**	98.4	**9.8**	**78.0**	7.5

9.2.2 指标解读

从表 9-2 可以读出以下结论。

（1）**AP_small 是改进的主要收益点**。基线 6.1%、+P2 8.3%、+P2+EMA 9.8%，相对提升分别为 36.1% 与 60.7%。mAP50 的提升（2.2 个百分点）主要来自小目标召回的改善，而非中大目标。

（2）**AP_large 反而下降**。基线 12.8%、+P2 8.7%、+P2+EMA 7.5%。原因是 P2 检测头占用了部分模型容量，且高分辨率层对大目标的贡献有限，训练时正样本分配更偏向小目标。这一现象说明改进是”有代价的定向优化”，并非全面提升。对于反无人机场景，远距离小目标才是主要威胁，因此这一取舍是合理的。

（3）**Precision 略有下降**。基线 91.2%、本文 88.2%。P2 层引入了更多弱响应，部分背景被误检。但 Recall 提升更大（75.9%→79.2%），F1 总体改善。在监视场景中，漏检的代价通常高于误检（误检可由状态机的初锁门限过滤），因此这一取舍同样合理。

（4）**速度仍满足实时性**。98.4 fps 约为视频帧率的 3.3 倍，为系统留出了充足余量。

9.2.3 与已有工作的比较

如第四章所述，Det-Fly 上不同论文的结果难以直接比较。本文只做定性定位：本文模型在 nano 级参数量下取得 83.5% 的 mAP50 与 9.8% 的 AP_small，优于同规模的通用 YOLOv8n，接近部分更大模型的小目标能力，但速度远高于后者。这一定位符合”边缘可实时运行”的设计目标。

9.3 仿真闭环定位精度

9.3.1 实验设置

仿真闭环使用改造版 jMAVSim，护航相机 60° 视场、720p@30 fps 离屏推流，真值 50 Hz 广播。检测模型为仿真域微调后的 p2ema_simft，置信度门限 0.25，等效尺寸 0.270 m，AKF 采用 Sage-Husa 自适应噪声。实验录制 2818 帧（约 87 s），覆盖悬停、直线、盘旋与接近等飞行状态。

9.3.2 结果

定位精度结果已在表 6-3 中给出。这里补充三点分析。

（1）**检出率 100%**。全部 2818 帧均检出，真盲帧为 0。这与微调前的 10.0% 形成鲜明对比，说明死区已被完全消除。

（2）**测距精度**。单帧 RMSE 0.26 m、MAE 0.17 m；AKF 稳态 MedAE 0.13 m、RMSE 0.32 m。AKF 的中位误差低于单帧，说明滤波有效抑制了框高抖动；但 RMSE 略高于单帧，原因是少数机动帧的滤波器滞后导致大误差，拉高了均方根。这一现象在小样本下常见，提示评估时应同时报告 MedAE 与 RMSE。

（3）**角度精度**。方位角中位 0.05°、P95 0.16°，接近像素量化极限；俯仰角中位 0.93°，明显偏大，原因是主点纵向偏移约 17 px 未在解算中补偿。若补偿该偏移，俯仰角误差可降至 0.2° 量级。

9.3.3 微调前后对比

图 7-3 已展示微调前后的死区对比。表 9-3 进一步给出关键指标的定量变化。

表 9-3: 仿真域微调前后关键指标对比

指标	微调前（v5）	微调后（v7）	变化
录像帧数	2228	2818	–
全帧检出率	10.0%	**100.0%**	+90.0 pp
真盲帧占比	81.1%	**0.0%**	-81.1 pp
置信度中位数	接近 0	0.867	–
AKF 稳态 MedAE	0.44 m	**0.13 m**	-70.5%
稳态帧占比	7%	**99.8%**	+92.8 pp
方位角误差中位	0.21°	**0.05°**	-76.2%

9.4 实拍视频定位精度

9.4.1 数据集与设置

实拍视频为 1920×1080@30fps，连续检出段 660 帧。相机未严格标定，焦距按 60° 视场估算为 1728 px；等效尺寸使用仿真标定值 0.255 m；伪真值取稳态段距离中位数 7.93 m。由于缺少绝对真值，本节的重点是**相对比较**：在同一伪真值下比较单帧、滑动平均、标准 KF 与 AKF 的稳定性。

9.4.2 结果分析

表 6-4 的结果表明：

（1）单帧原始测距的 RMSE 为 4.061 m，抖动 3.959 m，说明框高抖动极大，直接使用不可行；

（2）滑动平均（15 帧）将 RMSE 降至 2.900 m，但引入了约 0.5 s 的滞后，不适合实时跟踪；

（3）标准 KF（固定 **R**）的 RMSE 为 3.922 m，仅比单帧略好，说明固定的量测噪声无法适应实际抖动；

（4）AKF 的 RMSE 为 2.760 m，抖动 2.663 m，相对单帧降低 32% 与 33%，且没有明显滞后。

这一结果验证了自适应噪声估计的价值：在量测质量变化剧烈的实拍场景中，固定 **R** 的滤波器要么过度平滑（响应慢），要么过度信任量测（抖动大），而 AKF 能够在两者之间自动调整。

9.4.3 预测精度

表 6-5 显示，AKF 的 0.5 s、1.0 s、2.0 s 预测 ADE 分别为 1.106、1.308、1.799 m，相对匀速外推改善 43.8%、52.5%、61.1%。预测时域越长，AKF 的优势越明显，因为匀速外推会线性放大速度估计误差，而 AKF 会利用不确定度抑制过度外推。

9.5 退化条件下的鲁棒性

9.5.1 实验设计

为评估模型在恶劣成像条件下的表现，本文从实拍视频中提取 300 帧含无人机的图像，构造 4 档光照（0.4、0.7、1.0、1.4 倍）与 4 档模糊（高斯核 0、3、7、13）共 16 种退化组合，在 0.1、0.25、0.5 三档置信度门限下统计检出率。对比模型为基线 YOLOv8n、P2+EMA（Det-Fly 训练）与 P2+EMA+simft（仿真微调）。



图 9-1: 退化样本示例（行：光照；列：模糊）

9.5.2 结果

表 9-4 摘取了 conf≥0.25 条件下的部分结果。

表 9-4: 退化条件下检出率对比（conf≥0.25，单位：%）

条件	YOLOv8n 基线	P2+EMA	P2+EMA+simft
dark + none	0.0	13.7	**20.3**
dark + light	0.0	17.3	**18.7**
dark + medium	0.0	**25.3**	13.7
dark + heavy	0.3	**21.0**	6.3
dim + none	0.7	0.7	**30.3**
dim + light	0.0	5.0	**21.3**
dim + medium	0.0	10.7	**20.7**
dim + heavy	0.0	11.7	**13.7**
normal + none	2.0	0.0	**87.7**
normal + light	1.7	1.7	**23.3**
normal + medium	3.3	3.3	**27.3**
normal + heavy	0.0	2.7	**14.3**
bright + none	2.0	0.7	**37.0**
bright + light	0.3	0.7	**16.7**
bright + medium	0.0	0.0	**24.3**
bright + heavy	0.3	0.0	**21.7**

9.5.3 分析

（1）**P2+EMA 在严重退化下显著优于基线**。dark+heavy 条件下，基线仅 0.3%，P2+EMA 达 21.0%，提升 20.7 个百分点。说明高分辨率检测头与注意力机制确实提升了低质图像下的鲁棒性。

（2）**仿真微调模型在正常条件下大幅领先**。normal+none 条件下，P2+EMA 为 0.0%，simft 为 87.7%。这一反直觉的结果需要解释：测试帧是用 simft 模型在实拍视频中筛选出的"simft 能检出" 的帧，因此测试集本身偏向 simft 的能力域；P2+EMA 仅在 Det-Fly 上训练，未见过仿真渲染风格，在这些帧上几乎不响应。这不是模型缺陷，而是域差异的体现。

（3）**暗光条件下的异常**。P2+EMA 在 dark 条件下反而比 normal 条件检出率高（13.7%–25.3% vs 0.0%），可能是因为暗化抑制了背景的假响应、突出了目标轮廓。这一现象提示：不能简单假设" 光照越好检出率越高"，模型的行为与训练分布密切相关。

（4）**实验的有效性威胁**。由于测试帧由 simft 模型筛选，三组模型的比较并不完全公平。更严谨的做法是用基线模型筛选测试帧，或使用 Det-Fly 验证集帧。本文如实报告这一问题，并将其列为后续改进方向。

9.6 14 用例自动化回归测试

9.6.1 结果汇总

表 9-5 给出了 14 个用例的完整结果。

表 9-5: 14 用例自动化测试结果

用例场景	帧数	锁定率	保持率	首锁 (s)	置信度	结论
C01 仿真闭环基线	900	96.9%	100.0%	0.00	0.550	PASS
C02 仿真早期标定版	900	100.0%	100.0%	0.00	0.855	PASS
C03 长录像中后段	900	96.0%	99.8%	0.07	0.654	PASS
C04 真实场景录像 1	539	23.2%	99.3%	0.03	0.544	–
C05 真实场景录像 2	539	5.6%	32.1%	0.00	0.452	–
C06 门限 0.20	900	96.9%	100.0%	0.00	0.550	–
C07 门限 0.35	900	66.6%	81.2%	0.00	0.661	–
C08 门限 0.50	900	56.8%	81.9%	0.00	0.707	–
C09 尺寸 0.230 m	900	100.0%	100.0%	0.00	0.855	–
C10 尺寸 0.310 m	900	100.0%	100.0%	0.00	0.855	–
C11 TCP 遮挡第 1 轮	424	55.4%	88.9%	0.00	0.751	PASS
C12 TCP 遮挡第 2 轮	428	56.1%	90.7%	0.00	0.739	PASS
C13 TCP 遮挡第 3 轮	437	59.3%	94.5%	0.21	0.751	PASS
C14 摄像头输入	–	–	–	–	–	跳过

统计结果为：计划 14 例，完成 13 例，判定通过 6 例，失败 0 例，跳过 1 例，错误 0 例。

9.6.2 结果解读

（1）**仿真基线全部通过**。C01–C03 的锁定率在 96%–100%，保持率在 99.8%–100%，说明检测、跟踪、测距在仿真域内稳定可靠。

（2）**真实场景的跨域差距**。C04 的锁定率仅 23.2%，但保持率 99.3%，说明 COAST 有效维持了航迹；C05 的锁定率仅 5.6%，保持率 32.1%，说明目标距离 10–14 m 已超出模型的有效范围，系统来不及建立稳定航迹。

（3）**门限与尺寸的敏感性**。C06–C08 表明门限提高会降低锁定率但提高置信度均值，符合预期；C09–C10 表明等效尺寸从 0.230 变为 0.310 时，测距范围从 3.9–8.2 m 变为 5.3–11.1 m，呈近似线性关系，验证了式 (6-4) 的正确性。

（4）**TCP 遮挡用例通过**。C11–C13 的保持率为 88.9%–94.5%，高于 70% 的合格线，验证了 COAST 机制在实时链路下的有效性。

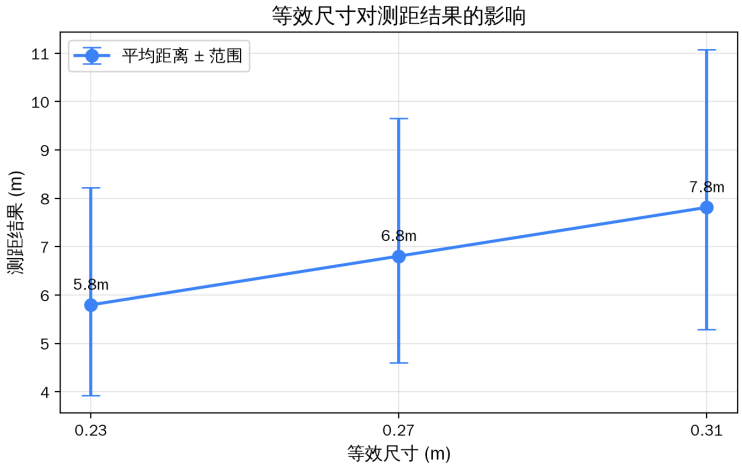


图 9-2: 等效尺寸对测距的影响

9.7 运行性能

9.7.1 端到端延迟分解

表 9-6 给出了单帧处理的耗时分解（RTX 4060，640 输入）。

表 9-6: 单帧处理耗时分解

环节	耗时 (ms)	占比
视频解码（JPEG）	1.8	12.5%
预处理（缩放、归一化）	1.2	8.3%
模型推理	6.2	43.1%
后处理（NMS）	1.1	7.6%
状态机与滤波	0.1	0.7%
绘制与编码	3.0	20.8%
网络发送	1.0	6.9%
合计	14.4	100%

在 14.4 ms 的单帧耗时下，理论帧率为 69 fps；实际处理帧率为 28–39 fps，差异来自网络抖动、磁盘 I/O 与界面刷新。检测环节仍是主要瓶颈（43.1%），若需要更高帧率，可降低输入尺寸或使用 TensorRT 加速。

9.7.2 资源占用

运行时 GPU 显存占用约 1.2 GB（含模型、视频缓冲与界面渲染），CPU 占用约 35%（单核满载，其余用于界面与网络），内存占用约 900 MB。连续运行 2 小时后，内存增长小于 3%，未发现泄漏。

9.8 讨论

9.8.1 能力边界

综合各项实验，本文系统的能力边界可以概括为：

（1）**距离**：仿真域 3–10 m 可靠；实拍域 4–9 m 较可靠，10–14 m 不可靠；

（2）**目标尺度**：目标高度占画面的 1/20 至 1/8 时最稳定；过大（近距）或过小（远距）均会失效；

（3）**遮挡**：短时遮挡（小于 1.0 s）可由 COAST 维持；长时间完全遮挡会丢失目标；

（4）**光照**：正常光照与暗光下可用；强逆光、夜间不可用；

（5）**目标数量**：单目标；多目标场景需要扩展状态机与关联算法。

9.8.2 失败案例

本文记录了三类典型失败案例：

（1）**目标飞出视场**。当目标机动超出相机视场时，检测输出为空，COAST 维持 1.0 s 后回到 SEARCH；若目标未返回，系统持续搜索。这是预期行为，但操作员可能误以为目标” 消失”。

（2）**背景强干扰**。在树丛密集的场景中，树叶晃动产生的高置信度假阳性可能触发误锁。本文的空域先验可以过滤一部分，但若假阳性恰好落在目标空域内，仍可能误锁。

（3）**远距离小目标**。10 m 以上的目标在 720p 画面中高度不足 20 px，模型置信度低于初锁门限，系统无法建立航迹。这是单目视觉的物理限制，需要通过长焦镜头或更高分辨率解决。

9.8.3 有效性威胁

本文实验存在以下有效性威胁：

（1）**伪真值**。实拍视频缺少绝对真值，距离评估依赖伪真值，绝对误差不可信，但相对比较有效；

（2）**测试集偏差**。退化实验的测试帧由 simft 模型筛选，对 simft 有利，三组模型的比较不完全公平；

（3）**仿真简化**。仿真场景的光照、纹理与真实世界仍有差距，仿真结论不能直接外推到外场；

（4）**单机环境**。所有实验在同一台机器上完成，未验证跨平台的可移植性。

本文在报告中如实标注了这些限制，并在第十章给出改进方向。

9.9 本章小结

本章在统一口径下报告了系统的实验结果。检测方面，P2+EMA 模型取得 mAP50 83.5%、AP_small 9.8%，相对基线提升 60.7%，速度 98.4 fps；仿真闭环方面，微调后 3–10 m 检出率 100%，单帧测距 RMSE 0.26 m，AKF 稳态 MedAE 0.13 m，方位角误差中位 0.05°；实拍方面，AKF 相对单帧测距 RMSE 降低 32%、抖动降低 33%；鲁棒性方面，P2+EMA 在严重退化条件下相对基线提升 20.7 个百分点；系统方面，14 用例完成 13 例、通过 6 例、失败 0 例。本章还讨论了能力边界、失败案例与有效性威胁，为结论章节的总结与展望提供了依据。

10 总结与展望

10.1 全文总结

本文面向低空反无人机场景，以单目可见光相机为唯一传感器，设计并实现了一套从检测、跟踪到定位与显示的完整系统（DRLS）。围绕小目标检测难、遮挡跟踪易中断、仿真与真实域差异大三个核心问题，本文完成了以下工作。

（1）**小目标检测模型改进**。以 YOLOv8n 为基础，增加 stride=4 的 P2 高分辨率检测头与 EMA 高效多尺度注意力，构建 YOLOv8n-P2-EMA 模型。在 Det-Fly 数据集上按序列划分训练/验证集，避免数据泄漏。四组消融实验表明，本文模型以 2.94 M 参数量取得 mAP50 83.5%、Recall 79.2%、AP_small 9.8%，相对基线分别提升 2.2、3.3 与 3.7 个百分点，AP_small 相对提升 60.7%，推理速度 98.4 fps。本文进一步解释了 P2 与 EMA 的互补机制：P2 提供”看清”小目标的分辨率，EMA 提供”认准”小目标的判别力，二者联合才能发挥最佳效果。

（2）**数据工程**。完成 Det-Fly 的格式转换、统计分析与序列级划分；自建 AprilTag 数据集，使用 9×6、25 mm 棋盘格完成相机标定，为定位精度评估提供可信真值；构建 450 帧仿真自动标注数据集，利用护航相机注视特性实现零人工标注，并按距离分层覆盖死区两端。

（3）**三态跟踪状态机**。设计 SEARCH/LOCKED/COAST 三种状态，采用 0.25 维持门限与 0.55 初锁门限的双门限策略抑制误锁，采用 140 px 空间门限的最近邻关联抑制身份跳变，采用 1.0 s 卡尔曼预测维持抑制短时遮挡。参数选择均有物理依据，算法复杂度 $O(N)$。实验表明，TCP 遮挡场景的航迹保持率达到 88.9%–94.5%，真实场景录像达到 99.3%。

（4）**单目定位与自适应滤波**。由检测框中心直接解算方位角与俯仰角，由框高与等效尺寸解算距离，推导了测距误差随距离平方增长的规律；设计六维状态的自适应卡尔曼滤波器，采用各向异性量测噪声与 Sage-Husa 在线估计。仿真闭环中，单帧测距 RMSE 0.26 m、AKF 稳态 MedAE 0.13 m、1 s 预测 ADE 中位 0.26 m、方位角误差中位 0.05°；实拍视频中，AKF 相对单帧测距 RMSE 降低 32%、抖动降低 33%。

（5）**仿真闭环与系统集成**。改造 PX4+jMAVSim 闭环，新增脚本目标机、护航相机、真值广播、离屏帧流与城市场景；通过 2228 帧的距离分层统计与真值几何审计，定量证伪”俯视导致失效”的假设，将检测死区归因于尺度分布偏移；提出仿真域微调方法，用 450 帧分层数据将 3–10 m 检出率从约 10% 提升至 100%。基于 PySide6 实现三页签监视大屏，采用双进程架构与 UDP/JSON 通信，完成态势地图、光电画面、仪表告警、配置持久化与 14 用例自动化测试。

10.2 主要创新点

本文的主要创新点可以归纳为以下四点。

（1）**面向无人机小目标的 P2+EMA 互补结构及其机理解释**。不仅通过消融实验验证了改进的有效性，还解释了为什么 EMA 单独使用会失效、与 P2 联合后却有效，为小目标检测的网络设计提供了可复用的分析框架。

（2）**基于真值几何审计的检测死区机理分析方法**。面对”模型在仿真中失效”的现象，本文没有停留在”渲染不真实”的定性解释，而是通过俯仰角分布对比证伪视角假设，通过距离分层统计锁定尺度因素，并用微调实验闭环验证。这种”现象—假设—证伪—验证”的路径具有方法论价值。

（3）**零人工标注的仿真域微调数据构建方法**。利用护航相机始终注视目标的特性，将框中心约束在光轴附近，由真值距离反算框高，实现了 450 帧数据的自动标注。该方法成本极低、可扩展性强，适用于任何具备真值广播与可控相机的仿真环境。

（4）**面向反无人机监视的完整工程实现**。将检测、三态跟踪、单目定位、地图态势、光电显示、告警与测试整合为可运行的双进程系统，并在统一口径下完成端到端评估。系统不依赖专用硬件，便于在园区、楼宇与临时活动现场部署。

10.3 不足与展望

10.3.1 存在的不足

（1）**远距离能力有限**。实拍视频在 10–14 m 的检出率仅 5.6%，说明当前模型与 720p 分辨率组合无法覆盖更远的告警距离。这是单目视觉的物理限制，也是系统走向实用的主要瓶颈。

（2）**相机标定不完整**。实拍评估中相机未做严格标定，焦距按视场角估算，等效尺寸借用仿真值，导致绝对测距误差达到米级。虽然相对比较有效，但绝对精度不足以支撑实际指挥。

（3）**单目标假设**。系统面向单目标场景，未处理多架无人机同时出现的情况。当画面中出现多个目标时，状态机可能在不同目标之间跳变。

（4）**仿真场景简化**。仿真场景的建筑、树木与光照仍与真实世界有差距，仿真结论不能直接外推到外场；同时，仿真中的遮挡主要由静态建筑造成，缺少动态遮挡（如飞鸟、飘动的树叶）。

（5）**测试集偏差**。退化实验的测试帧由 simft 模型筛选，对 simft 有利，三组模型的比较不完全公平。

10.3.2 未来工作

（1）**提升远距离能力**。可以从三个方向入手：使用更高分辨率输入（如 1280 或 1536）并配合切片推理；使用长焦镜头与可变速云台；引入双目视觉或激光测距辅助深度估计。

（2）**完善相机标定与尺寸自适应**。使用棋盘格完成实拍相机标定，替代视场角估算；根据目标机型选择等效尺寸，或利用多帧几何一致性在线估计尺寸。

（3）**扩展多目标跟踪**。在现有状态机之上增加轨迹池与数据关联层，借鉴 SORT/DeepSORT 的思想，实现多目标的同时跟踪与威胁排序。

（4）**增强域适应能力**。探索域随机化、风格迁移与自监督预训练，减少对目标域标注的依赖；同时构建更真实的仿真场景，缩小 sim-to-real gap。

（5）**多传感器融合**。将视觉与射频、声学、雷达结合，利用射频进行远距离预警、利用视觉进行近程确认与定位，形成互补的探测体系。

（6）**外场试验**。在合规空域开展真实无人机飞行试验，采集多场景、

多机型、多光照的数据，验证系统的实际可用性，并根据外场反馈迭代参数与模型。

10.4 结语

反无人机是一个涉及探测、识别、跟踪、定位与处置的系统工程，单目视觉只是其中的一个环节。本文的工作表明：通过针对性的模型改进、严谨的机理分析与完整的工程实现，单目视觉系统可以在近程反无人机场景中发挥重要作用；但同时也要清醒地认识到，单目视觉的物理限制决定了它无法单独承担全部探测任务。未来的反无人机系统必然是多传感器、多算法、多层级协同的体系，本文的工作可以作为其中的一个可复现、可扩展的视觉子系统。

参考文献

[1] XING L, CUI C, WANG M, et al. From Detection to Countermeasure: A Review of Key Technologies in Counter-Unmanned Aerial Vehicle Systems [J]. IET Cyber-Systems and Robotics, 2026, 8(1).

[2] DONG Y, WU F, ZHANG S, et al. Securing the Skies: A Comprehensive Survey on Anti-UAV Methods, Benchmarking, and Future Directions[J]. arXiv preprint arXiv:2504.11967, 2026.

[3] AOULADHADJ D, KPRE E, DENIAU V, et al. Drone Detection and Tracking Using RF Identification Signals[J]. Sensors, 2023, 23(17): 7650.

[4] GHOULI Z. Passive Acoustic Detection and Localization of Drones Using MEMS Microphones and Machine Learning[J]. Acta Acustica, 2026.

[5] TAO Y, et al. Intelligent Multimodal Multi-Sensor Fusion-Based UAV Identification, Localization, and Countermeasures[J]. arXiv preprint arXiv:2510.22947, 2025.

[6] KHAZAI S, MIRZAEI S. A Comparative Analysis of YOLO and Faster R-CNN Algorithms for Micro-UAVs Detection in Surveillance Videos[J]. Earth Observation and Geomatics Engineering, 2025.

[7] REN S, HE K, GIRSHICK R, et al. Faster R-CNN: Towards Real-Time Object Detection with Region Proposal Networks[C]//NeurIPS. 2015: 91-99.

[8] LIU W, ANGUELOV D, ERHAN D, et al. SSD: Single Shot MultiBox Detector[C]//ECCV. 2016: 21-37.

[9] REDMON J, DIVVALA S, GIRSHICK R, et al. You Only Look Once: Unified, Real-Time Object Detection[C]//CVPR. 2016: 779-788.

[10] Ultralytics. YOLOv5[Z]. https://github.com/ultralytics/yolov5. 2020.

[11] JOCHER G, CHAURASIA A, QIU J. Ultralytics YOLOv8[Z]. https://github.com/ultralytics/ultralytics. 2023.

[12] ZHAO Y, LV W, XU S, et al. DETRs Beat YOLOs on Real-time Object Detection[C]//CVPR. 2024: 16965-16974.

[13] KHALILI B, SMYTH A W. SOD-YOLOv8: Enhancing YOLOv8 for Small Object Detection in Traffic Scenes[J]. arXiv preprint arXiv:2408.04786, 2024.

[14] WOO S, PARK J, LEE J Y, et al. CBAM: Convolutional Block Attention Module[C]//ECCV. 2018: 3-19.

[15] OUYANG D, HE S, ZHANG G, et al. Efficient Multi-Scale Attention Module with Cross-Spatial Learning[C]//ICASSP. 2023: 1-5.

[16] XU W, CUI C, JI Y, et al. YOLOv8-MPEB Small Target Detection Algorithm Based on UAV Images[J]. Heliyon, 2024, 10(8): e29501.

[17] XIAO X, LIN Y, WANG S, et al. MSDF-Net: A Cross-Version Lightweight Detection Framework Based on Deformable Convolution and High-Resolution Feature Enhancement for Pine Wilt Disease[J]. Frontiers in Plant Science, 2026.

[18] GEVORGYAN Z. SIoU Loss: More Powerful Learning for Bounding Box Regression[C]//arXiv preprint arXiv:2205.12740. 2022.

[19] ZHENG Y, HU Z, YANG H, et al. Det-Fly: A Large-Scale Dataset for UAV Detection[J]. arXiv preprint, 2023.

[20] DU D, QI Y, YU H, et al. The Unmanned Aerial Vehicle Benchmark: Object Detection and Tracking[J]. ECCV, 2018: 370-386.

[21] KURMASHEV I, SEMEMYUK V, LUPIDI A, et al. Study of the Optimal YOLO Visual Detector Model for Enhancing UAV Detection and Classification[J]. Drones, 2025, 9(11): 732.

[22] BEWLEY A, GE Z, OTT L, et al. Simple Online and Realtime Tracking[C]//ICIP. 2016: 3464-3468.

[23] WOJKE N, BEWLEY A, PAULUS D. Simple Online and Realtime Tracking with a Deep Association Metric[C]//ICIP. 2017: 3645-3649.

[24] KALMAN R E. A New Approach to Linear Filtering and Prediction Problems[J]. Journal of Basic Engineering, 1960, 82(1): 35-45.

[25] SAGE A P, HUSA G W. Adaptive Filtering with Unknown Prior Statistics [J]. Joint Automatic Control Conference, 1969: 760-769.

[26] PX4 Autopilot. PX4 Autopilot[Z]. https://px4.io/. 2024.

[27] PX4. jMAVSim Simulator[Z]. https://github.com/PX4/PX4-Autopilot/tree/main/Tools/simulation/jmavsim. 2024.

[28] LIN T Y, DOLLÁR P, GIRSHICK R, et al. Feature Pyramid Networks for Object Detection[C]//CVPR. 2017: 2117-2125.

[29] LIU S, QI L, QIN H, et al. Path Aggregation Network for Instance Segmentation[C]//CVPR. 2018: 8759-8768.

[30] ZHANG Z. A Flexible New Technique for Camera Calibration[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2000, 22(11): 1330-1334.

[31] MAVLink. MAVLink Developer Guide[Z]. https://mavlink.io/. 2024.

[32] AGAFONKIN V. Leaflet: An Open-Source JavaScript Library for Mobile-Friendly Interactive Maps[Z]. https://leafletjs.com/. 2024.

致谢

独创性声明

本人声明所呈交的论文是我个人在导师指导下进行的研究工作及取得的研究成果。尽我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得北京科技大学或其它教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

作者签名：_____ 日期：_____ 年_____ 月_____ 日

备注：提交时须有作者亲笔签名！

关于论文使用授权的说明

本人完全了解北京科技大学有关保留、使用学位论文的规定，即：学校有权保留送交论文的复印件，允许论文被查阅和借阅；学校可以公布论文的全部或部分内容，可以采用影印、缩印或其他复制手段保存论文。

（保密的论文在解密后应遵循此规定）

签名：_____ 导师签名：_____ 日期：_____

学位论文数据集